数据采集与模仿学习

课程首页 · English · PDF

项目	说明
适用范围	示教数据、BC、DAgger、ACT、生成式动作块策略
文档核验日期	2026-10-18
许可	CC BY 4.0 · Xiong Zeng and contributors

核验边界： 方法与实验设计，未实际复现训练。 版本与固定源码引用见版本说明。原创教材采用 CC BY 4.0，第三方引用、图片及代码遵循其原有许可；注明来源不等于拥有再许可权。

目录

- 1. 从演示到可训练的数据
  - 1.1 一条轨迹应包含什么
  - 1.2 时间和坐标系先于网络结构
- 2. 数据采集与质量控制
  - 2.1 成功演示之外，还需要什么
  - 2.2 数据划分比指标数字更重要
- 3. 模仿学习：从 BC 到交互式纠错
  - 3.1 为什么训练误差低也会失败
  - 3.2 DAgger 是什么
- 4. 从单步动作到生成式动作块
  - 4.1 ACT 的核心思路
  - 4.2 Diffusion Policy 与 Flow Matching
- 5. 增强、再标定与仿真数据
  - 5.1 接触事件和恢复样本
  - 5.2 数据增强的安全边界
- 6. 统一 Panda 桌面抓取实验
  - 6.1 最小实验表
  - 6.2 常见失败排查
- 7. 统一数据模型：从轨迹到动作块
  - 7.1 为什么要区分真实状态、观测与命令
  - 7.2 Action Chunk 的学习目标
  - 7.3 时间戳、坐标系与归一化
- 8. BC 的数学形式、设计动机与局限
  - 8.1 确定性 BC 与概率 BC
  - 8.2 分布偏移：为什么测试时误差会累积
  - 8.3 动作块监督与平滑的取舍

- 9. 从离线 BC 到交互式模仿学习
  - 9.1 DAgger 的数据聚合与专家查询
  - 9.2 失败轨迹、恢复示教与标签质量
- 10. ACT、Diffusion Policy、Flow Matching 与 RTC：训练和执行
  - 10.1 ACT：CVAE 与 Transformer 动作块
  - 10.2 Diffusion Policy：以噪声预测学习动作块分布
  - 10.3 Flow Matching：动作速度场与物理速度不是一回事
  - 10.4 生成式策略和 BC 的公平对照
  - 10.5 RTC 为什么重要：从同步动作块到异步执行
  - 10.6 Inference-time RTC：把两段动作块衔接变成 Inpainting
  - 10.7 Training-time RTC：在模仿学习阶段学会遵守已承诺动作
  - 10.8 RTC 和 Temporal Ensembling、普通异步执行如何比较
- 11. 人类视频重定向、接触与数据增强
  - 11.1 从人类视频到机器人动作不是直接复制像素
  - 11.2 轨迹增强必须保持物理和标签一致
- 12. 建议的训练与评估规范
  - 12.1 区分离线预测、闭环成功率和扰动恢复
  - 12.2 一个贯穿课程的最小实验
- 13. 课程衔接与参考资料

学习目标： 识别示教数据质量问题；理解 BC、DAgger、ACT、Diffusion/Flow 的动作块训练；区分 Inference-time 与 Training-time RTC，并设计兼顾延迟、连续性和任务成功率的实验。

1. 从演示到可训练的数据

模仿学习的目标不是保存一段看起来正确的视频，而是把观察、机器人状态、动作和任务条件组织成可对齐、可复现的监督信号。对于闭环机器人，最终学习的是条件策略 $\pi_\theta(a_t \mid o_{\le t}, g)$，其中 g 是目标。

1.1 一条轨迹应包含什么

建议每条 episode 至少保存：任务与场景 ID、相机时间戳、RGB 或 RGB-D、关节状态、执行动作、动作坐标系、控制模式、成功与否、异常事件。**动作标签必须表示实际发给机器人的命令**，不能把目标关节角、实际反馈位置和关节速度混为一谈。对视觉模型，还需注明相机外参是静态还是时变。

1.2 时间和坐标系先于网络结构

使用统一的时钟基准或经验证的时间对齐。标明 T_B^C、T_B^E、T_B^O 的定义，所有姿态矩阵使用相同的乘法约定。相机通常低频，机器人本体状态可能更高频；可采用与动作时刻对齐的最近帧或带明确延迟的插值，避免未来信息泄漏。

2. 数据采集与质量控制

典型数据源包括遥操作、拖动示教、脚本专家、仿真 RL 专家和人类视频重定向。它们在采样效率、动作精度、接触真实性和设备成本上各有差异。



实用原则： 一开始优先获得质量稳定且可复现的小数据集，而不是尽快积累大量未标注或不同步的视频。

2.1 成功演示之外，还需要什么

保留有效的失败轨迹、纠错动作与恢复片段，并标注事件边界，例如接触开始、滑落、重新抓取。不要把所有失败都作为“照做”的标签；区分应模仿的恢复策略与应避免的危险命令。明确数据使用权限、隐私、许可证及真实机器人安全审核。

2.2 数据划分比指标数字更重要

按对象实例、场景布局、操作者、初始姿态和采集日期划分训练与测试；**禁止同一连续轨迹切块后同时出现在训练集和测试集**。记录真实 episode 级成功率，而不仅是逐动作 MSE。多相机或多帧观测应整体划分，防止相邻帧泄漏。

3. 模仿学习：从 BC 到交互式纠错

Behavior Cloning（BC）直接优化数据上的动作预测。对于确定性回归可采用 $\mathcal{L}_{BC} = \mathbb{E}_{(o,a)\sim D}\|\pi_\theta(o) - a\|_2^2$；对于概率策略则最大化动作条件对数似然。这两种目标并不自动解决测试时的分布偏移。

3.1 为什么训练误差低也会失败

闭环执行中，小的动作误差会改变下一时刻的观测，机器人可能进入训练集从未覆盖的状态。应在测试时记录状态偏移、触碰失败、纠错次数，以及是否能从偏离轨迹的状态恢复。可加入安全受控的小扰动或恢复示教，扩大有效状态覆盖。

3.2 DAgger 是什么

DAgger 的思想是让当前策略收集会访问的状态，并由专家为这些状态提供适当动作，再聚合数据更新策略。对真实机器人要有明确的安全干预机制；如果无法在线查询专家，就不能简单地把普通离线训练称为 DAgger。

4. 从单步动作到生成式动作块

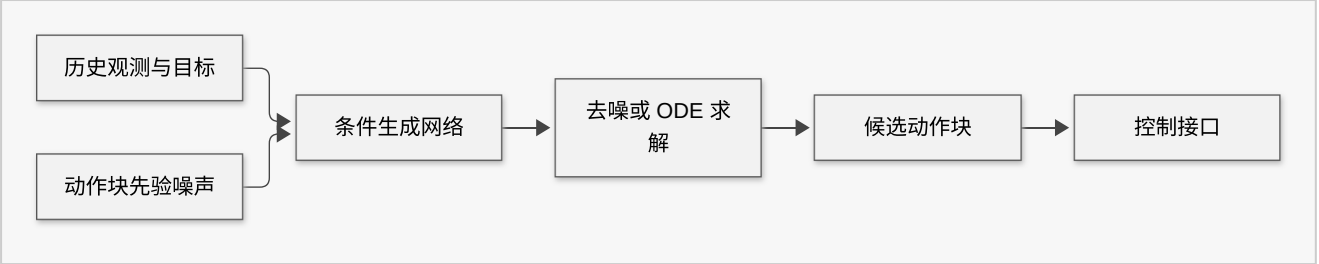
生成动作块可减少频繁重规划的开销，但会引入执行中观测过时的风险。区分 chunk horizon（预测长度）、execution horizon（执行长度）与 policy query rate（模型调用频率）。动作块的控制参考系必须和机器人的实际执行器接口一致。

4.1 ACT 的核心思路

ACT 使用 Transformer 预测一段连续的动作，并在论文实现中借助潜变量建模演示差异。与逐步 BC 相比，动作块适合示教数据中连续且结构化的操作，但需要正确处理 chunk 的对齐与组合。

4.2 Diffusion Policy 与 Flow Matching

Diffusion Policy 与 Flow Matching 都可用生成式机制表示多模态动作分布，但**扩散去噪过程、概率流或速度场求解与机器人关节速度是不同概念**。



在比较方法时，固定观察模态、示教数据量、推理预算、控制频率与评估环境；不能只比较离线训练损失。

5. 增强、再标定与仿真数据

在机器人操作中，几何变换必须一致地作用于图像、物体目标、轨迹参考和动作标签。仅把图像旋转而不调整动作的增强通常会产生错误监督。仿真专家轨迹可以扩充姿态覆盖，但接触参数、视觉渲染和执行器时延的 Sim-to-Real 差异需要单独验证。

5.1 接触事件和恢复样本

报告均匀采样基线，再评估接触切换、夹持失败和物体掉落附近的增采样。事件采样改变训练数据分布，需要明确其权重以及是否扭曲自然状态分布；也要评估无事件偏置的测试集。

5.2 数据增强的安全边界

不应把任意初始条件直接传播到不满足物理约束的接触轨迹。对旋转、平移、尺度、时序扰动都检查可达性、碰撞、接触一致性和控制限幅；可先做短时物理回放再收录。

6. 统一 Panda 桌面抓取实验

实验任务： 在 Isaac Lab 或 MuJoCo 中让 Panda 抓取随机放置的方块，先生成脚本专家或遥操作轨迹，再训练 BC / ACT / 生成式策略。

控制变量： 固定相机视角、训练任务数、机器人动作接口、控制频率、训练/测试对象划分、评估回合数。以简单 BC 作为所有生成式方法的必要基线。

指标： 成功率、接触失败率、轨迹偏差、恢复率、平均策略推理延迟、平均控制延迟与数据量。每种方法报告多个随机种子和失败模式，而非宣称某方法天然最优。

6.1 最小实验表

对照	目的
BC 单步	数据与控制接口是否正确
BC 动作块	排除 chunking 本身的贡献

对照	目的
ACT	检验 Transformer 行为生成
Flow/Diffusion	检验多模态动作建模
增加恢复示教	检验闭环扰动恢复

6.2 常见失败排查

优先检查时间对齐、动作/反馈混淆、相机外参、动作缩放、延迟、策略执行长度、数据划分与初始化分布，最后再考虑扩大模型。不能用只在训练集上计算的 action MSE 代替真机任务成功率。

7. 统一数据模型：从轨迹到动作块

7.1 为什么要区分真实状态、观测与命令

在机器人控制中，真实世界状态 s_t（物体速度、摩擦系数、接触模式等）一般无法被完整观测。机器人可以记录图像 o_t^{cam}、关节反馈 q_t、实际发送的控制命令 a_t 和任务目标 g。将一条示教定义为

$$\tau_i = \{g_i, (o_t^{\text{cam}}, q_t, a_t, r_t^{\text{event}})_{t=0}^{T_i-1}\}.$$

事件标注 r_t^{event} 可以表示接触、滑落、恢复与任务完成，**不是必须使用的强化学习奖励**。不要把仿真器的真实物体位姿、示教者未来的动作或后处理的成功标签偷放到部署策略输入。若监督信号来自动作命令而观测来自延迟的反馈，应明确这一时序关系。

7.2 Action Chunk 的学习目标

策略从最近 L 帧观测、当前本体状态和目标构造条件 $c_t = (o_{t-L+1:t}, q_t, g)$，预测长度为 H 的动作块

$$A_t = (a_t, a_{t+1}, \dots, a_{t+H-1}), \qquad p_\theta(A_t \mid c_t).$$

H 是**预测长度**，不是必须开环执行的步数。实际执行 $h \le H$ 步后重新观测，构成滚动时域控制。策略查询周期、机器人低层控制周期、动作块执行长度必须分别记录。例如视觉为 30 Hz、低层伺服为 100 Hz 时，策略可以低于伺服频率运行，但中间的插值和超时机制不可省略。

7.3 时间戳、坐标系与归一化

动作时间为 t_k^a 时，输入图像必须满足其**可用时间**不晚于 t_k^a。图像采集、传输与推理的延迟记为 δ，采用 $t_j^{\text{image}} \le t_k^a - \delta$ 的历史图像；不要使用未来图像对齐训练样本。对末端位姿动作，若增量定义在基座系可写作 $T_{BE,t+1} = \Delta T_{B,t} T_{BE,t}$；若定义在末端系则为 $T_{BE,t+1} = T_{BE,t} \Delta T_{E,t}$。**两种约定不可混用**。

对训练集中的动作分量计算 μ_D, σ_D 后归一化：

$$\tilde{a} = (a - \mu_D)/(\sigma_D + \varepsilon), \qquad a_{\text{deployed}} = \tilde{a}(\sigma_D + \varepsilon) + \mu_D.$$

不同关节角、夹爪开合或末端旋转需要正确的单位与限幅。检查归一化统计是否意外使用测试集数据。

8. BC 的数学形式、设计动机与局限

8.1 确定性 BC 与概率 BC

给定示教数据分布 $d_E(c, a)$，最简单的确定性 BC 优化

$$\mathcal{L}_{\mathrm{BC}}(\theta) = \mathbb{E}_{(c,a)\sim d_E} \|\pi_\theta(c) - a\|_2^2.$$

它在均方损失下趋向条件均值 $\mathbb{E}[a \mid c]$。当专家行为近似单峰时，它是低成本、值得保留的强基线；当同一条件下“从左绕开”和“从右绕开”都是合理动作时，平均行为可能撞上障碍物。

用概率模型更一般地写为最大似然：

$$\mathcal{L}_{\mathrm{NLL}}(\theta) = -\mathbb{E}_{(c,a)\sim d_E} \log p_\theta(a \mid c).$$

对于一般高斯 $p_\theta(a \mid c) = \mathcal{N}(\mu_\theta(c), \Sigma_\theta(c))$，NLL 包含 $\frac{1}{2}(a-\mu_\theta)^\top \Sigma_\theta^{-1}(a-\mu_\theta)$ 和 $\frac{1}{2}\log|\Sigma_\theta|$；因此只有协方差固定时才退化为加权 MSE。

若 p_θ 为方差固定的各向同性高斯分布，NLL 与带常数系数的 MSE 等价。多峰分布需要混合密度模型或生成式动作策略，**不能只因为动作维度高就认定 BC 必然失败**。

8.2 分布偏移：为什么测试时误差会累积

离线 BC 在专家访问的状态分布 d_{π_E} 上训练，但部署后的数据来自 d_{π_θ}，两者可能不同：

$$\min_\theta \mathbb{E}_{s\sim d_{\pi_E}} \ell(\pi_\theta(s), \pi_E(s)) \quad \not\Rightarrow \quad \min_\theta \mathbb{E}_{s\sim d_{\pi_\theta}} \ell(\pi_\theta(s), \pi_E(s)).$$

一个小的接触误差可能触发物体滑动，使后续观察脱离训练分布。专家示教集中在成功轨迹时，模型可能根本没有见过“物体掉落后重新抓取”的状态。这解释了为什么测试需要扰动恢复回合，而不仅是随机抽样的动作回归误差。

8.3 动作块监督与平滑的取舍

在带掩码的变长轨迹中，动作块回归可以写为

$$\mathcal{L}_{\mathrm{chunk}} = \frac{\sum_{t,k} m_{t,k} w_k \|\hat{a}_{t+k|t} - a_{t+k}\|_1}{\sum_{t,k} m_{t,k} w_k},$$

其中 $m_{t,k} \in \{0,1\}$ 排除越界步，w_k 可以减小远期预测权重。可选的动作平滑正则为 $\lambda_s \sum_k \|\hat{a}_{k+1} - \hat{a}_k\|^2$，但精密插装、接触切换时动作变化可能是必要的，**过度平滑会抹掉真实接触事件**。比较正则前后成功率和力/速度峰值，而不是只看曲线是否光滑。

9. 从离线 BC 到交互式模仿学习

9.1 DAgger 的数据聚合与专家查询

DAgger 的要点不是简单再训练，而是让当前策略暴露它自己会遇到的状态，专家再标注这些状态。第 i 轮执行混合策略 $\pi_i = \beta_i \pi_E + (1-\beta_i)\pi_{\theta_i}$，采集 $s \sim d_{\pi_i}$，专家提供动作 $\pi_E(s)$，然后更新

$$D_{i+1} = D_i \cup \{(s, \pi_E(s)) : s \sim d_{\pi_i}\}, \qquad \theta_{i+1} = \arg\min_\theta \sum_{(s,a)\in D_{i+1}} \ell(\pi_\theta(s), a).$$

β_i 通常逐步降低。真实机器人上必须给专家接管、安全停止和强制限幅预留控制权；不能直接让未经审查的探索命令在硬件上自由执行。

9.2 失败轨迹、恢复示教与标签质量

示教可以分为成功完成、可恢复失败、不可恢复失败、人工中断四类。只对**可安全模仿的动作**建立监督，记录接触开始、滑移、掉落、重新定位、重新抓取等事件。对于不可安全复现的行为，应保留结果标签与日志用于分析，而不是直接做正例 BC。

可选的事件采样权重为 $w_t = 1 + \lambda \sum_j \exp[-(t - t_j)^2/(2\sigma^2)]$，其中 t_j 表示接触/滑移等事件时刻。

建议在均匀时间采样的 baseline 之后再加入 event-biased sampling。若事件权重为 w_t，可以采用 $\mathcal{L} = \sum_t w_t \ell_t / \sum_t w_t$；必须披露其改变的训练分布，并在无偏的测试集上评估。

10. ACT、Diffusion Policy、Flow Matching 与 RTC：训练和执行

10.1 ACT：CVAE 与 Transformer 动作块

Action Chunking with Transformers（ACT）通过 Transformer 预测整段关节命令，原始方案还使用条件变分自编码器处理示教的风格差异。训练时编码器近似 $q_\phi(z \mid A, c)$，解码器给出 $p_\theta(A \mid z, c)$，常见的损失为

$$\mathcal{L}_{\text{ACT}} = \mathbb{E}_{z\sim q_\phi}\big[-\log p_\theta(A \mid z, c)\big] + \beta\, D_{\text{KL}}(q_\phi(z \mid A, c) \| p(z)).$$

第二项把示教编码分布约束到先验 $p(z)$；推理阶段没有真实未来动作块 A 可用，应从约定先验采样或使用其确定性代表。β 过大可能造成后验塌缩，过小则易使训练与推理潜变量分布不一致。

10.2 Diffusion Policy：以噪声预测学习动作块分布

令 A_0 为真实动作块、$\epsilon \sim \mathcal{N}(0, I)$、扩散时间 k，构造

$$A_k = \sqrt{\bar\alpha_k} A_0 + \sqrt{1 - \bar\alpha_k}\epsilon.$$

一个常见的条件噪声预测目标为

$$\mathcal{L}_{\text{diff}} = \mathbb{E}_{A_0, c, k, \epsilon} \| \epsilon - \epsilon_\theta(A_k, k, c) \|_2^2.$$

推理时从高斯噪声迭代去噪得到动作块，并只执行其中一部分，再基于新观测重规划。计算量由去噪步数、动作维度和视觉编码器共同决定；“生成式”本身不保证实时。

10.3 Flow Matching：动作速度场与物理速度不是一回事

为便于解释，设数据端点 $A_1 \sim p_{\text{data}}(\cdot \mid c)$、噪声 $A_0 \sim \mathcal{N}(0, I)$，选择直线路径 $A_\tau = (1 - \tau) A_0 + \tau A_1$。一个条件速度回归目标为

$$\mathcal{L}_{\text{FM}} = \mathbb{E}_{c, A_0, A_1, \tau} \| v_\theta(A_\tau, \tau, c) - (A_1 - A_0) \|_2^2.$$

采样时求解生成空间 ODE：$dA_\tau / d\tau = v_\theta(A_\tau, \tau, c)$。其中 v_θ 是**动作样本在生成时间 τ 上的变化方向**，不是机械臂关节速度 $\dot q$。不同论文的时间方向和路径不同；严格的连续性方程、条件期望推导及 OpenPI 的时间约定统一放在 Flow Matching 专题，本章只说明与模仿学习的接口。

10.4 生成式策略和 BC 的公平对照

先用相同数据、同一观测编码、同一动作表示和相同执行长度比较：单步 BC、chunked BC、ACT、Diffusion Policy、Flow Matching。报告训练数据量、推理频率、生成步数、动作延迟和实际任务成功率。不能把“ACT

的动作块收益”误记成“Transformer 架构收益”，也不能把更多推理计算导致的增益归因于算法本身。

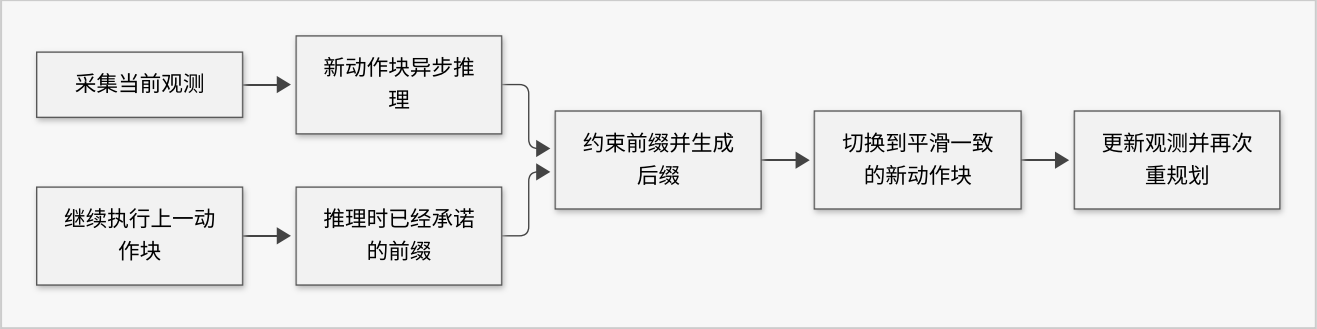
10.5 RTC 为什么重要：从同步动作块到异步执行

Real-Time Chunking（RTC）不是另一个 BC 损失函数，也不是一种新的机器人动作策略。它是使现有的 Diffusion / Flow Matching 动作块策略在高推理延迟下持续闭环工作的执行与条件生成方法。普通同步执行在每个动作块结束后等待下一次推理，机器人会暂停；简单地异步生成下一块虽能消除暂停，却可能在切换时跳到另一条合理但不连续的轨迹。Temporal Ensembling 将多条动作预测取平均，在多模态接触任务中也可能把两条可行轨迹平均成不可行轨迹。

设动作块长度为 H，每次实际执行 $s \le H$ 步，低层控制周期为 Δt，从观测采集到下一动作块可用的总推理延迟为 δ。用控制步数表示延迟：

$$d \approx \left\lceil \frac{\delta}{\Delta t} \right\rceil, \qquad A_t = (a_t, \dots, a_{t+H-1}).$$

这里的向上取整是**工程调度中的保守近似**；原始 RTC 论文为便于分析使用 $\lfloor \delta/\Delta t \rfloor$，并通过近期观测延迟估计下一次 d。对原论文的异步调度，需要同时满足 $d \le s \le H - d$：$d \le s$ 确保能够在下一次切换前启动并完成推理，$d \le H - s$ 确保旧动作块覆盖生成延迟。还应为延迟抖动、初始化及超时预留余量。例如 50 Hz 控制对应 $\Delta t = 20$ ms，实测延迟 140 ms 对应约 $d = 7$ 步，若 $H = 50$、$s = 20$，则可提前启动下一块推理，而旧块继续提供控制命令。这个条件不替代丢包、超时与急停机制。



10.6 Inference-time RTC：把两段动作块衔接变成 Inpainting

令 $\mathbf{Y}$ 表示**上一动作块中与新动作块的绝对时间索引对齐**的动作计划，A^τ 为新动作块生成过程在生成时间 $\tau \in [0,1]$ 的变量。由于前 d 步已由上一块承诺执行，新块的前缀不能改变；其后仍与旧块重叠的动作可以软约束，以允许新观测修正计划。论文中的 Soft Mask 可以写为

$$W_i = \begin{cases} 1, & 0 \le i < d, \\ c_i(e^{c_i} - 1)/(e - 1), & d \le i < H - s, \\ 0, & H - s \le i < H, \end{cases}$$

$$c_i = \frac{H - s - i}{H - s - d + 1}.$$

$W_i = 1$ 的区间是已经决定执行的动作前缀；中间区间权重逐渐下降；最后 s 步没有旧计划约束。这是**生成时的约束权重**，不能理解为对两个完整轨迹做后处理加权平均。

对于噪声到数据方向的 Flow Matching，一个局部的终点预测是

$$\widehat{A}^1 = A^\tau + (1 - \tau) v_\theta(A^\tau, \tau, c).$$

论文的 Pseudoinverse Guidance（Eq. 2–4）可等价写成加权误差负梯度形式：

$$\tilde{v}_\theta = v_\theta - \lambda_\tau \nabla_{A^\tau}\left[\frac{1}{2}\|W^{1/2}\odot(\widehat{A}^1 - Y)\|_2^2\right].$$

其中原论文的权重截断精确为

$$r_\tau^2 = \frac{(1-\tau)^2}{\tau^2+(1-\tau)^2}, \qquad \lambda_\tau = \min\left(\beta, \frac{1-\tau}{\tau\, r_\tau^2}\right).$$

β 用于避免生成末期引导项数值过大；分母中的 τ 接近 0 或 1 时需采用实现规定的裁剪或数值保护。 更新 $A^{\tau+\Delta\tau} = A^\tau + \Delta\tau\,\tilde{v}_\theta$，使生成动作块既兼容已经执行或承诺的前缀，又可更新未承诺的未来部分。梯度项需要在生成步骤计算向量–Jacobian 乘积，因此**Inference-time RTC 不必重新训练模型，但会增加推理计算**。该机制面向可做连续生成/引导的 Flow Matching 或 Diffusion Policy；对普通确定性 ACT 输出，不能直接假定同一 Inpainting 求解器可用。

10.7 Training-time RTC：在模仿学习阶段学会遵守已承诺动作

Training-Time Action Conditioning for Efficient Real-Time Chunking 进一步把“固定动作前缀”纳入监督训练。它直接学习：

$$p_\theta(A_{d:H} \mid c, A_{0:d}),$$

其中 $A_{0:d}$ 表示索引 $0,\dots,d-1$ 的已承诺动作，$A_{d:H}$ 表示尚需生成的后缀（区间均采用左闭右开约定）。对一条完整专家动作块 A，随机采样部署延迟步数 $0 \le d < H$、生成时间 τ 与噪声 ϵ，构造逐动作的时间与输入：

$$\bar{\tau}_i = \begin{cases} 1, & i < d, \\ \tau, & i \ge d, \end{cases} \qquad \widetilde{A}_i = \bar{\tau}_i A_i + (1-\bar{\tau}_i)\epsilon_i.$$

因此前 d 个动作是**未加噪的真值前缀**，后续动作才学习去噪；网络需要支持每个 action token 不同的生成时间条件。只对后缀计算条件 Flow Matching 损失：

$$\mathcal{L}_{\text{RTC-train}} = \mathbb{E}_{A,c,d,\tau,\epsilon}\left[\frac{1}{H-d}\sum_{i=d}^{H-1}\|v_\theta(\widetilde{A},\bar{\boldsymbol{\tau}},c)_i - (A_i-\epsilon_i)\|_2^2\right].$$

部署时把上一块中已经确定的动作作为前缀传给生成器，固定其值，**仅生成未来后缀**。这样不需要 Inference-time RTC 每步额外的梯度引导，但需要针对延迟分布重新训练或微调，并可能丧失前述软重叠约束的灵活性。训练用的前缀来自专家示教，部署前缀可能来自模型自身计划；仍需用受控 rollout 测试这种分布偏移。

这一方法特别适合本章，因为它直接改变**模仿学习的训练样本构造、token 条件与损失掩码**；严格的速度场与 ODE 数学推导依旧留在 Flow Matching 专章。训练时应从实测延迟分布采样 d，而不是无依据地指定统一延迟；例如论文在 $\pi_{0.6}$ 实验中训练了随机延迟前缀，并比较了模型延迟与任务性能。

10.8 RTC 和 Temporal Ensembling、普通异步执行如何比较

执行方法	是否等待推理	如何保证新旧动作块兼容	是否要改训练
同步 Chunking	需要	块间通常停顿，动作从新观测开始	否
Naive Asynchronous	通常不等待	直接切换，可能有轨迹跳跃	否
Temporal Ensembling	可以异步	对重叠预测加权平均，多峰策略不一定有效	否
Inference-time RTC	异步	固定承诺前缀 + Soft Mask / 生成时引导	**否**，但推理开销更高
Training-time RTC	异步	训练时以前缀为条件，部署时固定 Hard Prefix	**是**，推理不再额外做梯度引导

最小实验： 对同一个 Flow Matching 策略、同一动作频率、相同初始状态和相同控制安全层，比较上述五种模式，并注入 0/100/200 ms 的额外延迟。除了任务成功率、完成时间和每分钟吞吐量，还应记录实际端到端推理延迟 p50/p95、控制空档次数、块间动作跳变 $\|a_t - a_{t-1}\|$、加速度/jerk、接触失败率和掉落后的恢复率。要区分“模型推理时间”“动作交接延迟”和“机器人执行时间”，不能只展示离线 FPS。

进一步阅读： RTC 原论文（NeurIPS 2025）、训练时前缀条件（2025）、Physical Intelligence 视频与解释、LeRobot RTC 文档。2026 年的 Soft RTC 与 DiscreteRTC 进一步探索软重叠先验与离散动作生成器的原生 Inpainting，属于扩展阅读，**不能把它们的实验结论直接当作基础 RTC 的通用优势**。

11. 人类视频重定向、接触与数据增强

11.1 从人类视频到机器人动作不是直接复制像素

可采用“视频中的手/工具位姿估计 → 相机与尺度对齐 → 目标机器人运动学重定向 → 接触时间段识别 → 物理回放与不可达轨迹修复 → 学习”的链条。人类手与灵巧手的自由度、连杆长度及摩擦条件不同，简单的关节角映射通常不足以复现接触。重定向的目标可包含手部追踪、接触位置和约束软惩罚：

$$\mathcal{L}_{\text{retarget}} = w_p \|p_{\text{robot}} - p_{\text{target}}\|^2 + w_R \, d_{SO(3)}(R_{\text{robot}}, R_{\text{target}})^2 + w_c \mathcal{L}_{\text{contact}} + w_j \mathcal{L}_{\text{limits}}.$$

这里 $\mathcal{L}_{\text{contact}}$ 必须针对具体任务定义，例如接触点距离、接触法线、抓握保持或物体相对滑移；不等于“两个物体距离近”就保证存在力学接触。

11.2 轨迹增强必须保持物理和标签一致

对物体姿态的随机旋转与平移，需同步变换目标、观测几何和所有依赖参考系的动作标签。图像旋转不伴随动作坐标变换通常会导致错误监督。接触阶段还应在短时物理回放中检查指尖穿透、物体滑落、关节限位、控制频率和接触力，删去不可信增强片段。

12. 建议的训练与评估规范

12.1 区分离线预测、闭环成功率和扰动恢复

测试	应测指标	不能替代什么
留出示教集	NLL / 动作误差、chunk 接口一致性	不能代替闭环成功率
常规随机初始位	成功率、完成时间、碰撞与接触失败率	不能代替扰动测试
扰动 / 掉落后恢复	Recovery success、恢复时长、重新抓取次数	不能代替正常性能
跨场景和跨对象	分组划分的泛化成功率	不能使用相邻轨迹帧泄漏
系统实时性	策略推理 p50/p95 延迟、执行器延迟	不能只报告 GPU 帧率

成功率估计 $\hat{p} = k/N$ 应同时报告独立试验数 N、训练随机种子及置信区间；粗略标准误差为 $\sqrt{\hat{p}(1-\hat{p})/N}$，当 N 小或成功率接近 0/1 时采用 Wilson 区间。不能将相互相关的同一条轨迹的动作帧当作独立 episode。

12.2 一个贯穿课程的最小实验

在同一 Panda + 方块 + 桌面场景训练五个基线，固定训练 episode 数、相机、控制模式与任务划分。按阶段报告：首先验证动作标签，随后比较 BC 与 chunked BC，再比较 ACT、Diffusion/Flow，最后专门加入恢复示教并做随机外力或物体位姿扰动。在 Isaac / MuJoCo 交叉测试时明确控制器和接触模型可能不等价。

章节边界： 本章深入讲采集、示教监督、分布偏移、生成动作策略和数据设计；PPO/SAC 的理论推导仍在各自专题，Flow Matching 的严格数学推导见相应章节，视觉 6D 位姿与 SAM/Foundation 系列见 视觉感知与状态估计。

13. 课程衔接与参考资料

本章连接相机标定、视觉状态估计、Flow Matching与GR00T / SONIC。

- ACT / ALOHA
- Diffusion Policy
- DAgger
- Flow Matching for Generative Modeling
- LeRobot

核验边界： 本章是方法与实验设计导论；没有声称这些算法已在本课程统一 Panda 环境复现。