具身智能中的深度学习基础：从梯度下降到 Transformer

监督学习、反向传播、MLP、注意力与机器人基础模型

2026-10-28

目录

1. 从机器人任务理解深度学习 . . . 2
2. 监督学习：样本、目标与泛化 . . . 2
3. 梯度下降与反向传播：逐步推导 . . . 4
4. MLP：最简单的机器人策略网络 . . . 5
5. Transformer：从 Token 到 Attention . . . 6
6. 多模态 Transformer 与机器人动作头 . . . 7
7. 预训练、微调与强化学习后训练的关系 . . . 9
8. 稳定训练与评估：机器人数据的特殊性 . . . 9
9. 实时推理与部署：模型计算不等于机器人控制 . . . 10
10. 架构选择、误区与学习路径 . . . 10
11. 术语对照与参考资料 . . . 11

新增专题：从反向传播到 BPTT——理解 SuperMimic 所需的微分计算 . . . 11

课程首页 ·English Markdown ·中文 PDF

项目	说明
主题	深度学习基础
修订日期	2026-10-28
许可	CC BY-NC-SA 4.0 ·Xiong Zeng and contributors

1. 从机器人任务理解深度学习

监督学习、反向传播、*MLP*、*Transformer* 与机器人策略网络
更新日期：2026 年 10 月 19 日

核心问题：机器人如何从示教数据中学习动作？损失函数如何通过反向传播改变网络参数？MLP 与 Transformer 各自负责什么？视觉、语言、本体状态怎样形成可执行的动作？

1.1 不是“预测下一个词”，而是学一个条件映射

设机器人在时刻 t 获得视觉观测 o_t、本体感知 q_t（关节角、关节速度、夹爪状态）以及任务条件 g。最简单的策略是

$$\hat{a}_t = f_\theta(o_t, q_t, g), \qquad u_t = \text{Controller}(\hat{a}_t, q_t),$$

其中 θ 为网络参数，$\hat{a}_t$ 是**希望执行**的策略动作，u_t 是经控制器、滤波、限幅或安全约束处理后的实际命令。二者可能具有不同的单位或频率，不能混为一谈。策略输出可能是关节目标、末端位姿增量，也可能是未来 H 步的动作块 $A_t = (a_t, \dots, a_{t+H-1})$。

深度学习解决的是**如何以可训练参数表示输入到输出的映射或概率分布**。物理正确性、接触约束、时延、安全与泛化并不会仅因模型够大而自动成立。

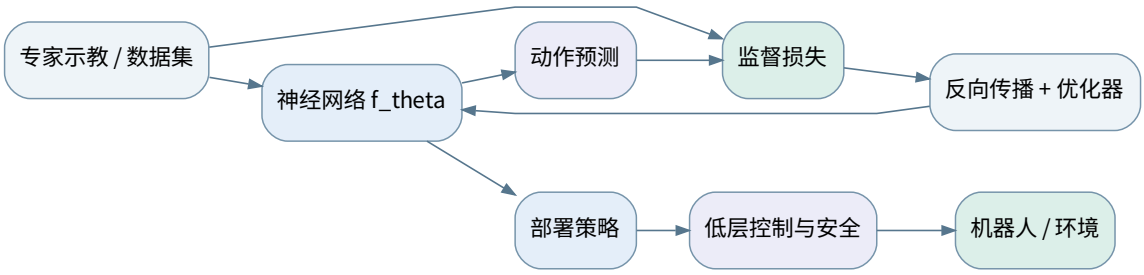


图 *1.* 训练环路用标签计算误差并更新参数；部署环路还必须经过低层控制与安全接口。

1.2 四个容易混淆的层次

层次	回答的问题	具身智能中的例子
网络架构	如何表示输入与输出之间的关系?	MLP、CNN、ViT、Transformer
训练目标	什么预测被认为是好的?	MSE、交叉熵、NLL、Flow Matching 损失
参数优化器	给定目标后如何更新参数?	SGD、Momentum、AdamW
学习范式 / 算法	通过什么数据与反馈学习?	BC、DAgger、PPO、SAC、RL Post-training

例如，**BC 可以使用 MLP 或 Transformer**；**Flow Matching 是训练目标，不是特定神经网络架构**；**PPO 与 SAC 是强化学习算法而不只是梯度优化器**。一个 VLA 也不是单独一种 Attention 公式，它是一套包含编码器、条件融合、动作表示与训练协议的系统。

2. 监督学习：样本、目标与泛化

2.1 从专家示教构造训练集

监督数据集写为 $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{N}$。在机器人行为克隆（Behavior Cloning, BC）中，$x_i = (o_i, q_i, g_i)$，$y_i = a_i^E$ 是专家动作。监督学习最小化经验风险：

$$\hat{\theta} = \arg\min_{\theta} \frac{1}{N} \sum_{i=1}^{N} \ell(f_\theta(x_i), y_i).$$

必须区分**观测与标签的时间对应关系**：相机帧产生时刻、动作命令下发时刻和机器人反馈时刻并非总相同。把执行后的画面当作该动作执行前的条件，会引入数据泄漏或错误因果对应。

2.2 连续动作的回归损失

最常见的是均方误差：

$$\mathcal{L}_{\text{MSE}} = \frac{1}{N} \sum_{i=1}^{N} \|f_\theta(x_i) - a_i^E\|_2^2.$$

若不同关节、平移与旋转尺度不同，可使用半正定权重矩阵 W：

$$\mathcal{L}_W = \frac{1}{N} \sum_i (\hat{a}_i - a_i^E)^\top W (\hat{a}_i - a_i^E), \qquad W \succeq 0.$$

对多维动作，训练前应明确角度单位、坐标系以及归一化规则。对旋转姿态直接使用欧氏距离并不总能尊重 $SO(3)$ 的几何结构；具体运动学损失属于机器人动力学与操作学习课程的范围。

若输出长度为 H 的动作块并存在补齐，使用有效掩码 $m_{ik} \in \{0, 1\}$：

$$\mathcal{L}_{\text{chunk}} = \frac{\sum_{i,k} m_{ik}\, \ell(\hat{a}_{ik}, a_{ik}^E)}{\sum_{i,k} m_{ik} + \varepsilon}.$$

2.3 分类、概率预测和最大似然

离散抓取模式或接触模式可以用交叉熵：

$$\mathcal{L}_{\text{CE}} = -\frac{1}{N} \sum_i \log p_\theta(y_i \mid x_i).$$

如果连续动作采用固定协方差的高斯分布，$p_\theta(a \mid x) = \mathcal{N}(a; \mu_\theta(x), \Sigma)$，则负对数似然（NLL）去掉与 θ 无关的常数后为

$$\mathcal{L}_{\text{NLL}} = \frac{1}{2N} \sum_i (a_i - \mu_\theta(x_i))^\top \Sigma^{-1} (a_i - \mu_\theta(x_i)).$$

所以固定各向同性协方差时，**MSE 与高斯最大似然的最优均值预测一致**。若连协方差也学习，还必须保留 $\frac{1}{2} \log\det \Sigma_\theta(x)$ 项；否则仅增大预测方差就可能降低二次误差项。

2.4 为什么监督误差低不代表操作成功率高

动作可多模态：同一障碍物可左绕或右绕，MSE 训练的点预测趋向条件均值 $\mathbb{E}[a \mid x]$，均值动作可能恰好不可执行。ACT、Diffusion 和 Flow Matching 等方法可表达更丰富的动作分布，但**多模态表达**不等于**闭环恢复能力**。

另外，BC 训练样本来自专家状态分布 d^{π_E}，部署时状态来自学习策略的 d^{π_θ}。早期小误差造成偏移后，模型可能进入未见过的接触状态；需要 DAgger、纠错示教或 RL 等机制改善分布覆盖。这些机制将在模仿学习与后训练课程详细讨论。

3. 梯度下降与反向传播：逐步推导

3.1 梯度下降到底修改什么

假设目标函数为 $\mathcal{L}(\theta)$。梯度指出损失在参数空间的局部上升方向，故最基本的更新是

$$\boxed{\theta^{(k+1)} = \theta^{(k)} - \eta \nabla_\theta \mathcal{L}(\theta^{(k)})},$$

其中 $\eta > 0$ 是学习率。若 $\mathcal{L}$ 可微，则一阶泰勒近似给出

$$\mathcal{L}(\theta - \eta g) \approx \mathcal{L}(\theta) - \eta \nabla \mathcal{L}(\theta)^\top g.$$

取 $g = \nabla \mathcal{L}(\theta)$ 时，右侧减小 $\eta \|\nabla \mathcal{L}\|^2$；但较大学习率、高曲率、随机梯度噪声都可能使**真实一步损失反而升高**。

3.2 一维线性策略：手算一次更新

令 $\hat{a} = wx + b$，单个样本的损失取 $L = \frac{1}{2}(wx + b - y)^2$。记误差 $e = wx + b - y$，则

$$\frac{\partial L}{\partial w} = ex, \qquad \frac{\partial L}{\partial b} = e.$$

例如 $x = 2, y = 3, w = 1, b = 0$，则 $\hat{a} = 2, e = -1$，梯度为 $(-2, -1)$。学习率 $\eta = 0.1$ 时，

$$(w^+, b^+) = (1, 0) - 0.1(-2, -1) = (1.2, 0.1).$$

更新后的预测为 2.5，损失由 0.5 降为 0.125。**梯度下降并不是直接移动机器人的动作；它改变网络参数，使以后对相同条件的动作预测发生变化**。

3.3 两层 MLP 的链式法则

考虑

$$z_1 = W_1 x + b_1, \qquad h = \sigma(z_1), \qquad \hat{y} = W_2 h + b_2,$$

以及 $L = \frac{1}{2}\|\hat{y} - y\|_2^2$。先计算输出误差 $\delta_2 = \hat{y} - y$：

$$\begin{aligned} \nabla_{W_2} L &= \delta_2 h^\top, & \nabla_{b_2} L &= \delta_2, \\ \delta_1 &= (W_2^\top \delta_2) \odot \sigma'(z_1), & & \\ \nabla_{W_1} L &= \delta_1 x^\top, & \nabla_{b_1} L &= \delta_1. \end{aligned}$$

这里 $\odot$ 是逐元素乘法，δ_1 将输出端的误差沿网络结构向后传播。**反向传播（Backpropagation）是对计算图高效应用链式法则以求梯度，不是一种与梯度下降并列的优化算法**。

若 $x \in \mathbb{R}^d$、$h \in \mathbb{R}^m$、$\hat{y} \in \mathbb{R}^p$，则 $W_1 \in \mathbb{R}^{m \times d}$、$W_2 \in \mathbb{R}^{p \times m}$，梯度与对应参数矩阵同形。检查维度可以捕获大量初学者推导错误。

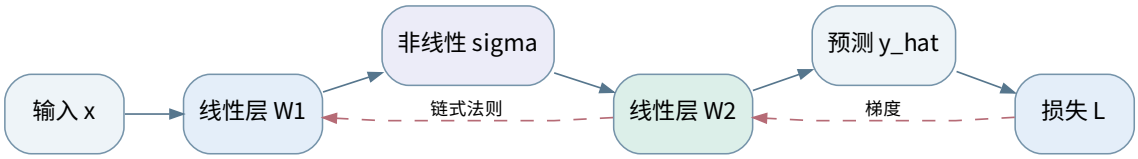


图 *2.* 前向计算生成预测；反向计算沿计算图传递局部导数。

3.4 从全量梯度到 Mini-batch、SGD 与 AdamW

实际训练在大小为 B 的 Mini-batch 上估计梯度

$$g_k = \frac{1}{B}\sum_{i\in\mathcal{B}_k} \nabla_\theta \ell_i(\theta_k), \quad \theta_{k+1} = \theta_k - \eta g_k.$$

SGD 使用当前随机梯度；Momentum 对梯度方向做时间平均；**Adam** 还对梯度平方作自适应缩放。Adam 的基本递推为

$$\begin{aligned} m_k &= \beta_1 m_{k-1} + (1-\beta_1) g_k, \\ v_k &= \beta_2 v_{k-1} + (1-\beta_2) g_k \odot g_k, \\ \hat{m}_k &= m_k/(1-\beta_1^k), \qquad \hat{v}_k = v_k/(1-\beta_2^k). \end{aligned}$$

AdamW 将权重衰减与梯度更新解耦，典型形式为

$$\theta_{k+1} = (1-\eta\lambda)\theta_k - \eta \frac{\hat{m}_k}{\sqrt{\hat{v}_k}+\epsilon}.$$

λ 是权重衰减系数；并非所有参数（如某些 Bias、LayerNorm 系数）都应该使用相同衰减设置。学习率调度、梯度裁剪与混合精度是训练稳定性工具，不能替代正确的监督标签。

4. MLP：最简单的机器人策略网络

4.1 多层感知机的结构与非线性

MLP 由仿射变换与非线性激活交替组成：

$$h^{(0)} = x, \quad h^{(\ell+1)} = \sigma(W_\ell h^{(\ell)} + b_\ell), \quad f_\theta(x) = W_L h^{(L)} + b_L.$$

如果所有 σ 都是恒等映射，则多层线性层的复合仍然只是一个线性映射。因此非线性激活至关重要。常见的 ReLU 为 $\max(0, z)$；GELU 与 SiLU 是现代网络中常见的平滑激活。激活选择影响优化性质、推理成本与输出分布，但不存在对所有机器人任务都最佳的激活函数。

4.2 MLP 如何实现 Actor、Critic 和状态估计器

网络	典型输入	典型输出	学习信号
MLP Actor	$q_t, \dot{q}_t, \hat{x}_t, g$	a_t 或策略分布参数	BC 标签 / 策略梯度
MLP Value Critic	s_t 或可得观测	$V_\phi(s_t)$	回报 / TD 目标
MLP Q Critic	(s_t, a_t)	$Q_\phi(s_t, a_t)$	Bellman 目标
本体状态估计器	观测历史、IMU/电流	速度、接触或隐状态特征	监督 / 自监督
Action Head	主干模型隐藏特征	连续动作、离散 Token	回归 / NLL / 生成损失

以上只是常见设计，Critic 也可以使用图像或 Transformer；Actor 与 Critic 的观测集合甚至可能不同（例如非对称 Actor–Critic）。需区分**网络结构**和**训练信号**。

4.3 为什么 MLP 在具身智能中仍然重要

对低维本体状态或高频低层闭环，MLP 往往具有较低延迟和明确的数值接口。它不需要先把每个标量变成 Token 再做 Attention。然而，当策略必须融合长时历史、许多视觉 Patch、对象关系或语言指令时，MLP 缺乏 Transformer 所具备的显式跨 Token 交互机制。

残差连接可以缓解深层网络的优化难度，例如 $h_{l+1} = h_l + F_l(h_l)$；归一化、初始化、合适的残差尺度也影响训练稳定性。**Transformer Block 本身通常包含由线性层与激活函数组成的 FFN/MLP**。

5. Transformer：从 Token 到 Attention

5.1 从固定维度向量走向 Token 序列

Transformer 处理表示序列 $X = [x_1; \dots; x_n] \in \mathbb{R}^{n \times d}$。语言 Token 来自词表嵌入；图像可被切成 Patch，再映射为视觉 Token；机器人的关节状态、历史动作、末端目标也可以编码为一个或多个 Token。**Token 是模型内部的表示单元，不自动等价于一次物理控制命令**。

仅堆叠 Token 而不表达顺序，Attention 无法直接辨别 “先抓取、后旋转” 和 “先旋转、后抓取”。因此需要位置或时间信息，例如位置嵌入、相对位置 Bias 或旋转位置编码；不同模型采用不同形式。

5.2 Self-Attention 的矩阵推导

由同一序列构造 Query、Key 和 Value：

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V,$$

其中 $Q, K \in \mathbb{R}^{n \times d_k}$，$V \in \mathbb{R}^{n \times d_v}$。第 i 个 Query 与第 j 个 Key 的相似度是 $q_i^\top k_j / \sqrt{d_k}$；对每行做 Softmax 得到权重

$$\alpha_{ij} = \frac{\exp(q_i^\top k_j / \sqrt{d_k})}{\sum_{r=1}^{n} \exp(q_i^\top k_r / \sqrt{d_k})}.$$

第 i 个 Token 的新表示为 $z_i = \sum_j \alpha_{ij} v_j$，整体写为

$$\boxed{\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right) V.}$$

M 可以是遮挡矩阵：在不允许访问的位置添加 $-\infty$，从而使权重为零。**Self-Attention 关注的是信息交互，不是机器人控制意义上的注意力或安全判断**。

5.3 Multi-Head、FFN、Residual 与 LayerNorm

多个 Attention Head 分别学习不同的关系：

$$\mathrm{MHA}(X) = \mathrm{Concat}(Z_1, \dots, Z_h)W_O.$$

典型 Pre-Norm Block 可表示为

$$Y = X + \mathrm{MHA}(\mathrm{LN}(X)), \qquad Z = Y + \mathrm{FFN}(\mathrm{LN}(Y)).$$

FFN 对各 Token 位置共享参数并独立作用于每个位置；Token 间的信息混合主要发生在 Attention 中。LayerNorm 通常沿特征维度归一化，Residual 为梯度传播和深层表达提供直接路径。这里展示的是一种常见实现，不能把它视为所有 Transformer 的唯一形式。

5.4 Encoder、Decoder、因果掩码与 Cross-Attention

Encoder 风格允许观测 Token 彼此双向交互，适合感知和特征融合。**自回归 Decoder** 的因果掩码限制每个位置只能读取已生成或允许的前文，适合序列逐步生成。**Cross-Attention** 使一组 Query 读取另一组上下文 Key/Value：

$$Q = HW_Q, \quad K = CW_K, \quad V = CW_V, \quad \mathrm{CrossAttn}(H, C) = \mathrm{Attention}(Q, K, V).$$

例如 H 是动作查询，C 是视觉与语言的上下文表示。ACT 中可以由动作 Query 读取编码后的多视角视觉与机器人状态，并行形成动作块。VLA 则可以选用独立视觉主干、语言主干与 Action Expert，或使用其他条件融合方式。**Transformer 不仅用于 World Action Model**。

5.5 Attention 的计算代价与时间信息

朴素全 Attention 需要形成 $n \times n$ 权重矩阵，其时间与注意力矩阵存储开销通常随 n 近似呈二次增长。长视频、高分辨率图像与多相机输入因此需要 Token 压缩、稀疏化、分层建模或高效 Attention 实现。FlashAttention 主要减少内存读写、改善精确 Attention 的实现效率，并不会自动改变任务所需的时间感受野。

6. 多模态 Transformer 与机器人动作头

6.1 图像、语言和本体状态如何融合

一个概念性机器人基础模型可写成

$$\begin{aligned} Z_v &= E_v(I_{t-k:t}), & Z_g &= E_g(g), \\ Z_q &= E_q(q_{t-k:t}), & H &= F_\theta(Z_v, Z_g, Z_q), \\ A_t &\sim p_\theta(\cdot \mid H). \end{aligned}$$

E_v 可以是 CNN/ViT，E_g 可以是文本 Transformer，E_q 可以是 MLP；F_θ 通过串接、Cross-Attention 或其他机制融合特征。动作头把隐藏特征映射到机器人的动作空间。此式描述模块**职责**，不强制要求端到端训练或某种固定数据流。

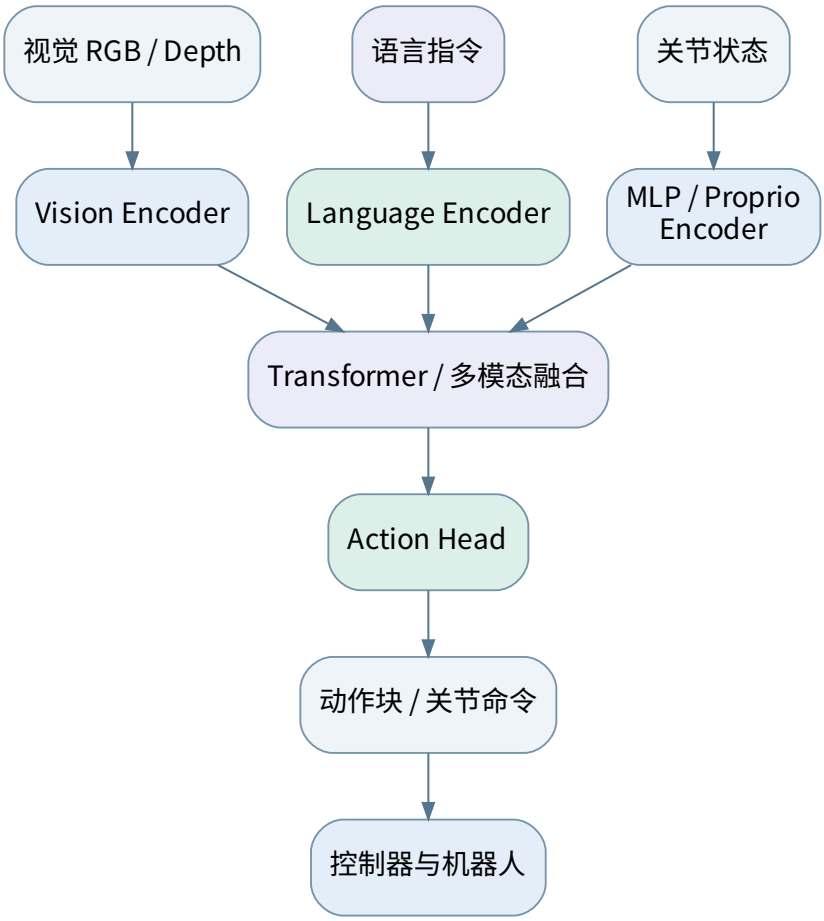


图 3. 典型多模态机器人策略的模块划分；具体模型可共享或省略部分编码器。

6.2 四类动作头对应不同的学习目标

动作头	训练目标	典型输出	优点与边界
确定性 MLP	MSE / L1	单步连续动作	简单、低延迟；多模态表示有限
概率动作头	NLL / CE	高斯参数或离散 Token	可表示不确定性；取决于分布族
ACT / Chunked Head	重建 + 潜变量 KL	H 步动作块	一次产生连续动作；依赖时间对齐
Diffusion / Flow Head	去噪或速度场回归	迭代生成动作块	表达复杂多模态；有采样时延

以常见的直线路径条件 Flow Matching 为例，令 $A_0 \sim \mathcal{N}(0, I)$、$A_1 \sim p_{\text{demo}}(\cdot \mid H)$，$\tau \sim U[0,1]$，并定义 $A_\tau = (1-\tau)A_0 + \tau A_1$。训练目标为

$$\mathcal{L}_{\text{FM}} = \mathbb{E}[\|v_\theta(A_\tau, \tau, H) - (A_1 - A_0)\|^2].$$

这里 v_θ 是**生成过程的速度场**，τ 是人工构造的生成时间，而非机械臂关节速度与物理时钟。完整的生成策略推导应在已有

Flow Matching 课程完成。

6.3 时间轴和动作语义不可由网络“自动学对”

机器人执行时间、相机采样时间、策略推理时间、动作块预测时间是四个不同概念。若模型输出的是末端相对位移 Δx，部署端就不能把它直接解释为绝对位姿 x。**模型结构只能在给定的数据契约内学习，无法纠正错误定义的控制语义。**

7. 预训练、微调与强化学习后训练的关系

7.1 一个训练系统可以经历不同的学习阶段

预训练（Pretraining）利用大规模数据形成通用表示或行为先验；监督微调（SFT/BC）用任务相关示教提高特定操作能力；强化学习后训练（RL Post-training）利用交互和奖励进一步改进成功率、精度、稳健性或恢复能力。它们并不是不同的网络架构，也不保证所有项目都必须依次经历全部阶段。

$$\underbrace{\theta_0 = \arg\min_\theta \mathcal{L}_{\text{pre}}}_{\text{预训练}} \longrightarrow \underbrace{\theta_1 = \arg\min_\theta \mathcal{L}_{\text{BC}}}_{\text{示教微调}} \longrightarrow \underbrace{\text{Improve } J(\pi_\theta)}_{\text{交互式 RL}}.$$

RL 中的 Actor 仍可由 MLP 或 Transformer 表示，Critic 也仍通过梯度学习；差别在于损失所依据的数据与回报估计。不能将“使用 AdamW”误认为就是“监督学习”，也不能将“冻结 Transformer”误认为模型不会从数据中学习，因为动作头或残差模块仍可更新。

7.2 全参数、部分参数、冻结主干、LoRA

将参数划分为基础模型 θ_b 与动作头 θ_h。全参数微调更新 $\nabla_{\theta_b,\theta_h}\mathcal{L}$；冻结主干则约束 $\Delta\theta_b = 0$，只更新 θ_h。LoRA 在选定权重 W 上使用低秩增量

$$W' = W + \Delta W, \qquad \Delta W = BA, \qquad \operatorname{rank}(BA) \le r.$$

其中一般固定原始 W，仅训练 A, B。LoRA 是**参数高效微调机制**，并非一种监督或强化学习目标。只有修改了可训练接口，并不意味着解决了动作采样时延、Reward Credit Assignment 或安全探索问题。

7.3 为什么后训练需要理解基础网络

对隐式生成策略，不能默认精确得到 $\log \pi_\theta(A \mid o)$。因此基于概率比的标准策略更新可能需要重参数化、替代更新目标、额外价值网络或冻结生成器的适配层。这是已有 RL Post-training 讲义讨论的重点；本课只解释为什么**网络架构、可训练参数和优化接口**必须分开理解。

8. 稳定训练与评估：机器人数据的特殊性

8.1 数据集划分与指标

为了评估泛化能力，应按**独立轨迹、场景、物体或采集轮次**划分训练与验证数据，而不是简单随机打散高度相邻的视频帧。应同时报告监督损失和任务指标：成功率、位置/姿态误差、接触失败类型、运行时延、碰撞及恢复次数。较低的离线 BC Loss 不等于较高的闭环成功率。

8.2 学习率、归一化与数值稳定性

输入 x 常按训练数据统计量归一化为 $\tilde{x} = (x - \mu_x)/(\sigma_x + \varepsilon)$；输出动作的反归一化必须与执行器物理单位一致。梯度裁剪可限制大梯度更新，混合精度可节省显存，但应监测 NaN/Inf 和损失缩放。图像预处理、关节索引、坐标轴方向、相机外参与动作控制频率都是模型接口的一部分。

8.3 过拟合、欠拟合与分布偏移

欠拟合可能来自网络容量、优化不足、标签噪声或观测不可辨识；过拟合可能表现为训练任务成功却无法适应新物体和新背景。正则化、数据增强、更多场景与适当的冻结策略有助于泛化，但并不保证解决接触动力学或遮挡造成的信息缺失。对位置噪声、视觉遮挡和随机摩擦的鲁棒性，应通过独立闭环评估来验证。

9. 实时推理与部署：模型计算不等于机器人控制

9.1 前向计算、动作块和控制周期

部署时通常只执行前向传播；不会在每个控制周期自动运行反向传播。设低层控制周期为 Δt_c，从传感器观测到得到新动作块的端到端时延为 T_{lat}，则可估计等待控制步数

$$d = \left\lceil \frac{T_{\text{lat}}}{\Delta t_c} \right\rceil .$$

如果策略预测 H 步，而每次执行 K 步再查询，必须保证新动作块衔接时的时延、旧块剩余覆盖时间与安全降级策略相容。H（预测长度）、K（每次使用的长度）与 d（推理占用周期）是不同概念。RTC/异步动作块策略属于模仿学习课程的深入内容。

9.2 KV Cache、FlashAttention 和 Flow 采样步数

KV Cache 可在**自回归生成**时复用历史 Token 的 Key/Value，减少重复计算；但对每次重新编码完整图像的双向 Encoder，不能直接照搬语言模型的 Cache 结论。FlashAttention 优化 Attention 计算的内存访问，不会直接解决机器人动作块切换或网络尾部时延。Flow/Diffusion Head 的推理速度还取决于迭代次数、每次网络评估成本及求解器。训练效率与闭环控制稳定性是不同指标。

9.3 安全边界属于系统设计

视觉–策略网络输出的动作，通常还需进行单位转换、关节限幅、速度/力矩约束、碰撞检查、低层伺服和异常恢复。在精密接触操作中，模型推理误差、相机遮挡和触觉缺失都会影响可观测性，不能仅用“更大的 Transformer”补救。

10. 架构选择、误区与学习路径

10.1 给定任务，如何选择网络

主要需求	常见起点	何时升级架构
低维本体闭环、短延迟	MLP Actor / Critic	需要长历史、多模态感知时
从简单专家示教学习	MLP BC / Chunked BC	动作显著多模态或要求长时一致性时
多相机 + 语言 + 状态	视觉 Encoder + Transformer 融合	更复杂时序、3D 几何或跨机器泛化时
多模态连续动作块	ACT / Diffusion / Flow Head	依据分布复杂度与推理预算选择
冻结基础模型后适应	可训练 Action Head / Adapter / LoRA	在可控资源下比较不同可训练接口

选择之前应明确：输入可得哪些传感器、标签动作的坐标系是什么、控制周期是多少、是否允许在线交互、训练与测试机器人是否一致。表中的方案是**合理起点，不是实证排名**。

10.2 六个必须避免的误解

1. **“反向传播就是梯度下降”**：前者求导，后者使用导数更新参数。
2. **“Transformer 等于具身基础模型”**：Transformer 是部件；完整模型还需要观测、动作与训练接口。
3. **“Flow Matching 一定比 MLP 慢”**：应比较具体网络、求解步数和部署硬件；二者并非同一分类维度。
4. **“训练 Loss 越低，机器人成功率越高”**：离线拟合不直接评估闭环接触与恢复。
5. **“Actor–Critic 必须使用两种固定网络”**：两者可以共享或分离表示，并使用不同的观测和目标。
6. **“VLA 输出动作就不需要控制器”**：动作预测与物理执行、安全监督始终是不同层次。

10.3 建议后续阅读顺序

本课学完后，可沿两条路线阅读仓库：**模仿学习方向**：BC/DAgger → ACT → Flow Matching → RL Post-training → GR00T/SONIC；**强化学习运控方向**：机器人动力学 → Isaac/MuJoCo → PPO/SAC → 运动控制 RL。学习 Robot Agent 时，再把任务规划、工具调用、策略和物理验证区分为不同层次。

11. 术语对照与参考资料

中文	English	在本讲义中的含义
监督学习	Supervised Learning	从带标签输入—输出对拟合映射
经验风险	Empirical Risk	在训练样本上的平均损失
反向传播	Backpropagation	以链式法则计算参数梯度
梯度下降	Gradient Descent	沿负梯度方向更新参数
多层感知机	MLP	仿射层与非线性激活的复合
自注意力	Self-Attention	同一序列内部的 Token 交互
交叉注意力	Cross-Attention	用 Query 读取另一上下文序列
动作头	Action Head	将隐藏表征转为机器人动作
冻结主干	Frozen Backbone	固定一部分预训练参数
后训练	Post-training	在预训练基础上进一步适应任务

基础论文与延伸阅读（按学习路线排序）：

1. Rumelhart, Hinton & Williams (1986), *Learning representations by back-propagating errors.* Nature.
2. Kingma & Ba (2015), *Adam: A Method for Stochastic Optimization.* arXiv:1412.6980.
3. Loshchilov & Hutter (2019), *Decoupled Weight Decay Regularization.* arXiv:1711.05101.
4. Vaswani et al. (2017), *Attention Is All You Need.* arXiv:1706.03762.
5. Dosovitskiy et al. (2021), *An Image Is Worth 16x16 Words.* arXiv:2010.11929.
6. Hu et al. (2022), *LoRA: Low-Rank Adaptation of Large Language Models.* arXiv:2106.09685.
7. Zhao et al. (2023), *Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware*（ACT）. arXiv:2304.13705.
8. Chi et al. (2023), *Diffusion Policy: Visuomotor Policy Learning via Action Diffusion.* arXiv:2303.04137.
9. Lipman et al. (2023), *Flow Matching for Generative Modeling.* arXiv:2210.02747.
10. Kim et al. (2024), *OpenVLA: An Open-Source Vision-Language-Action Model.* arXiv:2406.09246.

原创教学文字按 CC BY 4.0 许可共享。示意图用于概念教学，并不表示某一特定 VLA 的完整官方架构；所引论文与第三方项目遵循各自许可。

新增专题：从反向传播到 BPTT——理解 SuperMimic 所需的微分计算

> 本专题为 2026-10-28 增补内容。前述课程正文保持不变。先修：第 3 章链式法则、MLP、Actor–Critic；进阶参见新教程《基于世界模型的强化学习》。

1. 从单步网络到跨时间计算图

普通监督学习计算 $y = f_\omega(x)$ 并根据损失 $\ell(y, y^*)$ 更新参数。机器人控制则产生**闭环计算图**：

$$a_t = \pi_\theta(o_t, g_t), \qquad \hat{s}_{t+1} = f_\omega(\hat{s}_t, a_t, \xi), \qquad \hat{o}_{t+1} = h_\omega(\hat{s}_{t+1}, \xi).$$

策略参数 θ 改变当前动作，也通过未来状态改变之后的动作和奖励。**Backpropagation Through Time（BPTT）**就是在有限时间展开的计算图上应用链式法则；它并不要求网络本身必须是 RNN。

2. 展开全导数，而非只看局部梯度

令 $D_t = \mathrm{d}\hat{s}_t/\mathrm{d}\theta$；为清晰起见，暂设 $o_t = h(\hat{s}_t)$，任务目标 g_t 固定，世界模型参数 ω 在策略更新时冻结。

$$\frac{\mathrm{d}a_t}{\mathrm{d}\theta} = \frac{\partial \pi_\theta}{\partial \theta} + \frac{\partial \pi_\theta}{\partial o_t}\frac{\partial h}{\partial s_t} D_t,$$
$$D_{t+1} = \frac{\partial f_\omega}{\partial s_t} D_t + \frac{\partial f_\omega}{\partial a_t}\frac{\mathrm{d}a_t}{\mathrm{d}\theta}.$$

由此可见，奖励对 θ 的梯度包含整个短期未来的间接影响。若把中间 $\hat{s}_t$ 错误地 `detach`，就会切断这些依赖，只剩下不完整的局部梯度。

3. 冻结模型权重不等于切断模型梯度

SuperMimic 的一次策略更新中，**世界模型权重不更新**，但梯度仍必须穿过模型对状态、动作输入的映射：

- 合理：模型参数`requires_grad=False`，保持 $\partial f_\omega/\partial a_t$ 可用；
- 错误：对整个模型前向计算使用 `no_grad()`，导致路径梯度断开；
- 实际系统还需区分数值裁剪、动作限幅、状态归一化与梯度停止的位置。

4. 短视野和 Critic 为什么同时出现?

世界模型想象时域为 H，策略优化的目标可以写为：

$$\hat{J}_H(\theta) = \mathbb{E}\left[\sum_{t=0}^{H-1} \gamma^t \hat{c}_t \hat{r}_{t+1} + \gamma^H \hat{c}_H V_\psi(\hat{s}_H, g_H, \xi)\right].$$

$\hat{c}_t$ 表示预测存活权重，V_ψ 为末端价值估计。短视野缓解长时域梯度爆炸、消失和模型偏差；Critic 近似补足 H 之后的回报。对比 PPO：它用 $\nabla_\theta \log \pi_\theta$ 形式的估计器，不要求对物理环境求导。

5. 三个应当能够回答的检查题

1. 为什么世界模型输入需要可微，而外部 MuJoCo Warp 并不需要可微?
2. 为什么小的状态预测误差不能保证动作方向上的梯度准确?
3. 设 $H = 1$ 且不使用 Critic，策略会忽略哪些长期效应?

后续阅读：SuperMimic 论文；SHAC；《基于世界模型的强化学习》新增教程。

版权说明：本新增原创专题使用 *CC BY-NC-SA 4.0*；原有章节及第三方引用的许可不因本次增补而改变。