具身智能中的强化学习教程：算法分类、任务分类与应用场景

Reinforcement Learning for Embodied AI: Algorithms, Applications, and Research Directions

2026 年 10 月 15 日

目录

一、具身强化学习的总体分类 **2**
1.1 分类框架 . . . 2
1.2 核心分类表 . . . 2

二、按算法分类：PPO 与 SAC **2**
2.1 On-policy RL：PPO . . . 2
2.2 Off-policy RL：SAC . . . 3
2.3 PPO 与 SAC 的比较 . . . 4

三、按任务分类：机器人运动控制强化学习 **4**
3.1 Locomotion RL：机器人运动控制 . . . 4
3.2 Manipulation RL：机器人操作强化学习 . . . 6

四、按任务分类：具身基础模型强化学习后训练 **7**
4.1 什么是具身基础模型 RL Post-training? . . . 7
4.2 RL 后训练主要解决什么问题? . . . 7
4.3 具身基础模型 RL 后训练的五类方法 . . . 8
4.4 五类方法的总结 . . . 10

五、PPO、SAC 在两类任务中的具体用途 **10**

六、如何根据任务选择 RL 方法? **11**

七、两个研究方向的典型实验路线 **11**
7.1 机器人运控 RL . . . 11
7.2 具身基础模型 RL 后训练 . . . 12

八、最后总结 **13**

本教程重点介绍具身智能中强化学习的**分类、用途、典型方法、适用场景及研究方向**，不涉及强化学习的数学基础和算法推导。

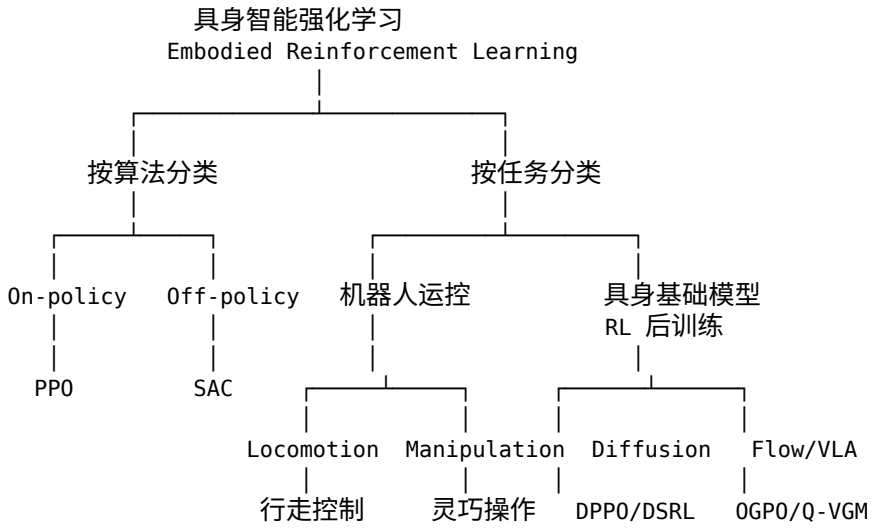
具身强化学习可以从两个主要维度进行分类：

- **按算法分类**：On-policy RL（以 PPO 为代表）和 Off-policy RL（以 SAC 为代表）。
- **按任务分类**：机器人运动控制强化学习（Robot Control RL）和具身基础模型强化学习后训练（Foundation Model RL Post-training）。

这两个维度相互独立，可以组合形成不同的研究路线。

一、具身强化学习的总体分类

1.1 分类框架



其中，机器人操作（Manipulation）既可以采用传统的低层控制策略，也可以采用 Diffusion Policy 或 VLA。

因此，**同一个操作任务可以属于传统机器人控制 RL，也可以属于具身基础模型 RL 后训练，关键取决于策略模型和训练目标。**

1.2 核心分类表

分类维度	类别	代表算法或方法	主要用途
算法	On-policy	PPO	大规模仿真训练、运动控制
算法	Off-policy	SAC	连续控制、数据高效学习、在线改进
任务	Locomotion RL	PPO、SAC	双足、四足、人形机器人运动
任务	Manipulation RL	PPO、SAC	抓取、手内操作、灵巧控制
任务	Foundation Model RL	DPPO、DSRL、OGPO 等	改进预训练 Diffusion / Flow / VLA 策略

需要注意：DPPO、DSRL 和 OGPO 是针对生成式策略设计的方法，不能全部直接归类为标准 PPO 或 SAC。

二、按算法分类：PPO 与 SAC

2.1 On-policy RL：PPO

PPO（Proximal Policy Optimization）是机器人运控中广泛使用的强化学习算法。

其主要特点是：

- 使用当前策略采集的交互数据进行训练；
- 每轮采样后对策略进行有限次数的更新；
- 训练通常比较稳定；
- 容易结合 GPU 大规模并行仿真；
- 不适合长期重复使用大量旧数据。

PPO 主要用于哪些任务?

应用	具体任务
四足机器人	行走、奔跑、跳跃、复杂地形穿越
人形机器人	双足行走、平衡、抗扰恢复
Whole-Body Control	全身协调控制、动作跟踪
灵巧操作	灵巧手旋转物体、抓取、接触操作
Sim-to-Real	仿真训练控制策略并部署到真机
生成式策略后训练	DPPO 等针对 Diffusion Policy 的策略梯度方法

为什么运控领域喜欢 PPO?

因为运控任务通常可以在 Isaac Lab 等仿真器中同时运行数千个机器人。

例如：



在这样的设置下，环境交互数据容易大量获得，因此 PPO 的 On-policy 数据使用方式通常是可以接受的。

典型技术组合：

```
Isaac Lab + RSL-RL + PPO
```

Isaac Lab 官方文档也将 RSL-RL 作为新机器人 RL 项目的一种推荐起点。(Isaac Lab 文档)

2.2 Off-policy RL：SAC

SAC（Soft Actor-Critic）是机器人连续控制中具有代表性的 Off-policy 算法。

主要特点：

- 可以重复使用历史交互数据；
- 使用 Replay Buffer 存储经验；
- 通常具有较高的环境交互样本效率；
- 适合在线策略改进；
- 可以利用 Critic 指导动作选择；
- 对 Critic 的学习质量比较敏感。

SAC 主要用于哪些任务?

应用	具体任务
机械臂控制	抓取、放置、推物体
灵巧操作	手内旋转、物体重定位、精密操作
真实机器人 RL	利用有限真实交互数据改进策略
Residual RL	在已有控制器上学习动作修正
Latent RL	学习预训练生成策略的潜变量
具身模型后训练	基于 Critic 的 Off-policy 策略优化

为什么 SAC 适合真实机器人学习?

因为真实机器人交互比较昂贵。

例如，一次灵巧手抓取可能涉及：

- 机械臂移动；
- 手指接触；
- 抓取执行；
- 任务成功或失败判断；
- 机器人复位。

如果每次策略更新都需要重新采集大量数据，训练成本会非常高。

SAC 可以通过 Replay Buffer 反复利用已有经验，因此常用于研究数据高效的机器人在线学习。

但需要强调：SAC 的样本效率优势并不意味着它在所有机器人任务上都比 PPO 更好。特别是在拥有大规模并行仿真资源时，PPO 可能获得更高的训练吞吐量。

2.3 PPO 与 SAC 的比较

维度	PPO	SAC
类型	On-policy	Off-policy
训练数据	主要来自当前策略	当前和历史策略数据
历史数据复用	有限	较充分
Replay Buffer	通常不需要长期 Replay Buffer	需要
样本效率	通常较低	通常较高
并行仿真	非常成熟	同样可以使用
训练稳定性	通常容易控制	依赖 Critic 质量
真实交互成本高的场景	通常不占优势	往往更有优势
典型任务	Locomotion	Manipulation、Online RL
代表框架	RSL-RL	Stable-Baselines3、其他 SAC 实现

如何选择?

选择 PPO：

机器人仿真速度快、可以运行大量并行环境、希望从零训练一个稳定的运动控制策略。

选择 SAC：

真实机器人数据昂贵、需要重复利用历史经验、希望持续在线提升策略性能。

不过，实际选择还取决于策略结构。如果策略是大型 Diffusion 或 Flow Matching 模型，就不能不加修改地直接使用标准 PPO/SAC。

三、按任务分类：机器人运动控制强化学习

机器人运动控制强化学习主要目标是：

让机器人通过与环境交互，学会稳定、高效地执行具体的物理动作。

通常直接训练一个相对轻量的控制策略，并将其部署到机器人控制系统中。

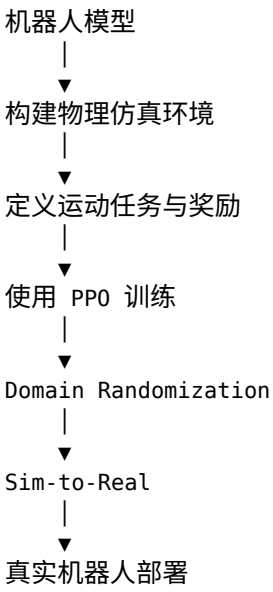
3.1 Locomotion RL：机器人运动控制

Locomotion RL 主要针对机器人移动与全身运动能力。

典型应用

方向	任务	主要用途
Quadruped Locomotion	四足行走、奔跑、跳跃	机器狗运动控制
Humanoid Locomotion	双足行走、上下楼梯	人形机器人运动
Motion Tracking	跟踪人类或参考运动	人形机器人动作模仿
Whole-Body Control	全身协调运动	移动操作、复杂全身动作
Push Recovery	外部推力扰动恢复	提高机器人稳定性
Terrain Adaptation	斜坡、碎石、楼梯	复杂地形适应

典型训练方式



这一方向主要研究什么?

1. 运动能力

让机器人完成越来越复杂的运动任务，例如:

- 从平地行走扩展到楼梯;
- 从慢速行走扩展到奔跑;
- 从简单步态扩展到全身动作跟踪。

2. 鲁棒性

提高机器人应对不同环境的能力，例如:

- 外部推力;
- 摩擦变化;
- 未知负载;
- 执行器误差。

3. Sim-to-Real

减少仿真与真实机器人的差异。

主要技术包括:

- Domain Randomization;
- System Identification;
- Teacher-Student Learning;
- Privileged Learning;
- Online Adaptation。

典型技术栈

模块	常见选择
仿真	Isaac Lab、MuJoCo
RL	PPO
实现	RSL-RL
控制策略	MLP、RNN
低层控制	PD / Torque Control
训练方式	大规模并行仿真
部署	机器人实时控制系统

这一方向的特点：

通常可以在仿真中从零训练，主要瓶颈是物理仿真、奖励设计、任务复杂度以及真实部署的鲁棒性。

3.2 Manipulation RL：机器人操作强化学习

Manipulation RL 主要针对机械臂和灵巧手操作。

虽然它与 Locomotion RL 都属于机器人控制层面的强化学习，但操作任务经常涉及更复杂的接触动力学。

典型应用

方向	任务	主要用途
Reaching	机械臂到达目标位置	基础末端控制
Grasping	抓取不同物体	机器人抓取
In-hand Manipulation	手内旋转与重定位	灵巧手精细操作
Object Reorientation	调整物体姿态	灵巧操作
Tool Manipulation	使用螺丝刀等工具	工具操作
Contact-Rich Manipulation	插孔、旋转、装配	精密接触操作
Bimanual Manipulation	双臂协同	双手操作与装配

与 Locomotion RL 的区别

Locomotion 更多关注：

- 身体平衡；
- 速度跟踪；
- 地面接触；
- 周期性运动。

Manipulation 更多关注：

- 多点接触；
- 物体位姿；
- 抓取稳定性；
- 接触切换；
- 手指协调；
- 精密操作。

使用 PPO 还是 SAC?

PPO:

适合在仿真中并行训练大量灵巧操作任务。

例如，给定不同物体初始姿态，训练灵巧手完成物体旋转。

SAC:

适合研究真实机器人在线学习，以及需要较高环境交互样本效率的操作任务。

例如，在已有初始操作策略的基础上，通过少量真实交互逐步提高抓取成功率。

重要区别

这里训练的可能仍然是传统低层控制策略:

```
Observation
    ↓
MLP Actor
    ↓
Joint Position / Torque
    ↓
Robot
```

它与下一部分的 VLA 强化学习后训练不是同一个问题设定。

四、按任务分类：具身基础模型强化学习后训练

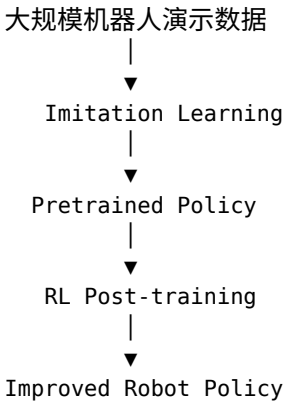
4.1 什么是具身基础模型 RL Post-training?

具身基础模型通常先利用大量演示数据进行预训练，再利用强化学习提高任务表现。

例如:

- Diffusion Policy;
- Flow Matching Policy;
- π0 / π0.5 等 VLA;
- 其他视觉语言动作生成模型。

训练过程通常是:



它与从零训练 Locomotion Policy 的主要区别是:

后训练阶段已经有一个具备一定任务能力的预训练策略。

强化学习的目标不再是从零学习基本动作，而是在已有能力基础上进一步提升性能。

4.2 RL 后训练主要解决什么问题?

问题	RL 后训练的作用
成功率不足	提高抓取、放置、插孔等任务成功率
动作速度慢	缩短任务完成时间

问题	RL 后训练的作用
精度不足	提升末端定位和精密操作能力
遇到新环境失败	在线适应环境变化
模仿学习性能受限	利用自主经验超越演示策略
失败后无法恢复	学习错误恢复和重新尝试
真实任务缺少演示	通过自主探索进一步改进策略

例如：

一个预训练 VLA 已经能够完成螺丝刀抓取，但成功率只有 70%。

我们希望通过强化学习，提高成功率、减少不必要的动作，并提高对初始姿态变化的鲁棒性。

4.3 具身基础模型 RL 后训练的五类方法

按照**强化学习究竟更新模型的哪个部分**，可以分为五类。

第一类：Full Policy Fine-tuning

直接更新预训练生成策略。

代表方法：

- DPPO；
- OGPO。

其中 DPPO 通过策略梯度微调 Diffusion Policy；OGPO 则利用 Off-policy Critic 和适配生成过程的策略优化目标，实现对生成式控制策略的完整微调。(DPPO)

主要用途：

当预训练策略的能力明显不足，希望真正改变其动作生成能力时，采用完整策略微调。

优点是修改范围大，能力提升空间也可能更大。

局限是训练成本较高，并且需要防止破坏原有的预训练能力。

第二类：Latent / Noise-Space RL

冻结预训练模型，只优化其输入潜变量或噪声分布。

代表方法：

- DSRL；
- LP-DS。

DSRL 通过学习 Diffusion Policy 的初始噪声分布实现策略改进，而不需要修改基础策略参数。(DSRL)

主要用途：

当预训练模型已经具备较好的动作生成能力，只需要选择更优的动作模式时。

优点是：

- 不需要微调整个大模型；
- 在线训练相对轻量；
- 可以复用预训练策略。

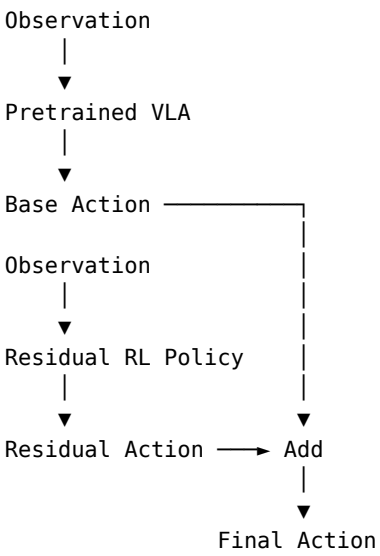
局限是：

无法轻易突破冻结生成器本身的表达能力限制。

第三类：Action Residual RL

在预训练策略输出的动作上增加 RL 修正。

例如：



主要用途：

预训练策略基本正确，但末端误差、姿态误差或接触控制仍然不够精确。

例如：

- 提高插孔精度；
- 修正抓取姿态；
- 对工具操作增加局部控制；
- 改善接触阶段的动作。

这类方法通常不需要重新训练基础 VLA。

第四类：Feature / Token-Level RL

利用预训练 VLA 的内部特征，训练轻量 RL 模块。

代表方法：

- RL Token。

RL Token 通过预训练 VLA 提供紧凑的任务相关表示，并训练轻量 Actor-Critic 模块实现在线策略改进。(RL Token)

主要用途：

大型 VLA 的在线强化学习。

例如：

- 精密装配；
- 插孔；
- 工具操作；
- 在线提升操作速度。

这类方法适合希望保留基础模型表征、降低在线训练开销的场景。

第五类：Velocity Field Fine-tuning

直接优化 Flow Matching Action Expert 的 Velocity Field。

代表研究：

- Q-VGM；
- Reward / Advantage-Guided Velocity Matching 相关方法。

Q-VGM 使用 Critic 提供的价值梯度信号，通过局部 Velocity Matching 改进预训练 Flow Matching Policy。(Q-VGM)

主要用途：

希望真正改进 Flow Matching 动作生成模型，但又不希望每次策略更新都对完整生成轨迹进行昂贵反向传播。
这是一条与大型 Flow Matching VLA 后训练高度相关的研究路线。

4.4 五类方法的总结

方法	代表	更新内容	主要用途
Full Fine-tuning	DPPO、OGPO	整个生成策略或主要 Action Expert	提升模型的动作生成能力
Latent RL	DSRL、LP-DS	输入噪声或潜变量策略	轻量级在线改进
Action Residual RL	Residual SAC 等	输出动作残差	精密控制、局部动作修正
Feature / Token RL	RL Token	轻量 Actor-Critic 模块	大型 VLA 的高效在线学习
Velocity Field RL	Q-VGM 等	Flow Matching Velocity Field	直接改进 Flow Matching Action Expert

其中，前四类的主要区别是优化参数的位置，而第五类进一步利用了 Flow Matching 的生成结构。
这些类别并非完全互斥。例如，可以只训练 Velocity Field 的残差模块，它同时属于 Residual Adaptation 和 Velocity Field Fine-tuning。

五、PPO、SAC 在两类任务中的具体用途

将两个分类维度组合，可以得到下面这张核心表。

	机器人运动控制	具身基础模型 RL 后训练
On-policy PPO	大规模仿真训练运控策略	DPPO 等生成策略微调
Off-policy SAC	灵巧操作、真实机器人在线学习	DSRL 等基于 SAC 或 Off-policy Critic 的适配方法

5.1 PPO + Locomotion

典型任务：

人形机器人学会上楼梯。

常用方式：

Isaac Lab + RSL-RL + PPO。

主要优势：

充分利用大规模仿真环境。

5.2 SAC + Manipulation

典型任务：

机器人通过在线交互学习抓取和物体操作。

主要优势：

复用 Replay Buffer 中的经验，减少获得新训练数据的需求。

5.3 PPO 类方法 + VLA

典型任务：

使用 DPPO 对 Diffusion Policy 进行强化学习后训练。

主要优势：

直接通过策略梯度改进生成策略。

5.4 SAC / Off-policy Critic 类方法 + VLA

典型任务：

使用 DSRL 优化预训练生成策略的潜变量，或者使用 OGPO、Q-VGM 等方法改进生成策略。

主要优势：

利用历史交互经验提高数据效率。

这里尤其需要区分：

OGPO 和 Q-VGM 都属于 Off-policy 生成策略优化路线，但并不等价于标准 SAC。

六、如何根据任务选择 RL 方法？

下面给出实际项目中比较有用的选型参考。

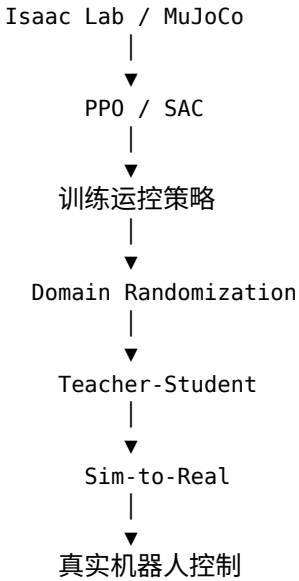
项目目标	优先考虑	原因
从零训练四足机器人行走	PPO	并行仿真成熟
训练 G1 等人形机器人运控	PPO	成熟的运动控制 RL 工作流
训练灵巧手在仿真中旋转物体	PPO	可利用并行仿真
真机灵巧手在线改进操作能力	SAC 或基于演示初始化的 Off-policy RL	可以复用历史数据
微调已有 Diffusion Policy	DPPO、OGPO	直接改进生成策略
不修改已有 Diffusion/Flow 模型	DSRL	冻结生成模型，优化噪声策略
提升 VLA 的精密操作能力	Residual RL、RL Token	训练轻量模块
直接微调 Flow Matching 的 Velocity Field	Q-VGM 等	利用价值信号更新生成模型
希望避免完整生成链的反向传播	Latent RL、Token RL、局部 Velocity Matching	降低在线优化成本

实际选型还要考虑模型大小、仿真是否可用、奖励是否稀疏，以及真实交互和计算资源的预算。

七、两个研究方向的典型实验路线

7.1 机器人运控 RL

推荐路线：



这条路线主要关注：

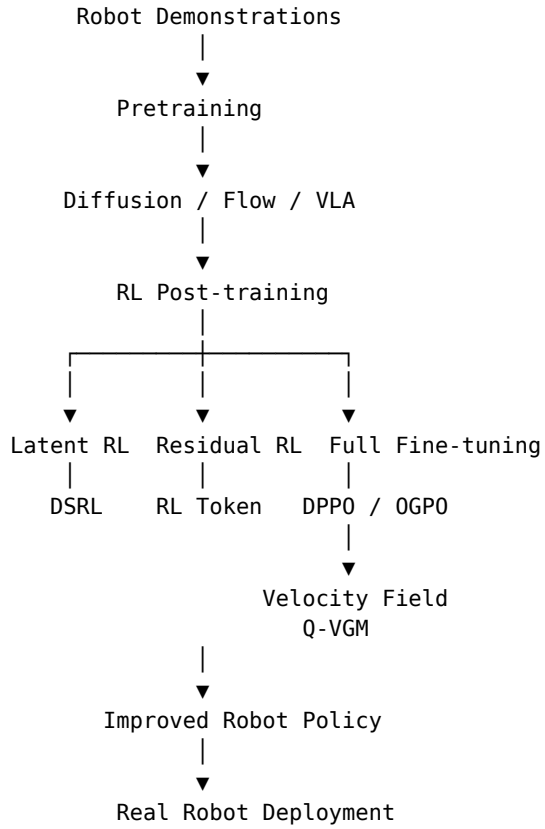
如何让机器人运动得更稳定、更灵活，并具备更强的物理环境适应能力。

推荐入门：

Isaac Lab + RSL-RL

7.2 具身基础模型 RL 后训练

推荐路线：



这条路线主要关注：

如何利用强化学习，以较少的机器人交互数据提升预训练基础模型的任务能力。

推荐入门：

DSRL → DPPO → OGPO → Q-VGM

八、最后总结

对于具身智能中的强化学习，建议采用以下三层分类来理解整个领域。

分类层次	主要类别	核心问题
第一层：算法	PPO、SAC	如何利用环境反馈改进策略?
第二层：任务	Locomotion、Manipulation、Foundation Model Post-training	强化学习要解决什么机器人任务?
第三层：优化对象	低层控制策略、Residual、Latent、Action Expert、Velocity Field	强化学习究竟更新策略的哪个部分?

其中：

机器人运控强化学习以 PPO、大规模物理仿真、运动控制和 Sim-to-Real 为主要技术路线。

具身基础模型强化学习后训练以 Diffusion/Flow/VLA 为基础，重点研究如何利用 RL 改进预训练模型，包括 Latent RL、Residual RL、Token-Level RL 和 Full Policy Fine-tuning。

二者最核心的差异在于：

- **运控 RL：**主要解决机器人如何获得稳定的运动与操作控制能力。
- **基础模型 RL 后训练：**主要解决如何让已经学会操作的模型表现得更好，并进一步提高成功率、速度、精度和鲁棒性。

因此，具身强化学习并不只是 PPO 和 SAC 的选择问题，还包括**任务类型、策略架构、训练数据来源和策略更新范围**的选择。