基于世界模型的强化学习：从模型学习到可微策略优化

Dyna、PETS、Dreamer、SHAC 与 SuperMimic | Foundation of Embodied AI

2026-10-28

目录

1. 为什么需要 Model-Based RL? . . . 2
2. 世界模型：状态、数据和训练目标 . . . 2
3. 世界模型的三种主要用途 . . . 3
4. 从 Pathwise Gradient 到 BPTT：数学推导 . . . 3
5. Short-Horizon Actor–Critic：为什么不仅用 BPTT? . . . 4
6. SuperMimic：共享学习动力学与运动跟踪 . . . 5
7. 面向灵巧操作：接触梯度为什么是研究问题? . . . 5
8. 可复现训练与评估计划 . . . 6
9. 学习路径、自测题与参考资料 . . . 6

课程首页 ·English ·SuperMimic ·SHAC

项目	说明
主题	基于模型的强化学习
修订日期	2026-10-28
许可	CC BY-NC-SA 4.0 ·Xiong Zeng and contributors

1. 为什么需要 Model-Based RL?

> **定位：**本课程原有 PPO、SAC、机器人动力学、MuJoCo 与 Motion Tracking 之间的新增桥梁。以公式和系统接口为中心，不包含未经验证的代码或假想实验结果。

在马尔可夫决策过程中，真实或仿真系统按未知转移核 $P(s_{t+1} \mid s_t, a_t)$ 演化，目标是最大化

$$J(\pi) = \mathbb{E}_{P,\pi}\left[\sum_{t=0}^{T-1} \gamma^t r(s_t, a_t)\right].$$

Model-Free RL（PPO、SAC）通常只需观测到的奖励和状态转移来更新策略或价值函数，不要求显式预测下一状态。**Model-Based RL（MBRL）**则学习或使用模型 $\hat{P}$（或确定性 f_ω），使未来变化可以被想象、评估或优化。

三件事必须区分：**环境模型是否存在、模型是否可微、是否对模型进行策略反向传播**。MPC 可以使用不可微模型通过采样优化；Dyna 可以使用模型数据训练 SAC；SuperMimic 需要可微的学习代理模型来计算 Pathwise Gradient。高保真模拟器本身不一定可微。

1.1 机器人问题里的数据瓶颈

真实机器人每个动作都需物理时间，接触冲击和失败重置可能很昂贵。并行仿真可以提高样本吞吐，但高度多样化的全身动作跟踪或灵巧接触仍需大量模拟。一个共享的学习动力学模型可以将多种任务中共用的**机械与接触规律**压缩进参数 ω，让策略更新不必每次都重新向物理仿真器询问完整未来。

这并不意味着学习模型自动比模拟器准确。模型偏差与优化利用（Model Exploitation）必须作为系统设计中的一等风险。

2. 世界模型：状态、数据和训练目标

2.1 状态、动作、观测和环境上下文

以机器人控制为例，先定义

$$s_t = (q_t, \dot{q}_t, x_t^{obj}, v_t^{obj}), \quad a_t = \text{applied joint command}, \quad o_t = h(s_t) + \eta_t.$$

x_t^{obj} 代表可能存在的物体位姿，ξ 是摩擦系数、质量、执行器增益等每个环境的参数。观测 o_t 与仿真特权状态 s_t **不是同一个变量**。世界模型可以用特权仿真状态拟合，部署后的 Actor 仍必须遵守真实可观测信息约束。

数据集

$$\mathcal{B} = \{(s_t, a_t, r_{t+1}, s_{t+1}, d_{t+1}, g_t, \xi)\}$$

应记录**实际执行的动作**（添加探索噪声、位置限幅之后），并明确 d 是失败终止、成功终止还是时间截断。跨 Episode Reset 拼接的序列不应作为连续动力学窗口。

2.2 从单步 MSE 到自回归多步损失

学习动力学使用

$$\hat{s}_{t+1} = f_\omega(\hat{s}_t, a_t, \xi), \qquad \hat{s}_t = s_t$$

并最小化单步预测误差。训练多步时，依次使用上一时刻**预测状态**作为下一步模型输入：

$$\hat{s}_{t+j+1} = f_\omega(\hat{s}_{t+j}, a_{t+j}, \xi), \qquad \mathcal{L}_{dyn} = \mathbb{E}_{\mathcal{B}} \sum_{j=1}^{K} \|\hat{s}_{t+j} - s_{t+j}\|_{W_s}^2.$$

多步目标比单步教师强制输入更能暴露模型的误差累积。对于姿态，欧氏四元数距离会受到 q 与 $-q$ 等价性的影响，常须使用测地距离或一致的旋转参数化。

若额外学习奖励、无噪观测及终止概率，可以构造

$$\mathcal{L}_{WM} = \mathcal{L}_{dyn} + \lambda_r \mathcal{L}_{reward} + \lambda_o \mathcal{L}_{observation} + \lambda_d \mathcal{L}_{termination},$$

其中终止的预测适合二元交叉熵；某些物理上明确可算的目标可用解析函数，而不一定学习对应网络。

2.3 不确定性与模型分布外使用

世界模型在 Replay Buffer 中出现频繁的状态上可很准确，在策略优化推动到的未见状态上却可能错误。因此应同时关注独立测试集多步预测、数据覆盖、Ensemble 分歧及真实仿真验证。PETS 倾向于用概率集成和轨迹采样表达预测不确定性；单个确定性模型更轻量，但应通过模型刷新和保守更新控制漂移。

3. 世界模型的三种主要用途

路线	代表	模型提供什么?	改进动作的机制
Dyna / 经验增强	Dyna、MBPO 风格	合成状态转移用于更新 Q/Actor	SAC / TD 等模型无关更新
Online Planning	PETS、MPC、CEM/MPPI	对候选动作序列预测未来	每个控制时刻搜索或采样动作
Differentiable Policy Learning	SHAC、SuperMimic	对动作及状态可微的预测图	BPTT 优化策略参数
Latent Imagination	Dreamer、部分 TD-MPC 方案	紧凑潜状态和未来预测	潜空间价值学习、策略优化或规划

这些分类会交叉。**是否使用 CEM** 与**是否学习 World Model** 是独立选择。CEM 和 MPPI 主要用于搜索动作序列；通过 BPTT 训练一个可执行的前馈策略是另一类计算安排。

3.1 CEM 与 MPPI 的典型优化变量

对于 H 步动作块 $A = (a_0, \dots, a_{H-1})$，规划目标为

$$A^* = \arg\max_A \mathbb{E}_{\hat{P}} \left[\sum_{t=0}^{H-1} \gamma^t r(\hat{s}_t, a_t) \right].$$

CEM 更新候选动作分布的均值与方差；MPPI 按轨迹回报对采样动作扰动加权。二者都可以把模型当成黑盒，不必计算 $\partial \hat{s}_{t+1}/\partial a_t$。在线规划持续调用模型；已训练的策略一般部署更快，但需要通过训练将控制模式 “编译” 进参数 θ。

4. 从 Pathwise Gradient 到 BPTT：数学推导

4.1 单步求导

设动作由可微确定性策略给出，且模型参数暂时固定：

$$a_t = \pi_\theta(h(\hat{s}_t), g_t), \qquad \hat{s}_{t+1} = f_\omega(\hat{s}_t, a_t, \xi).$$

令 $D_t = \mathrm{d}\hat{s}_t/\mathrm{d}\theta$，则

$$\frac{\mathrm{d}a_t}{\mathrm{d}\theta} = \frac{\partial \pi_\theta}{\partial \theta} + \frac{\partial \pi_\theta}{\partial o_t}\frac{\partial h}{\partial s_t} D_t,$$
$$D_{t+1} = \frac{\partial f_\omega}{\partial s_t} D_t + \frac{\partial f_\omega}{\partial a_t}\frac{\mathrm{d}a_t}{\mathrm{d}\theta}.$$

这给出动力学模型对策略参数的**全导数递推**。若起始状态来自 Replay Buffer 且与 θ 无关，则 $D_0 = 0$，但从 $t = 1$ 开始，后续状态仍受到先前动作的影响。

4.2 多步回报与梯度

对于光滑奖励 $\hat{r}(\hat{s}_t, a_t)$，忽略终止的简化目标为

$$\hat{J}_H(\theta) = \sum_{t=0}^{H-1} \gamma^t \hat{r}(\hat{s}_t, a_t) + \gamma^H V_\psi(\hat{s}_H).$$

其梯度为

$$\frac{\mathrm{d}\hat{J}_H}{\mathrm{d}\theta} = \sum_{t=0}^{H-1} \gamma^t \left(\frac{\partial \hat{r}_t}{\partial s_t} D_t + \frac{\partial \hat{r}_t}{\partial a_t} \frac{\mathrm{d}a_t}{\mathrm{d}\theta} \right) + \gamma^H \frac{\partial V_\psi}{\partial s_H} D_H.$$

计算图可直接用自动微分实现这组链式法则。与 PPO 的似然比估计器不同，这个梯度依赖可微模型 Jacobian：**它是近似目标 $\hat{J}_H$ 的梯度，并不等于真实环境 J 的无偏梯度**。

4.3 冻结世界模型但保留梯度通路

算法交替优化两套参数：世界模型 ω 和策略 θ。优化 θ 时不更新 ω，但不可阻断 $\partial f_\omega / \partial a$。把整段模型想象放在 `no_grad` 中会切断 BPTT。

4.4 终止概率和软存活权重

令 $\hat{d}_{t+1} \in [0, 1]$ 为模型预测的 Episode 终止概率，$\hat{c}_0 = 1$ 且

$$\hat{c}_{t+1} = \hat{c}_t (1 - \hat{d}_{t+1}).$$

通过可微存活权重，可定义（与 SuperMimic 形式一致的）想象目标

$$\boxed{\hat{J}_H(\theta) = \mathbb{E}\left[\sum_{t=0}^{H-1} \gamma^t \hat{c}_t \hat{r}_{t+1} + \gamma^H \hat{c}_H V_\psi(\hat{s}_H, g_H, \xi) \right].}$$

该表达式对终止建模方式、Reward 定义和 Episode 语义敏感，不应不加修改地搬到任意任务。

5. Short-Horizon Actor–Critic：为什么不仅用 BPTT?

长时域计算图的 Jacobian 连乘可能导致梯度爆炸或消失；模型状态误差随着步数累积，接触切换使局部梯度不稳定。短视野用 H 限定路径长度，而价值函数估计余下回报：

$$G_t^{(H)} = \sum_{j=0}^{H-1} \gamma^j r_{t+j+1} + \gamma^H V_\psi(s_{t+H}).$$

对真实终止后的状态应屏蔽尾项；对时间截断则可能需要保留 bootstrap，这取决于训练定义。Critic 可利用 TD(λ)、GAE 风格的目标学习，但不要将**模型里的回报估计**与**真实仿真评估回报**混淆。

SHAC（Short-Horizon Actor-Critic）通过**可微仿真器**对短轨迹求梯度；SuperMimic 通过**从普通仿真数据训练的可微代理模型**求梯度。两者共享短视野 +Critic 原理，却对物理求导提出不同要求。

5.1 三种常见失效模式

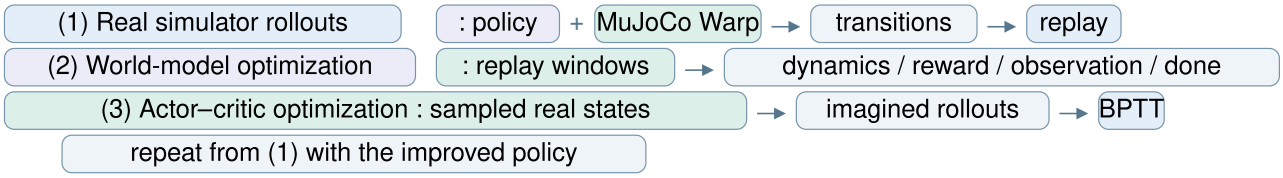
- **Model Bias**：模型低估滑移或碰撞代价，Actor 学到 “钻空子” 的动作；
- **Gradient Bias**：状态 MSE 低但 $\partial f_\omega / \partial a$ 的方向不可靠；
- **Distribution Shift**：Actor 更新后访问的状态超出 Buffer 支持，产生虚假高回报。

实用缓解包括周期性重采样、动作正则化、限制想象时域、模型集成不确定性阈值、早停和接触分层验证。

6. SuperMimic：共享学习动力学与运动跟踪

原论文 SuperMimic (2026) 针对人形机器人全身动作跟踪。与在大量 Motion Clips 上重复 Model-Free PPO 的做法不同，它用**一个共享动力学世界模型**学习通用的机器人响应，在该代理模型上高效训练跟踪策略。

6.1 三阶段循环



论文中的常用配置包括 **8 步自回归世界模型训练窗口**、**32 步想象轨迹**和利用 Critic 对想象轨迹尾部的回报进行 bootstrapping。可在一个训练循环中多次交替更新，但世界模型参数应在 Actor-BPTT 阶段保持冻结。

6.2 数据合同与模型输出

- 输入：真实仿真状态 s_t、实际动作 a_t、域随机化上下文 ξ；
- 输出：预测下一状态 $\hat{s}_{t+1}$，以及任务相关的奖励、干净观测和终止预测（部分头可使用解析实现）；
- Goal：参考动作、相位或未来指令 g_t 在 Actor/Critic 中保持时间对齐；
- 训练/部署区分：训练中使用真实仿真状态作为世界模型监督，部署 Actor 不应依赖只有模拟器才可获得的特权变量。

6.3 与 SONIC 的比较边界

论文报告：单张 H100 训练约 3 小时后，其回报超过使用 128 张 L40、训练约 7 天的 SONIC 已发布 checkpoint；更长训练在论文的运动集合上进一步降低失败数。**这不是相同硬件、相同训练数据和相同优化配置下的因果消融**。应分开报告 GPU-hours、墙钟时间、训练交互数与完整评估协议，不能把全部硬件效率差异归因于一种梯度估计器。

6.4 原论文的适用边界

原始 SuperMimic 论文展示**人形全身动作跟踪**及真机 Unitree G1 运动，**并未直接验证灵巧手掌内旋转的真机部署**。将该思路用于灵巧手，需单独研究物体动力学、接触事件与视觉/触觉状态估计。

7. 面向灵巧操作：接触梯度为什么是研究问题?

标准刚体接触包含非穿透与摩擦约束，局部模式可能在 separation、impact、stick、slip 之间切换。若物理映射在切换处不光滑，使用可微代理模型训练策略是一种有效的工程折中，但**代理梯度近似的是训练数据中的连续响应，并不自动匹配真实模式切换**。

在导数存在的局部，除了验证 $\|f_\omega - F_{sim}\|$，还要评估动作方向导数是否能够预测真实仿真器回报变化；在碰撞附近可使用有限扰动方向性测试，而非强行要求不存在的经典梯度。

灵巧手世界模型推荐输入：关节位置/速度、物体位姿/速度、目标方向、动作历史，以及可用的摩擦/执行器上下文；视觉部署时需要区分训练特权状态与估计可用状态。

8. 可复现训练与评估计划

阶段	应测量	不通过时的处理
A. 仿真器正确性	质量惯量、关节 PD、控制频率、接触行为	修正 URDF/MJCF/USD 资产与执行器参数
B. Model-Free 基线	PPO 成功率、仿真交互量、GPU-hours	保持基线可复现，固定种子
C. 世界模型	1/8/32 步误差、接触事件误差	采用多步训练、重新平衡接触数据
D. BPTT+Critic	实际仿真回报增量、梯度范数、H 敏感度	降低想象时域或模型优化步数
E. 泛化	未见命令、环境参数与初始状态	加强数据覆盖与域随机化
F. Sim-to-Real	物体跟踪延迟、掉落、硬件保护	回到辨识/标定，不把成功率当作无条件保证

8.1 必要消融

1. PPO（不学世界模型）vs 使用同一物理仿真样本预算的 Model-Based RL；
2. `BPTT + Critic` vs `BPTT without Critic`；
3. 想象时域 $H \in \{8, 16, 32, 64\}$，长视野是否真的更好由实验判断；
4. 单步训练 vs 8 步自回归训练；
5. 仅更新 Actor/模型 vs 循环收集新真实仿真数据；
6. 终止建模、Contact-Biased Buffer Sampling、Model Ensemble 是否提升稳健性。

8.2 报告规范

请分别报告实际仿真 transitions 与 imagined transitions；模型训练、策略优化与仿真采样的各自用时；GPU 种类和数量；独立随机种子及置信区间。对于接触密集任务，单一平均 Reward 不足以替代掉落率、目标姿态误差和任务成功率。

9. 学习路径、自测题与参考资料

建议顺序：原课程 #6 Dynamics → #7 Simulation → #9 PPO / #10 SAC → 本教程第 1–5 章 → SuperMimic 第 6 章 → 新增灵巧手专题。想进一步研究在线规划，可转向 PETS/CEM/MPPI；研究视觉模型则结合原课程 WAM。

自测：

1. 写出 2 步世界模型的 $\mathrm{d}\hat{s}_2/\mathrm{d}\theta$，说明为什么不能只用当前动作的局部导数。
2. PPO、SHAC 和 SuperMimic 分别依赖哪一个梯度计算图?
3. 为什么一个模型能够 1-step 预测准确，却使策略优化方向变差?
4. 为什么 $H = 32$ 并不意味着模型每个样本必须训练连续 32 步?
5. 对于掌内方块旋转，设计三个可直接检验的接触失败指标。

主要参考:

- SuperMimic: Scaling Humanoid Whole-Body Control with One Differentiable World Model (2026)
- Accelerated Policy Learning with Parallel Differentiable Simulation / SHAC (2022)
- PETS: Deep Reinforcement Learning in a Handful of Trials using Probabilistic Dynamics Models (2018)
- Dreamer: Dream to Control (2019)
- TD-MPC: Temporal Difference Learning for Model Predictive Control (2022)
- Dex-Supermimic: independent dexterous-hand adaptation（仅作为社区实现）

版权与边界：本课程是对既有文献的独立教学整理，不是 SuperMimic 官方教程；比较和推荐属于教学分析，未暗示执行了新的基准实验。本文原创文字采用 CC BY-NC-SA 4.0；论文、代码及既有课程内容分别遵守各自许可。