# PPO 完整推导与设计动机

含 Actor 与 Critic 学习机制：从策略梯度、PPO-Clip、GAE 到机器人控制

2026 年 10 月 18 日

## 目录


第一部分　从预期回报到策略梯度 . . . . . 2
第二部分　Baseline、Value 与 Advantage . . . . . 3
第三部分　性能差分、Surrogate Objective 与重要性采样 . . . . . 4
第四部分　TRPO：用 Trust Region 控制更新 . . . . . 6
第五部分　PPO-Clip 的核心推导 . . . . . 7
第六部分　GAE：Advantage 究竟如何估计? . . . . . 9
第七部分　完整 Actor–Critic 损失 . . . . . 13
第八部分　连续动作 PPO 与机器人控制 . . . . . 15
第九部分　一次 PPO Iteration 的完整执行过程 . . . . . 17
第十部分　超参数与实际诊断 . . . . . 19
第十一部分　与 REINFORCE、Actor–Critic、TRPO 的关系 . . . . . 20
第十二部分　最终公式总览与研究启示 . . . . . 20


课程首页 ·English ·PDF

| 项目 | 说明 |
| --- | --- |
| 主题 | PPO |
| 修订日期 | 2026-10-19 |
| 许可 | CC BY 4.0 ·Xiong Zeng and contributors |

# 第一部分　从预期回报到策略梯度

> **阅读目标**：逐步理解 PPO 为什么这样设计，而不仅仅是记住其损失函数。本文覆盖完整数学推导、各步骤的设计动机、数值示例、实现要点，以及在机器人连续控制与残差策略学习中的用法。

**核心思想**：提高好动作的概率、降低坏动作的概率，同时避免一次策略更新过大，使得根据旧策略数据建立的局部性能模型仍然可信。

**阅读路线**：回报最大化 → Policy Gradient → Baseline / Advantage → 性能差分与重要性采样 → TRPO → PPO-Clip → GAE → Actor–Critic 完整损失 → 机器人应用与实现。

> **记号约定**：主要考虑折扣无限时域 MDP，$\gamma \in [0,1)$；$J(\theta)$ 表示从初始状态分布出发的折扣回报。涉及实际 PPO 的时间步平均时，会明确说明与严格折扣占用分布之间的区别。$\widehat{A}_t$ 是利用旧策略 Rollout 计算、在本轮策略更新中固定的 Advantage 估计。

**学习主线**：Critic 根据固定的 Bootstrap/GAE Target 学会估计长期回报 → 用 TD Error / GAE 为旧动作计算相对优劣 → Actor 根据优势梯度更新动作概率分布 → PPO-Clip 抑制过度策略变化 → 新策略重新采样。**Critic 做回归，Actor 做动作分布的带裁剪策略优化；二者通过固定的 Advantage 信号协同**。

## 1. 定义强化学习优化问题

考虑马尔可夫决策过程（MDP）：

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, r, \gamma, \rho_0).$$

其中 $s_t \in \mathcal{S}$ 为状态，$a_t \in \mathcal{A}$ 为动作，$P(s_{t+1} \mid s_t, a_t)$ 为环境转移核，$r_t$ 为奖励，$\rho_0$ 是初始状态分布，$\pi_\theta(a \mid s)$ 是参数为 $\theta$ 的随机策略。学习目标是

$$\boxed{\theta^* = \arg\max_\theta J(\theta)}, \qquad \boxed{J(\theta) = \mathbb{E}_{\tau \sim p_\theta}\left[\sum_{t=0}^{\infty} \gamma^t r_t\right]}. \tag{1}$$

轨迹记为 $\tau = (s_0, a_0, s_1, a_1, \ldots)$，其折扣回报为 $R(\tau) = \sum_t \gamma^t r_t$。于是

$$J(\theta) = \int p_\theta(\tau) R(\tau)\, d\tau.$$

**动机与困难**：$\theta$ 首先改变动作分布，再通过环境动力学影响整条未来轨迹：

$$\theta \longrightarrow a_0 \longrightarrow s_1 \longrightarrow a_1 \longrightarrow \cdots \longrightarrow R(\tau).$$

对于碰撞、摩擦、接触切换和未知动力学，$R(\tau)$ 一般不能简单地通过环境对 $\theta$ 反向传播。因此需要一种**不要求环境动力学可微**的梯度估计方法。

## 2. 利用 Log-Derivative Trick 推导 Policy Gradient

对期望求梯度：

$$\nabla_\theta J(\theta) = \int \nabla_\theta p_\theta(\tau) R(\tau)\, d\tau.$$

使用恒等式

$$\boxed{\nabla_\theta p_\theta(\tau) = p_\theta(\tau) \nabla_\theta \log p_\theta(\tau)}, \tag{2}$$

得到

$$\boxed{\nabla_\theta J(\theta) = \mathbb{E}_{\tau\sim p_\theta}\left[R(\tau)\nabla_\theta \log p_\theta(\tau)\right]}. \tag{3}$$

这称为 Likelihood-Ratio / Score-Function Trick。它把**概率密度的梯度**转为**对数概率的梯度**。下一个关键点是：MDP 轨迹概率恰好可以分解。

$$p_\theta(\tau) = \rho_0(s_0)\prod_{t=0}^{\infty}\pi_\theta(a_t \mid s_t)P(s_{t+1} \mid s_t, a_t).$$

取对数并求导。如果初始分布、环境转移核不依赖 $\theta$，则

$$\begin{aligned}\log p_\theta(\tau) &= \log \rho_0(s_0) + \sum_t \log \pi_\theta(a_t \mid s_t) + \sum_t \log P(s_{t+1} \mid s_t, a_t),\\ \boxed{\nabla_\theta \log p_\theta(\tau)} &= \boxed{\sum_t \nabla_\theta \log \pi_\theta(a_t \mid s_t)}.\end{aligned} \tag{4}$$

所以形式上有

$$\boxed{\nabla_\theta J(\theta) = \mathbb{E}\left[R(\tau)\sum_t \nabla_\theta \log \pi_\theta(a_t \mid s_t)\right]}. \tag{5}$$

这里严格处理无穷时域时需要适当的可积性与极限交换条件；也可以先在有限时域推导后取极限。

**这一转换解决了什么？** 我们只需要对策略网络的 $\log \pi_\theta(a_t \mid s_t)$ 求梯度。机器人动力学和奖励仍然只用于前向采样，不必可微。

### 3. 因果性与 Reward-to-Go

式 (5) 的每个动作梯度都乘以整条轨迹回报。但 $a_t$ 不能影响发生在 $t$ 以前的奖励。利用 score function 的零均值性质，过去奖励对应的交叉项期望为零，于是可改写成

$$G_t = \sum_{k=t}^{\infty}\gamma^{k-t}r_k, \qquad \boxed{\nabla_\theta J(\theta) = \mathbb{E}\left[\sum_{t=0}^{\infty}\gamma^t \nabla_\theta \log \pi_\theta(a_t \mid s_t)G_t\right]}. \tag{6}$$

**动机**：对 $a_t$ 的更新应由它能够影响的未来后果决定。去除过去奖励通常可以降低估计方差，而不改变梯度期望。式中的 $\gamma^t$ 与原始折扣目标严格一致；实际 PPO 代码经常直接对采样时间步平均，属于相应采样分布下的优化约定，不应混为完全相同的无穷时域表达式。

## 第二部分　Baseline、Value 与 Advantage

### 4. 为什么可以减去 Baseline?

虽然使用 Reward-to-Go 比整条轨迹回报更合理，但 $G_t$ 仍会因未来随机性而显著波动。考虑引入只依赖状态的 Baseline $b(s_t)$：

$$g_t = \nabla_\theta \log \pi_\theta(a_t \mid s_t)\,[G_t - b(s_t)].$$

证明它不改变策略梯度的期望：

$$
\begin{aligned}
&\mathbb{E}_{a\sim\pi_\theta(\cdot|s)}[\nabla_\theta \log \pi_\theta(a \mid s) b(s)] \\
&= b(s) \int \pi_\theta(a \mid s) \nabla_\theta \log \pi_\theta(a \mid s)\, da \\
&= b(s) \int \nabla_\theta \pi_\theta(a \mid s)\, da \\
&= b(s) \nabla_\theta \int \pi_\theta(a \mid s)\, da \\
&= b(s) \nabla_\theta 1 = 0.
\end{aligned} \tag{7}
$$

因此

$$
\boxed{\mathbb{E}[\nabla \log \pi_\theta G_t] = \mathbb{E}[\nabla \log \pi_\theta (G_t - b(s_t))]}. \tag{8}
$$

**动机**：去除与“当前动作相对质量”无关的整体回报水平，从而减小随机波动。要注意：不是任何 Baseline 都能保证减小方差；严格的最优方差 Baseline 通常还与 score gradient 的平方范数有关。$V^\pi(s)$ 是实用而自然的选择。

### 5. 为什么使用 Value Function 作为 Baseline?

定义状态价值、动作价值和优势函数：

$$
\begin{aligned}
V^\pi(s) &= \mathbb{E}_\pi[G_t \mid s_t = s], \\
Q^\pi(s,a) &= \mathbb{E}_\pi[G_t \mid s_t = s, a_t = a], \\
\boxed{A^\pi(s,a)} &= \boxed{Q^\pi(s,a) - V^\pi(s)}.
\end{aligned} \tag{9}
$$

$V^\pi(s)$ 衡量“从该状态按现有策略继续执行的平均回报”；$Q^\pi(s,a)$ 衡量“先执行指定动作再按策略继续执行的平均回报”。因此：

- $A^\pi(s,a) > 0$：这个动作比当前策略的平均动作更好，应倾向于提高其概率；
- $A^\pi(s,a) < 0$：这个动作比平均动作更差，应倾向于降低其概率；
- $A^\pi(s,a) = 0$：在该估计下没有相对优劣信号。

在准确的 $Q^\pi, V^\pi$ 下，得到 Advantage Policy Gradient：

$$
\boxed{\nabla_\theta J(\theta) = \mathbb{E}\left[\sum_t \gamma^t \nabla_\theta \log \pi_\theta(a_t \mid s_t) A^{\pi_\theta}(s_t, a_t)\right]}. \tag{10}
$$

从而引出 Actor–Critic：Actor $\pi_\theta$ 负责产生动作；Critic $V_\phi$ 近似状态价值；Advantage 连接二者。使用不准确的 Value Baseline 本身不会改变理想 score-function 公式的期望，但使用自举构造 Advantage 时会引入额外估计偏差。

## 第三部分　性能差分、Surrogate Objective 与重要性采样

### 6. 旧数据为什么不能无限重复使用?

Policy Gradient 假设采样数据与当前策略一致。若使用 $\pi_{\theta_0}$ 采样后更新到 $\pi_{\theta_1}$、$\pi_{\theta_2}$，旧 Rollout 依然服从 $\pi_{\theta_0}$，并不服从新策略。每次梯度步都重新采样又非常昂贵。

PPO 的目标之一是：**在一批由旧策略采集的数据上，进行多次相对安全的一阶更新**。要做到这一点，必须区分状态分布的变化和给定状态下动作分布的变化。

### 7. Performance Difference Lemma 的逐步证明

定义归一化折扣状态访问分布：

$$\boxed{d_\pi(s) = (1-\gamma)\sum_{t=0}^{\infty}\gamma^t \Pr(s_t = s \mid \pi)}. \tag{11}$$

对连续状态空间，上式应理解为对应概率测度/密度。对于任意新旧策略，性能差分引理给出**精确恒等式**：

$$\boxed{J(\pi_\theta) - J(\pi_{\text{old}}) = \frac{1}{1-\gamma}\mathbb{E}_{\substack{s\sim d_{\pi_\theta}\\ a\sim\pi_\theta}}[A^{\pi_{\text{old}}}(s,a)]}. \tag{12}$$

**证明**：由旧策略的 Bellman 方程，

$$A^{\pi_{\text{old}}}(s_t,a_t) = \mathbb{E}[r_t + \gamma V^{\pi_{\text{old}}}(s_{t+1}) - V^{\pi_{\text{old}}}(s_t) \mid s_t, a_t].$$

沿**新策略**的轨迹求折扣和：

$$\begin{aligned}&\mathbb{E}_{\pi_\theta}\left[\sum_t \gamma^t A^{\pi_{\text{old}}}(s_t,a_t)\right]\\ &= \mathbb{E}_{\pi_\theta}\left[\sum_t \gamma^t r_t + \sum_t \gamma^{t+1}V^{\pi_{\text{old}}}(s_{t+1}) - \sum_t \gamma^t V^{\pi_{\text{old}}}(s_t)\right].\end{aligned}$$

后两个级数望远镜相消，只剩 $-V^{\pi_{\text{old}}}(s_0)$（假设末端项消失），因此

$$\mathbb{E}_{\pi_\theta}\left[\sum_t \gamma^t A^{\pi_{\text{old}}}(s_t,a_t)\right] = J(\pi_\theta) - J(\pi_{\text{old}}).$$

再用 $d_{\pi_\theta}$ 的定义重写折扣时间求和，即得到式 (12)。

**重要直觉**：新策略的回报提升，等于它在自身将访问的状态、执行的动作上，取得的 “相对于旧策略” 的 Advantage 总和。

### 8. 将真实性能改进近似为 Surrogate Objective

式 (12) 的困难在于，期望中的状态来自新策略：

$$s \sim d_{\pi_\theta}.$$

但我们手上只有旧策略数据。如果新旧策略足够接近，可以作**局部近似**：

$$d_{\pi_\theta}(s) \approx d_{\pi_{\text{old}}}(s).$$

忽略正常数 $1/(1-\gamma)$ 后，定义

$$\boxed{L_{\text{sur}}(\theta) = \mathbb{E}_{\substack{s\sim d_{\pi_{\text{old}}}\\ a\sim\pi_\theta}}[A^{\pi_{\text{old}}}(s,a)]}. \tag{13}$$

它比直接优化新策略的整条轨迹分布容易得多：状态分布固定，只需要研究给定状态下动作概率的变化。在旧参数附近，准确 Advantage 对应的 Surrogate 与真实目标具有相同的一阶局部方向（差一个正常数）。

**核心前提**：只有当 $\pi_\theta$ 不远离 $\pi_{\text{old}}$ 时，这种状态分布替换才比较可信。这为后面的 Trust Region 和 Clipping 提供了动机。

### 9. Importance Sampling 推导 Probability Ratio

式 (13) 仍然包含 $a \sim \pi_\theta$，而数据中的动作来自旧策略。给定状态 $s$，利用重要性采样：

$$\begin{aligned}\mathbb{E}_{a\sim\pi_\theta}[A^{\pi_{\text{old}}}(s,a)] &= \int \pi_\theta(a \mid s) A^{\pi_{\text{old}}}(s,a)\, da \\ &= \int \pi_{\text{old}}(a \mid s) \frac{\pi_\theta(a \mid s)}{\pi_{\text{old}}(a \mid s)} A^{\pi_{\text{old}}}(s,a)\, da.\end{aligned}$$

定义概率比：

$$\boxed{r_\theta(s,a) = \frac{\pi_\theta(a \mid s)}{\pi_{\text{old}}(a \mid s)}}. \tag{14}$$

于是得到 CPI（Conservative Policy Iteration）形式的代理目标：

$$\boxed{L^{\text{CPI}}(\theta) = \mathbb{E}_{\substack{s\sim d_{\pi_{\text{old}}} \\ a\sim\pi_{\text{old}}}}\left[r_\theta(s,a) A^{\pi_{\text{old}}}(s,a)\right]}. \tag{15}$$

实际估计写为 $\mathbb{E}_t[r_t(\theta)\hat{A}_t]$。

概率比的解释：若旧动作概率为 0.2、新概率为 0.3，则 $r = 1.5$；若新概率变为 0.1，则 $r = 0.5$。正 Advantage 鼓励 $r$ 上升，负 Advantage 鼓励 $r$ 下降。

**边界与限制**：上述重要性采样要求新策略对旧策略概率为零的动作不赋正概率（绝对连续性）；对于一般 Gaussian 分布，通常满足动作密度支持条件。重要性采样仅精确修正了**给定状态下的动作分布**，并未修正 $d_{\pi_\theta}$ 与 $d_{\pi_{\text{old}}}$ 的差异。因此，它没有消除式 (13) 的状态分布近似误差。

## 第四部分　TRPO：用 Trust Region 控制更新

### 10. 直接最大化 CPI 为什么危险?

对于正 Advantage 样本，$r_t\hat{A}_t$ 随 $r_t$ 增长：若 $\hat{A} = 5$，$r = 1.2, 2, 10$ 对应 $6, 10, 50$。代理目标似乎鼓励无限放大好动作的概率。但这些 Advantage 是根据旧策略计算的；如果新策略改变很大，旧估计不一定再可信。

尤其在机器人操作中，动作分布的一次较大改变可能引发接触切换、掉落甚至完全不同的未来状态访问。故 $L^{\text{CPI}}$ 增大**不保证**真实 $J$ 增大。

### 11. KL Divergence 与 TRPO 约束

使用 KL Divergence 衡量同一状态下两策略的分布差异：

$$D_{\text{KL}}(\pi_{\text{old}} \| \pi_\theta) = \mathbb{E}_{a\sim\pi_{\text{old}}}\left[\log \frac{\pi_{\text{old}}(a \mid s)}{\pi_\theta(a \mid s)}\right].$$

TRPO 的实用优化形式是

$$\boxed{\begin{aligned} &\max_\theta \quad \mathbb{E}_t[r_t(\theta)\hat{A}_t] \\ &\text{s.t.} \quad \mathbb{E}_{s\sim d_{\pi_{\text{old}}}}[D_{\text{KL}}(\pi_{\text{old}}(\cdot \mid s) \| \pi_\theta(\cdot \mid s))] \le \delta. \end{aligned}} \tag{16}$$

$\delta$ 决定信赖域大小。其动机不是 “策略改变越小越好”，而是**在一个代理目标足够可信的局部区域内寻找改进**。

TRPO 的理论分析给出含有最大状态策略差异惩罚项的性能下界，典型结构为

$$J(\pi_\theta) \geq J(\pi_{\text{old}}) + \frac{L_{\text{sur}}(\theta)}{1-\gamma} - C \max_s D_{\text{KL}}(\pi_{\text{old}} \| \pi_\theta), \tag{17}$$

其中 $C$ 依赖回报/Advantage 的界和 $\gamma$；具体常数以及 KL 方向取决于采用的界。**注意**：理论中的最坏状态差异控制，强于工程实现的平均 KL 约束；实际神经网络 TRPO 不能据此保证每次更新单调提升。

### 12. TRPO 局部二阶近似与 Natural Gradient

令 $\Delta\theta = \theta - \theta_{\text{old}}$。在旧参数附近进行泰勒展开：

$$L^{\text{CPI}}(\theta) \approx L^{\text{CPI}}(\theta_{\text{old}}) + g^\top \Delta\theta, \quad g = \nabla_\theta L^{\text{CPI}}\big|_{\theta_{\text{old}}}.$$

KL 在相同策略处为零且一阶梯度为零，二阶近似为

$$\bar{D}_{\text{KL}} \approx \tfrac{1}{2} \Delta\theta^\top F \Delta\theta,$$

其中 $F$ 是在旧参数处计算的 Fisher 信息矩阵。为避免歧义，先定义 $u_{\text{old}}(s,a) = \nabla_\theta \log \pi_\theta(a \mid s)\big|_{\theta=\theta_{\text{old}}}$，则

$$F = \mathbb{E}_{s\sim d_{\pi_{\text{old}}},\, a\sim\pi_{\text{old}}}[u_{\text{old}}(s,a) u_{\text{old}}(s,a)^\top].$$

局部问题变成

$$\boxed{\max_{\Delta\theta} g^\top \Delta\theta \quad \text{s.t.} \quad \tfrac{1}{2}\Delta\theta^\top F \Delta\theta \leq \delta.} \tag{18}$$

写出 Lagrangian：

$$\mathcal{L}(\Delta\theta, \eta) = g^\top \Delta\theta - \eta(\tfrac{1}{2}\Delta\theta^\top F \Delta\theta - \delta).$$

一阶条件 $g - \eta F \Delta\theta = 0$ 导致 $\Delta\theta = \eta^{-1} F^{-1} g$。代入活动约束（假设 $F$ 正定、$g \neq 0$）得

$$\boxed{\Delta\theta^* = \sqrt{\frac{2\delta}{g^\top F^{-1} g}} F^{-1} g.} \tag{19}$$

方向 $F^{-1}g$ 正是 Natural Policy Gradient 的核心形式。实际训练不能显式反演一个巨大矩阵，因此需要 Fisher-vector product、共轭梯度、线搜索等技术；非正定或病态情况下还需阻尼。**PPO 的设计动机**：保留保守策略更新的思想，但避免 TRPO 的复杂二阶/约束优化。

## 第五部分　PPO-Clip 的核心推导

### 13. 从 KL Penalty 到 Clipped Surrogate

最直接的一阶化方式是 PPO-Penalty：

$$L^{\text{KLPEN}}(\theta) = \mathbb{E}_t[r_t(\theta)\hat{A}_t] - \beta\, \mathbb{E}_t[D_{\text{KL}}(\pi_{\text{old}} \| \pi_\theta)]. \tag{20}$$

但 $\beta$ 太小会限制不足，太大则更新过慢，还需要调整罚系数。PPO-Clip 改为限制 “过大的概率比带来的额外目标收益”。设

$$\text{clip}(r, 1-\epsilon, 1+\epsilon) = \min\{1+\epsilon, \max\{r, 1-\epsilon\}\}.$$

最常用的 PPO 目标为

$$\boxed{L^{\text{CLIP}}(\theta) = \mathbb{E}_t\left[\min\left(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon)\hat{A}_t\right)\right]}. \tag{21}$$

常见起点为 $\epsilon = 0.1 \sim 0.2$，但应当根据环境、动作维度和监测的 KL 调整。**这里的 `min` 与 `clip` 必须一起理解**。

### 14. 正 Advantage：好动作不能无限被奖励

若 $\hat{A}_t > 0$，希望提高该动作概率，即使 $r_t > 1$。式 (21) 化简为

$$\boxed{L_t^{\text{CLIP}} = \min(r_t, 1+\epsilon)\hat{A}_t = \begin{cases} r_t\hat{A}_t, & r_t \le 1+\epsilon, \\ (1+\epsilon)\hat{A}_t, & r_t > 1+\epsilon. \end{cases}} \tag{22}$$

设 $\hat{A}_t = 2, \epsilon = 0.2$:

| $r_t$ | 原始 $r_t\hat{A}_t$ | PPO 目标 |
|---|---|---|
| 0.8 | 1.6 | 1.6 |
| 1.0 | 2.0 | 2.0 |
| 1.1 | 2.2 | 2.2 |
| 1.2 | 2.4 | 2.4 |
| 1.5 | 3.0 | 2.4 |
| 2.0 | 4.0 | 2.4 |

当 $r_t > 1.2$ 时，这个样本不再因为概率继续上升而增加代理目标，梯度在此方向上为零。**设计动机**：避免对看起来 “好” 的旧策略样本过度提高概率。

### 15. 负 Advantage：坏动作也不能无限被压低

若 $\hat{A}_t < 0$，希望降低动作概率，即降低 $r_t$。由于乘以负数会反转大小关系，

$$\boxed{L_t^{\text{CLIP}} = \max(r_t, 1-\epsilon)\hat{A}_t = \begin{cases} (1-\epsilon)\hat{A}_t, & r_t < 1-\epsilon, \\ r_t\hat{A}_t, & r_t \ge 1-\epsilon. \end{cases}} \tag{23}$$

设 $\hat{A}_t = -2, \epsilon = 0.2$:

| $r_t$ | 原始 $r_t\hat{A}_t$ | PPO 目标 |
|---|---|---|
| 0.5 | -1.0 | -1.6 |
| 0.7 | -1.4 | -1.6 |
| 0.8 | -1.6 | -1.6 |
| 1.0 | -2.0 | -2.0 |
| 1.2 | -2.4 | -2.4 |
| 1.5 | -3.0 | -3.0 |

PPO 最大化目标，因此负 Advantage 时降低 $r$ 有利；但当 $r < 0.8$ 时不再额外奖励进一步压低该动作的概率。

### 16. 为什么一定要有 `min`，而不是只用 `clip`?

假设只有 $\text{clip}(r, 1-\epsilon, 1+\epsilon)\hat{A}$。若 $\hat{A} > 0$、$r = 0.5$、$\epsilon = 0.2$，说明好动作的概率已经被错误地大幅降低，但单独的 `clip` 会输出 $0.8\hat{A}$，在 $r < 0.8$ 区域梯度为零，无法纠正错误方向。

加入 `min` 后，由于 $r\hat{A} < 0.8\hat{A}$，实际使用原始项 $r\hat{A}$，因此仍有正梯度推动 $r$ 回升。负 Advantage 下的错误方向同理。

| | |
|---|---|
| 更新方向正确但幅度过大： | 停止提供额外优化收益； |
| 更新方向不利于 Advantage： | 保留纠偏梯度。 |

而且由 $\min(x, y) \le x$，逐样本成立 $L^{\text{CLIP}} \le L^{\text{CPI}}$：这是对**未裁剪代理目标**的保守下界，**不等于对真实回报 $J$ 的严格下界**。

### 17. 从梯度看 PPO 在何处停止更新

因为旧策略分母在本次优化中不变，

$$\boxed{\nabla_\theta r_t(\theta) = r_t(\theta)\nabla_\theta \log \pi_\theta(a_t \mid s_t)}. \tag{24}$$

忽略折点处的不可微性（优化器采用次梯度），单样本梯度为

$$\nabla_\theta L_t^{\text{CLIP}} = \begin{cases} 0, & \hat{A}_t > 0,\ r_t > 1+\epsilon, \\ 0, & \hat{A}_t < 0,\ r_t < 1-\epsilon, \\ \hat{A}_t r_t \nabla_\theta \log \pi_\theta(a_t \mid s_t), & \text{其余区域.} \end{cases} \tag{25}$$

当 $\theta = \theta_{\text{old}}$，$r_t = 1$，因此初始局部梯度与 CPI/Advantage Policy Gradient 一致（差相应归一化常数）。**PPO 不改变初始策略改进方向，而是在重复更新、概率比逐渐偏离 1 时抑制过大更新收益**。

### 18. PPO 不能保证 Ratio 或 KL 被硬性约束

$\epsilon = 0.2$ **不意味着**更新后始终有 $0.8 \le r_t \le 1.2$。Clipping 修改的是损失，而不是把策略投影到可行集合。共享神经网络参数会同时影响其他状态和样本；多个 Mini-batch Epoch 后，平均 KL 依然可能过大。

因此常在训练中监测

$$\bar{D}_{\text{KL}}(\pi_{\text{old}} \| \pi_\theta)$$

并使用 Target-KL Early Stopping，必要时结合学习率调整、Gradient Clipping。需要分清三种裁剪：**Ratio Clipping** 控制代理收益；**Gradient Clipping** 控制梯度范数；**Action Clipping** 限制真实执行动作范围。三者不是一回事。

## 第六部分　GAE：Advantage 究竟如何估计?

### 19. Monte Carlo Advantage 的动机与代价

PPO 中使用的 $\hat{A}_t$ 不是凭空给定。按定义 $A^\pi = Q^\pi - V^\pi$，最直接的方法是把样本回报 $G_t$ 作为 $Q^\pi$ 的样本估计：

$$\boxed{\hat{A}_t^{\text{MC}} = G_t - V_\phi(s_t)}, \qquad G_t = \sum_{l=0}^{T-t-1} \gamma^l r_{t+l}. \tag{26}$$

对完整终止轨迹，在正确策略分布下，$G_t$ 的条件期望等于 $Q^\pi(s_t, a_t)$。它不需要用 Critic 对未来进行自举，因此目标相对直接。然而，如果抓取任务直到第 100 步成功才给出奖励，早期动作的 $G_t$ 会受到大量后续随机因素影响，梯度方差可能很大。

**问题**：能否尽早利用较少步数的信息估计 Advantage，而不依赖整条未来轨迹?

### 20. 由 Bellman 方程得到 One-Step TD Advantage

Bellman 关系为

$$Q^\pi(s_t, a_t) = \mathbb{E}[r_t + \gamma V^\pi(s_{t+1}) \mid s_t, a_t].$$

因此，一步 TD Residual：

$$\boxed{\delta_t = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t)} \tag{27}$$

可用作 Advantage 估计：

$$\boxed{\hat{A}_t^{(1)} = \delta_t}. \tag{28}$$

它只需要一个转移样本 $s_t, a_t, r_t, s_{t+1}$。未来随机回报被 $V_\phi(s_{t+1})$ 代替，通常可以降低方差；代价是 Critic 不准确时会引入自举偏差。对于真正终止状态，未来价值为零；对于人为时间截断，则通常仍需 Bootstrap。

| 估计器 | 主要优点 | 主要缺点 |
|---|---|---|
| Monte Carlo | 减少未来价值自举偏差 | 长期回报导致高方差 |
| One-Step TD | 方差较低、反馈及时 | 更依赖 Critic 的预测准确性 |

### 21. 从 One-Step 推导 N-Step Advantage

一步估计：

$$\hat{A}_t^{(1)} = r_t + \gamma V(s_{t+1}) - V(s_t) = \delta_t.$$

两步估计：

$$\begin{aligned} \hat{A}_t^{(2)} &= r_t + \gamma r_{t+1} + \gamma^2 V(s_{t+2}) - V(s_t) \\ &= [r_t + \gamma V(s_{t+1}) - V(s_t)] \\ &\quad + \gamma[r_{t+1} + \gamma V(s_{t+2}) - V(s_{t+1})] \\ &= \boxed{\delta_t + \gamma \delta_{t+1}}. \end{aligned} \tag{29}$$

三步估计同理：

$$\hat{A}_t^{(3)} = \delta_t + \gamma \delta_{t+1} + \gamma^2 \delta_{t+2}.$$

推广到 $n$ 步：

$$\boxed{\hat{A}_t^{(n)} = \sum_{l=0}^{n-1} \gamma^l \delta_{t+l}}. \tag{30}$$

较小 $n$ 更多依赖 Value Bootstrap，较大 $n$ 更多依赖真实未来奖励。**GAE 的出发点**：不要在单一的 $n$ 上做硬选择，而是平滑组合多个 N-Step 估计器。

### 22. GAE 的指数权重与求和交换推导

令 $0 \le \lambda < 1$，定义

$$\boxed{\hat{A}_t^{\mathrm{GAE}(\gamma,\lambda)} = (1-\lambda)\sum_{n=1}^{\infty}\lambda^{n-1}\hat{A}_t^{(n)}}. \tag{31}$$

这里权重总和为 1：$(1-\lambda)\sum_{n\ge 1}\lambda^{n-1} = 1$。代入 N-Step 形式：

$$\begin{aligned}\hat{A}_t^{\mathrm{GAE}} &= (1-\lambda)\sum_{n=1}^{\infty}\lambda^{n-1}\sum_{l=0}^{n-1}\gamma^l\delta_{t+l} \\ &= \sum_{l=0}^{\infty}\gamma^l\delta_{t+l}(1-\lambda)\sum_{n=l+1}^{\infty}\lambda^{n-1} \\ &= \sum_{l=0}^{\infty}\gamma^l\delta_{t+l}\lambda^l.\end{aligned}$$

因此：

$$\boxed{\hat{A}_t^{\mathrm{GAE}(\gamma,\lambda)} = \sum_{l=0}^{\infty}(\gamma\lambda)^l\delta_{t+l}}. \tag{32}$$

也就是：

$$\hat{A}_t = \delta_t + \gamma\lambda\delta_{t+1} + (\gamma\lambda)^2\delta_{t+2} + \cdots.$$

**两个极端**：$\lambda = 0$ 时只剩 $\delta_t$，即 One-Step TD；$\lambda \to 1$ 时趋于所有后续 TD Residual 之和。对于完整终止轨迹，$\lambda = 1$ 对应 $G_t - V(s_t)$。实用 PPO 常把 $\gamma = 0.99, \lambda = 0.95$ 作为起点。

GAE 并非数学上保证任何情况下方差都更低。它提供可调的偏差–方差折中：$\lambda$ 较小通常更依赖 Critic，$\lambda$ 较大通常更依赖长期采样回报。

### 23. GAE 的 $O(T)$ 反向递推

式 (32) 具有递归结构：

$$\boxed{\hat{A}_t = \delta_t + \gamma\lambda\hat{A}_{t+1}}. \tag{33}$$

若 $d_t = 1$ 表示 MDP 在该步真正终止：

$$\boxed{\begin{aligned}\delta_t &= r_t + \gamma(1-d_t)V_\phi(s_{t+1}) - V_\phi(s_t), \\ \hat{A}_t &= \delta_t + \gamma\lambda(1-d_t)\hat{A}_{t+1}.\end{aligned}} \tag{34}$$

这样从 $T-1$ 向前循环一次就能完成全部计算，复杂度为 $O(T)$。固定长度 Rollout 的最后一个状态若并未真正终止，应使用 $V(s_T)$ Bootstrap；而递归不能跨越一次 Episode Reset 错误地把下一条 Episode 的 Advantage 累加进来。实现时应区分 **terminated（真实终止）**、**truncated（外部时间限制）**和 **Rollout Boundary（采样段边界）**。

## 24. 用 GAE 构造 Critic 训练目标

GAE 给出 Advantage 估计：

$$\hat{A}_t \approx Q^{\pi_{\text{old}}}(s_t, a_t) - V_{\text{old}}(s_t).$$

自然定义 TD($\lambda$) Return：

$$\boxed{\hat{R}_t^{\lambda} = \hat{A}_t^{\text{GAE}} + V_{\phi_{\text{old}}}(s_t)}. \tag{35}$$

这里 $V_{\phi_{\text{old}}}$ 是计算这一批 Rollout 目标时保存的旧 Value，整个 PPO 更新阶段必须视为常量。这一技巧让 Actor 的 Advantage 估计与 Critic 的回归目标保持一致。

### 24.1 Critic 的学习信号：Bellman Target 与半梯度

Critic 不知道真实的 $V^{\pi_{\text{old}}}(s)$，但可以从旧策略产生的样本 $(s_t, a_t, r_t, s_{t+1})$ 构造近似监督信号。对于不是真正终止的下一状态，一步自举目标为

$$\boxed{y_t^{\text{TD}} = r_t + \gamma V_{\phi_{\text{old}}}(s_{t+1})}, \qquad \delta_t = y_t^{\text{TD}} - V_{\phi_{\text{old}}}(s_t).$$

若 $d_t = 1$ 代表真实的 MDP 终止，则使用 $y_t^{\text{TD}} = r_t + \gamma(1 - d_t)V_{\phi_{\text{old}}}(s_{t+1})$。人工时间上限、Rollout 切分和真正终止不能直接使用同一个 Mask：若环境只是截断而非终止，应从截断前的真实最后观测 Bootstrap，不能误用 Reset 后的状态。

把目标视为**常量**，Critic 通过回归学习：

$$\ell_t(\phi) = \tfrac{1}{2}\left(V_\phi(s_t) - \text{stopgrad}(y_t^{\text{TD}})\right)^2,$$

$$\boxed{\nabla_\phi \ell_t = (V_\phi(s_t) - y_t^{\text{TD}})\nabla_\phi V_\phi(s_t)}.$$

这就是常说的 **Semi-Gradient TD**：目标中的旧 Critic 值不接受本次反向传播；但预测项 $V_\phi(s_t)$ 接受梯度。若让梯度同时穿过目标 $V_\phi(s_{t+1})$，优化的就不再是通常的固定目标 TD 回归。注意：PPO **通常不要求**像 DQN 那样再维护一个长期滞后的 Target Network；一次 Rollout 内保存旧值并固定回归目标即可。

### 24.2 为什么 PPO 常用 TD($\lambda$) Return，而非仅用 One-Step TD?

第 22–23 节已推导 GAE。它与 Critic Target 存在一致的代数关系：

$$\boxed{\hat{R}_t^{\lambda} = V_{\text{old}}(s_t) + \hat{A}_t^{\text{GAE}}}.$$

对一段没有真实终止的连续轨迹，可等价写成

$$\hat{R}_t^{\lambda} = r_t + \gamma\left[(1-\lambda)V_{\text{old}}(s_{t+1}) + \lambda \hat{R}_{t+1}^{\lambda}\right],$$

在采样段尾部用合适的 $V_{\text{old}}(s_T)$ 初始化 Bootstrap；遇到真正终止则令后续回报为零。$\lambda = 0$ 退化为 One-Step TD Target；对完整终止轨迹，$\lambda = 1$ 退化为 Monte Carlo Return。中间值同时利用多步奖励与 Bootstrap，这既可作为 Actor 的 Advantage 信号，也可形成 Critic 的回归目标。

**关键区分：**“计算 GAE 的旧 Value”与“当前要训练的 $V_\phi$”是两个时间快照；PPO 一轮优化中，$\hat{A}_t$、$\hat{R}_t^{\lambda}$ 和旧动作 Log Probability 均固定，即使 Critic 参数已更新也不在同一轮内偷偷重算它们。

# 第七部分　完整 Actor–Critic 损失

## 25. Actor Loss

本轮旧策略 Rollout 上，先计算并固定 $\hat{A}_t$（实践中经常标准化）。Actor 最大化

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[ \min \left( r_t \hat{A}_t, \text{clip}(r_t, 1-\epsilon, 1+\epsilon) \hat{A}_t \right) \right].$$

在 PyTorch 等以最小化为接口的框架中：

$$\boxed{\mathcal{L}_{\text{actor}} = -L^{\text{CLIP}}}. \tag{36}$$

如果 $\hat{A}_t$ 通过当前可训练 Critic 的计算图产生，应在 Actor Loss 中对其 `detach`，避免无意把 Actor 更新传播到 Advantage 目标。

### 25.1 Actor 没有正确动作标签，为什么仍能学习?

行为克隆需要专家标签 $a_t^*$，PPO 不需要。它只有自己采样的动作及其**相对质量** $\hat{A}_t$。先看未裁剪代理目标：

$$L_t^{\text{CPI}}(\theta) = \rho_t(\theta) \hat{A}_t, \qquad \rho_t(\theta) = \frac{\pi_\theta(a_t \mid s_t)}{\pi_{\text{old}}(a_t \mid s_t)}.$$

因为旧分母和 Advantage 被固定，

$$\boxed{\nabla_\theta [-L_t^{\text{CPI}}] = -\hat{A}_t \rho_t(\theta) \nabla_\theta \log \pi_\theta(a_t \mid s_t)}.$$

在本轮更新刚开始时 $\theta = \theta_{\text{old}}$，有 $\rho_t = 1$，Clipping 尚未生效，因此 Actor 与基本 Advantage Policy Gradient 的方向一致：

- $\hat{A}_t > 0$：提高这次采样动作的概率密度，**并非**将动作强行回归到它；
- $\hat{A}_t < 0$：降低这次动作的概率密度；
- $\hat{A}_t \simeq 0$：该样本给出的局部策略信号很弱。

对参数做梯度下降后，神经网络会改变许多状态与动作的概率，因此上面讨论的是**单样本、局部的梯度贡献**，不保证某个动作最终概率必然按该方向变化。Clipping 只在样本的概率比朝有利方向变化过多时，停止提供额外收益；第 17 节已经给出精确的分段梯度。

### 25.2 一个 Actor 更新数值例子

设某个采样动作在旧策略下的概率为 $\pi_{\text{old}}(a_t \mid s_t) = 0.20$，$\epsilon = 0.2$，$\hat{A}_t = +2$。若新概率变成 0.22，则 $\rho_t = 1.1$，该样本的未裁剪收益为 2.2；若变成 0.30，则 $\rho_t = 1.5$，PPO-Clip 对该样本只计 $1.2 \times 2 = 2.4$，进一步增大这一概率不再增加其代理收益。对于负 Advantage，过度**降低**概率时也出现相应平台。这里为了直观以离散动作的概率作例子；连续 Gaussian Policy 应使用**概率密度**与联合 Log Probability，而非单点概率。

## 26. Critic Loss

Critic 通过回归 $\hat{R}_t^\lambda$ 学习状态价值：

$$\boxed{\mathcal{L}_{\text{critic}}(\phi) = \mathbb{E}_t[(V_\phi(s_t) - \hat{R}_t^\lambda)^2]}. \tag{37}$$

也可以直接回归 Monte Carlo Return。某些实现另设 Value Clipping 或 $\frac{1}{2}$ 系数，但它们不是 PPO-Clip 目标的必要组成。Critic 过差会导致 Advantage 的符号或量级不准确，因此 PPO 的训练稳定性很大程度依赖 Value Function 的估计质量。

### 26.1 Critic 的误差如何真正改变网络参数?

为简化梯度形式，考虑带 $\frac{1}{2}$ 系数的逐样本 MSE：

$$\ell_t^V(\phi) = \tfrac{1}{2}\big(V_\phi(s_t) - \hat{R}_t^\lambda\big)^2, \quad \boxed{\nabla_\phi \ell_t^V = \big(V_\phi(s_t) - \hat{R}_t^\lambda\big)\nabla_\phi V_\phi(s_t)}.$$

例如 $V_{\text{old}}(s_t) = 4$、$V_{\text{old}}(s_{t+1}) = 5$、$r_t = 2$、$\gamma = 0.9$、且没有终止，One-Step Target 为

$$y_t^{\text{TD}} = 2 + 0.9 \times 5 = 6.5, \qquad \delta_t = 6.5 - 4 = 2.5.$$

若把 $V(s_t)$ 暂时视为一个可单独优化的标量，则 $\partial \ell / \partial V = 4 - 6.5 = -2.5$，梯度下降会推动预测值上升。对真实神经网络，更新通过 $\nabla_\phi V_\phi(s_t)$ 分配到共享参数，因此不会保证任何特定状态的预测单调改变。

**学习的不只是即时奖励：** $V_\phi(s_t)$ 预测的是当前策略下的折扣**长期**回报；即使当前奖励为零，后继状态的 Bootstrap 或未来多步奖励也能传递学习信号。Critic 属于近似的、自举的监督回归，不是已知真值标签上的普通回归。

### 26.2 Critic Loss 降了，Value 就一定正确吗?

不一定。Target 依赖旧 Critic、有限轨迹和随机奖励；Actor 更新又会改变下轮所对应的策略与状态分布。低训练 MSE 不等于 Value 无偏，也不等于真实 Episode Return 提升。**Explained Variance** 常定义为

$$\text{EV} = 1 - \frac{\text{Var}(\hat{R}_t^\lambda - V_\phi(s_t))}{\text{Var}(\hat{R}_t^\lambda)},$$

当目标的方差接近零时该指标不稳定；且目标本身仍可能有偏。应结合成功率、实际回报与 Target / Value 的尺度一起诊断。某些实现对 Value 增量做 Clipping，但它不保证真实价值精度提升。

## 27. Entropy Bonus 的动机

策略可能过早收缩到狭窄动作分布，停止尝试其他抓取方式。使用策略熵

$$\boxed{H(\pi_\theta(\cdot \mid s)) = -\mathbb{E}_{a\sim\pi_\theta}[\log \pi_\theta(a \mid s)]}. \tag{38}$$

鼓励合理探索。其平均值记为 $L^{\text{entropy}} = \mathbb{E}_t[H(\pi_\theta(\cdot \mid s_t))]$。高熵并不总是更好，尤其是机器人部署阶段；Entropy Coefficient 可能取零，也可能随训练退火。

### 27.1 熵正则如何参与 Gaussian 方差学习?

一维未压缩 Gaussian $\mathcal{N}(\mu, \sigma^2)$ 的熵为

$$\boxed{H(\pi) = \tfrac{1}{2}\log(2\pi e\sigma^2) = \tfrac{1}{2}\log(2\pi e) + \log\sigma}, \qquad \frac{\partial H}{\partial \log\sigma} = 1.$$

因此，最小化总损失中的 $-c_e H$，会在 $c_e > 0$ 时提供增加 $\log\sigma$ 的梯度倾向；而 Advantage 的梯度可能使方差增大或减小，具体见第 30 节。**探索并不是方差越大越好**：高噪声会妨碍接触稳定性，也可能使机器人执行动作触及安全限制。多维独立 Gaussian 的熵为各维之和；经 Tanh 变换后的动作熵不能不加修改地等同于变换前 Gaussian 熵。

## 28. PPO 的最终训练目标

把 Actor、Critic、Entropy 组合，得到一个常见的联合最大化目标：

$$\boxed{L^{\text{PPO}}(\theta, \phi) = L^{\text{CLIP}}(\theta) - c_v \mathcal{L}_{\text{critic}}(\phi) + c_e L^{\text{entropy}}(\theta)}. \tag{39}$$

对应的**最小化**形式为

$$\boxed{\mathcal{L}_{\text{total}} = -L^{\text{CLIP}} + c_v \mathcal{L}_{\text{critic}} - c_e L^{\text{entropy}}}. \tag{40}$$

- $c_v$：控制 Value 回归损失权重；
- $c_e$：控制 Entropy Bonus 权重；
- 独立 Actor 与 Critic 参数时可分别更新；共享网络时需要考虑梯度耦合。

常见实现对每个训练 Mini-batch 做多轮更新，但旧 Log Probability、Advantage 和 Return Target 在该 Rollout 的 PPO Epoch 内保持固定。

#### 28.1 梯度图：谁更新谁?

在使用独立参数的 Actor 和 Critic 时，一轮采样后先完成 GAE 计算，然后形成两条**彼此不同的监督路径**：

$$\begin{aligned}
&\pi_{\theta_{\text{old}}} \longrightarrow (s_t, a_t, r_t, s_{t+1}, \log \pi_{\text{old}}, V_{\text{old}}) \\
&\qquad\qquad \downarrow \quad \text{TD errors and GAE} \\
&\hat{A}_t \xrightarrow{\text{stopgrad}} L^{\text{CLIP}}(\theta) \longrightarrow \text{Actor parameters } \theta, \\
&\hat{R}_t^{\lambda} = \hat{A}_t + V_{\text{old}}(s_t) \xrightarrow{\text{stopgrad}} \mathcal{L}_{\text{critic}}(\phi) \longrightarrow \text{Critic parameters } \phi.
\end{aligned}$$

**为什么停止 Advantage 的梯度?** Actor 应因改变 $\pi_\theta(a_t \mid s_t)$ 而提高代理目标，而非通过修改 Critic 的 $V_\phi$ 或回归标签来“投机”降低 Actor Loss。固定 Advantage 并不会阻止 Critic 根据自己的 Loss 学习。

若两个网络各自独立，可分别用不同优化器和学习率更新。若共享视觉编码器或 Backbone，联合 Loss 对共享参数的梯度来自 Actor、Critic 和 Entropy 三项；`stopgrad` 仍用于冻结**优势与回归目标**，但不会阻断 Critic Loss 自身对共享 Backbone 的合理梯度。共享表示降低推理和参数开销，也可能导致策略与价值梯度竞争；这并不是 PPO 必须采用的架构。

#### 28.2 机器人中的 Asymmetric Actor–Critic

在仿真训练中，Actor 可以只输入部署时可获得的相机图像、本体感觉或估计状态，而 Critic 使用仿真器可访问的真实物体姿态、接触信息等 Privileged State。用符号表示为

$$\pi_\theta(a_t \mid o_t), \qquad V_\phi(x_t), \quad x_t \text{ 可包含训练阶段特权信息.}$$

这类 Asymmetric Actor–Critic 能减少价值估计难度，但**绝不能让部署 Actor 无意依赖特权输入**；如存在历史信息、部分可观测性和非马尔可夫观测，也要明确 Value 使用的信息集与 Bootstrap 条件。它是训练架构选择，而不是 PPO-Clip 算法的必备条件。

## 第八部分　连续动作 PPO 与机器人控制

### 29. Gaussian Policy 的对数概率与 Ratio

机器人动作通常是连续向量，例如关节位置增量、目标速度或关节力矩。典型 Actor 使用对角 Gaussian：

$$\boxed{\pi_\theta(a \mid s) = \mathcal{N}(\mu_\theta(s), \operatorname{diag}(\sigma_1^2, \dots, \sigma_n^2))}. \tag{41}$$

则联合 Log Probability 为

$$\boxed{\log \pi_\theta(a \mid s) = -\frac{1}{2} \sum_{i=1}^{n} \left[ \frac{(a_i - \mu_i)^2}{\sigma_i^2} + 2 \log \sigma_i + \log(2\pi) \right]}. \tag{42}$$

数值稳定的 Ratio 计算为

$$\boxed{r_t = \exp\left(\log \pi_\theta(a_t \mid s_t) - \log \pi_{\text{old}}(a_t \mid s_t)\right)}. \tag{43}$$

**实现重点**：先把各动作维度的 Log Probability 求和，得到整个动作向量的联合 Log Probability，再指数化算 Ratio；不能对各维 Ratio 分别 Clip 后当作标准 PPO 联合策略目标。若使用 Tanh-Squashed Gaussian，需按变量变换计算正确的 Log Probability；若环境直接将采样动作截断到硬边界，也要审慎区分 “采样动作” 和 “实际执行动作” 的密度。

### 30. Gaussian Policy 的梯度如何推动动作均值?

考虑一维固定方差模型：

$$a \sim \mathcal{N}(\mu_\theta(s), \sigma^2),$$

$$\boxed{\frac{\partial \log \pi_\theta(a \mid s)}{\partial \mu_\theta} = \frac{a - \mu_\theta(s)}{\sigma^2}}. \tag{44}$$

因此未裁剪区域的 Policy Gradient 对均值参数的主要贡献为

$$\boxed{\nabla_\theta J \propto \mathbb{E}\left[\hat{A}\frac{a - \mu_\theta(s)}{\sigma^2}\nabla_\theta \mu_\theta(s)\right]}. \tag{45}$$

当 $\hat{A} > 0$，更新推动分布均值朝采样动作移动；当 $\hat{A} < 0$，更新推动均值远离该动作。PPO 的 Clipping 再限制单个样本从此类概率变化中获得的额外收益。若 $\sigma$ 可训练，还有关于方差的梯度项。

#### 30.1 除了均值，Log Standard Deviation 怎样学习?

允许 Gaussian 的标准差可训练，令 $\eta_\theta(s) = \log \sigma_\theta(s)$。一维 Log Probability 为

$$\log \pi_\theta(a \mid s) = -\tfrac{1}{2}\left[\frac{(a - \mu_\theta(s))^2}{e^{2\eta_\theta(s)}} + 2\eta_\theta(s) + \log(2\pi)\right].$$

对均值和对数标准差分别求导：

$$\boxed{\frac{\partial \log \pi_\theta}{\partial \mu_\theta} = \frac{a - \mu_\theta}{\sigma_\theta^2}}, \qquad \boxed{\frac{\partial \log \pi_\theta}{\partial \eta_\theta} = \frac{(a - \mu_\theta)^2}{\sigma_\theta^2} - 1}.$$

未被 Clipping 截断的样本，在梯度**上升**方向给这两项乘以 $\hat{A}_t \rho_t$。对于 $\hat{A}_t > 0$，如果 $|a - \mu| > \sigma$，该样本会倾向于增加 $\log \sigma$；如果 $|a - \mu| < \sigma$，则倾向于减小 $\log \sigma$。$\hat{A}_t < 0$ 时方向相反。可见策略不是机械地 “好动作就缩小噪声”，而是同时学习概率分布的**位置和宽度**。

机器人 PPO 中常见两种参数化：

1. **State-Independent Log Std**：网络预测 $\mu_\theta(s)$，另把每个动作维度的 $\eta_i$ 当作可训练参数；在许多 Locomotion 配置中常用，结构简单。
2. **State-Dependent Log Std**：网络同时预测 $\mu_\theta(s)$ 和 $\eta_\theta(s)$；表达能力更强，但数值稳定性与训练难度可能不同。

实际可对 Log Std 设上下界，并检查策略熵和实际控制噪声。训练时从策略采样动作（通常为随机）；评估/部署时常用均值动作或等价的确定性映射，但这不是 PPO 数学要求的唯一选择。若使用 Tanh-Squashed Gaussian，密度计算需要一致地考虑相应变量变换。

### 31. 机器人 Residual PPO 示例

假设有基础轨迹跟随控制器

$$a_t^{\text{base}} = \pi_{\text{base}}(s_t),$$

另外用 PPO 学习随机残差

$$\Delta a_t \sim \pi_\theta(\cdot \mid s_t),$$

最终执行

$$\boxed{a_t = a_t^{\text{base}} + \Delta a_t}. \tag{46}$$

残差可表示关节目标位置、速度、末端位姿的修正。

此时要用**残差动作分布**计算

$$r_t = \frac{\pi_\theta(\Delta a_t \mid s_t)}{\pi_{\text{old}}(\Delta a_t \mid s_t)}.$$

如果残差经过缩放、非线性变换或安全过滤，必须明确哪些变量的密度用于策略优化、哪些是实际控制命令。PPO 不要求接触动力学可微，但需要可重复的环境 Rollout、合理奖励和足够准确的状态/价值估计。

## 第九部分　一次 PPO Iteration 的完整执行过程

### 32. 从采样到更新的十个步骤

1. **冻结旧策略**：令 $\pi_{\text{old}} = \pi_{\theta_k}$，用它采集若干 Episode 或定长 Rollout。
2. **保存采样信息**：记录 $(s_t, a_t, r_t, s_{t+1})$、终止标记、$\log \pi_{\text{old}}(a_t \mid s_t)$ 和 $V_{\text{old}}(s_t)$。
3. **计算 TD Error**：$\delta_t = r_t + \gamma V_{\text{old}}(s_{t+1}) - V_{\text{old}}(s_t)$，对真实终止进行正确 Mask。
4. **反向计算 GAE**：$\hat{A}_t = \delta_t + \gamma\lambda \hat{A}_{t+1}$，同时正确处理 Episode Boundary。
5. **计算 Critic Target**：$\hat{R}_t^\lambda = \hat{A}_t + V_{\text{old}}(s_t)$，之后固定该目标。
6. **可选标准化 Advantage**：$\tilde{A}_t = (\hat{A}_t - \mu_A)/(\sigma_A + \varepsilon_{\text{num}})$。
7. **在 Mini-batch 上计算新 Log Probability**：对于已采样的**旧动作** $a_t$，计算当前 $\log \pi_\theta(a_t \mid s_t)$。
8. **计算 Ratio 与 Clipped Actor Loss**：$r_t = \exp(\log \pi_\theta - \log \pi_{\text{old}})$，然后应用式 (21)。
9. **更新 Actor 与 Critic**：最小化联合损失或分别优化，在同一批数据上重复若干 Epoch，监测 KL、Clip Fraction、Value Loss。
10. **重新采样**：更新完毕后，用新策略生成下一批数据；不把任意久远的旧数据当作标准 On-Policy PPO 的普通 Rollout 重复训练。

#### 32.1 同一批 Rollout 中，Actor 与 Critic 的参数到底何时变化?

建议把第 32 节的十个步骤理解为两个不同的阶段：

1. **数据采样与 GAE 阶段：**环境状态、采样动作和奖励随时间变化，随后一次性计算 $\hat{A}_t$ 与 $\hat{R}_t^\lambda$。采样时的行为策略 $\pi_{\text{old}}$ 和用于形成 Target 的 $V_{\text{old}}$ 保持为固定快照。
2. **$K$ 轮 Mini-batch 优化阶段：**只更新当前 Actor 参数 $\theta$、Critic 参数 $\phi$ 以及由它们产生的新 Log Probability 和 Value。存储的旧动作、旧 Log Probability、$\hat{A}_t$、$\hat{R}_t^\lambda$ 始终不变。
3. **下一次 Rollout 阶段：**更新后的 Actor 成为新的行为策略，采集新数据；不把很久以前的旧 Rollout 当作标准 PPO 的新采样继续训练。

这样能解释一个常见混淆：在同一轮 PPO Epoch 中，**Critic 的预测可以改变，但用来训练 Critic 的回归 Target 不跟着改变**。如果训练时动态重算旧 Log Probability 或 Advantage，优化目标会不再对应于最初的旧策略快照。

### 33. 简洁且可直接改造的 PyTorch 实现

下面代码给出 PPO 核心 Actor Loss。输入`new_log_prob`、`old_log_prob` 均为**动作向量的联合** Log Probability，且旧 Log Probability 和 Advantage 在本轮更新中固定。

```
import torch

def ppo_actor_loss(new_log_prob, old_log_prob,
                   advantages, clip_eps=0.2):
    # The old log probability and advantage are fixed rollout data.
    old_log_prob = old_log_prob.detach()
    advantages = advantages.detach()

    log_ratio = new_log_prob - old_log_prob
    ratio = torch.exp(log_ratio)

    objective_unclipped = ratio * advantages
    objective_clipped = torch.clamp(
        ratio, 1.0 - clip_eps, 1.0 + clip_eps
    ) * advantages

    return -torch.minimum(
        objective_unclipped, objective_clipped
    ).mean()
```

计算 GAE 的最小后向递推如下。此示例中的`bootstrap_mask[t]` 控制 $\delta_t$ 是否使用下一状态价值；`continue_mask[t]` 控制 GAE 是否跨越此步递归，真实终止、超时与 Rollout 切分须由环境正确提供。

```
import torch

def compute_gae(rewards, values, next_values,
                bootstrap_mask, continue_mask,
                gamma=0.99, lam=0.95):
    """All tensors are indexed by rollout time."""
    T = rewards.shape[0]
    advantages = torch.zeros_like(rewards)
    running = torch.zeros_like(rewards[0])

    for t in reversed(range(T)):
        delta = (rewards[t]
                 + gamma * bootstrap_mask[t] * next_values[t]
                 - values[t])
        running = (delta
                   + gamma * lam * continue_mask[t] * running)
        advantages[t] = running

    returns = advantages + values
    return advantages, returns
```

如果使用并行环境, 这些变量可以具有形状 `[T, N_env]`；`continue_mask` 不能跨不同 Episode 串接。用于生成 `returns` 的旧 `values` 和 `next_values` 应与计算 Rollout 目标时的冻结 Critic 一致。

对于对角 Gaussian：

```
# dist: torch.distributions.Normal, action shape [batch, action_dim]
new_log_prob = dist.log_prob(actions).sum(dim=-1)
# entropy shape [batch]
entropy = dist.entropy().sum(dim=-1)
```

这段代码只展示核心公式；完整训练还需要 Rollout Buffer、环境步进、网络结构、优化器、正确的`terminated/truncated` 处理与指标记录。

### 33.1 从三种损失得到一次可反向传播的完整更新

以下补充代码只演示**已准备好一个固定 Rollout Mini-batch** 时的三个 Loss。它不替代上面的 GAE / 终止 Mask 处理，也不是完整训练包。

```
import torch

def ppo_joint_losses(actor, critic, obs, actions,
                     old_log_prob, advantages, returns,
                     clip_eps=0.2, value_coef=0.5,
                     entropy_coef=0.0):
    # actor(obs) returns [batch, action_dim] mean and log_std.
    mean, log_std = actor(obs)
    dist = torch.distributions.Independent(
        torch.distributions.Normal(mean, log_std.exp()), 1
    )
    new_log_prob = dist.log_prob(actions)
    actor_loss = ppo_actor_loss(
        new_log_prob, old_log_prob.detach(),
        advantages.detach(), clip_eps
    )
    value_pred = critic(obs).squeeze(-1)
    value_loss = 0.5 * (value_pred - returns.detach()).square().mean()
    entropy = dist.entropy().mean()
    total_loss = actor_loss + value_coef * value_loss - entropy_coef * entropy
    return total_loss, actor_loss, value_loss, entropy
```

若 Actor、Critic 参数互不共享，可以分别计算梯度并调用各自优化器；若共享 Backbone，则`total_loss.backward()`会汇总对共享参数的梯度。示例使用 `Independent(Normal, 1)` 得到动作向量的联合 Log Probability；如果网络的动作分布实现不同，必须对应调整 Density 的计算。这里的 `returns` 必须由**旧 Value + GAE** 在优化前计算。

## 第十部分　超参数与实际诊断

### 34. 常见起始超参数及其含义

| 参数 | 常见起点 | 控制什么 |
|---|---|---|
| $\gamma$ | 0.99 | 未来奖励的时间折扣 |
| GAE $\lambda$ | 0.95 | Advantage 的偏差–方差折中 |
| Clip $\epsilon$ | 0.1–0.2 | 过大 Probability Ratio 的额外代理收益 |
| Actor 学习率 | $3 \times 10^{-4}$ | Actor 优化速度 |
| PPO Epoch 数 | 3–10 | 一批旧数据的重复更新次数 |
| Target KL | 0.01–0.03 | 是否提前停止 Actor 更新 |
| Entropy 系数 | 0 或小正数 | 探索强度 |
| Value 权重 | 约 0.5 | Critic 回归损失相对权重 |

这些是便于启动实验的经验量级，不是普适最优参数。RSL-RL 等大规模并行运控实现可能使用不同学习率、Batch 尺寸、Clip 和 Epoch 设置。

**$\gamma$ 与 $\lambda$ 的根本区别**：$\gamma$ 决定优化目标如何折扣远期奖励，而 $\lambda$ 决定 Advantage 估计多大程度依赖远期采样 TD 信息。二者共同以 $(\gamma\lambda)^l$ 出现在 GAE 中，但理论角色不同。

重要诊断量还包括 Episode Return、Success Rate、Value Loss、Explained Variance、Entropy、Approximate KL、Clip Fraction、梯度范数。出现“代理 Loss 看似改善、真实成功率下降”时，应重点检查数据分布漂移、Critic 误差、KL 过大和奖励设计。

### 34.1 将诊断指标映射到 Actor–Critic 的真实学习问题

- **Value Loss 大 / Explained Variance 低：**可能是 Critic Target 噪声大、网络表达能力不足、Bootstrap 偏差或奖励尺度变化。优先核对 Return Target 与 Value 的范围、真正终止的 Mask、Value 学习率和 Normalization。
- **Actor Loss 下降，但成功率不升：**代理目标不必然等同于真实性能。应比较新 Rollout 的 Return、Approximate KL、Clip Fraction 和奖励定义，并审查 Advantage 估计的噪声。
- **Approximate KL 或 Clip Fraction 长期偏大：**通常提示在固定 Rollout 上 Actor 更新太快。检查 Actor Learning Rate、每批 PPO Epoch 数、Mini-batch 大小和 Target-KL Early Stopping。
- **Entropy 很快接近零：**检查可训练 Log Std 是否收缩过快、Log Std 的上下界、动作分布形式及 Entropy Coefficient。
- **机器人接触任务中策略抖动：**可能来自过大的探索噪声、不合适的动作尺度或控制频率；应联动检查 Action Scale、Log Std、控制周期以及关节/接触约束。

**注意两类学习率和两个时间尺度：**Actor 的学习率控制策略漂移；Critic 的学习率控制 Value 对变化中的目标的追踪速度。Critic 太慢可能损坏 GAE，太快可能导致高噪声目标下的过拟合或优化不稳定。不能仅凭 Critic Loss 数值选择两者；应同时观察性能和 KL。更多数据复用提高样本利用率，但也增加偏离采样策略的风险。

## 第十一部分　与 REINFORCE、Actor–Critic、TRPO 的关系

### 35. 算法演化：每一步解决一个问题

| 算法 | 关键公式 / 想法 | 主要动机 |
|---|---|---|
| REINFORCE | $\nabla \log \pi_\theta G$ | 不对环境求导也能优化策略 |
| Advantage Actor–Critic | $\nabla \log \pi_\theta \hat{A}$ | 用状态价值作为 Baseline 降低方差 |
| TRPO | 最大化 $\mathbb{E}[r\hat{A}]$，约束 KL | 保持代理目标在可信的局部区域 |
| PPO-Clip | $\min(r\hat{A}, \text{clip}(r)\hat{A})$ | 用简单一阶更新抑制过大概率改变的收益 |
| PPO + GAE | $\hat{A}_t = \sum_l (\gamma\lambda)^l \delta_{t+l}$ | 调节 Advantage 估计的偏差和方差 |

PPO 本质上依然是 **On-Policy Policy Gradient / Actor–Critic**。在每轮 Rollout 的初始点，它的 Clipped Objective 与普通 CPI 代理目标的一阶梯度相同；真正的区别发生在对同一批数据继续做多次更新、Probability Ratio 逐渐偏离 1 之后。

PPO 在仿真机器人控制中常见，是因为可以并行采样许多环境、训练结构简单、不要求动力学可微，且天然支持 Gaussian 连续动作。但在真实机器人上，样本采集昂贵，SAC 等 Off-Policy 算法可能更具交互样本效率。对于 Diffusion / Flow Matching Action Policy，标准 PPO 需要的显式且可计算 Log Probability 往往不易获得，通常需要专门改造。

## 第十二部分　最终公式总览与研究启示

**核心公式 1：策略梯度**

$$\nabla_\theta J \propto \mathbb{E}\left[\nabla_\theta \log \pi_\theta(a \mid s) A^\pi(s,a)\right].$$

**动机**：不必对不可微动力学反向传播。

**核心公式 2：重要性采样**

$$r_t = \pi_\theta(a_t \mid s_t)/\pi_{\text{old}}(a_t \mid s_t).$$

**动机**：在旧策略动作样本上构造新策略的局部代理目标。

**核心公式 3：TRPO 的信赖域思想**

$$\bar{D}_{\text{KL}}(\pi_{\text{old}} \| \pi_\theta) \le \delta.$$

**动机**：控制代理目标因分布变化而失真的风险。

**核心公式 4：PPO Clipped Objective**

$$\boxed{L^{\text{CLIP}} = \mathbb{E}_t \left[ \min \left( r_t \hat{A}_t, \text{clip}(r_t, 1-\epsilon, 1+\epsilon) \hat{A}_t \right) \right]}.$$

**动机**：保守限制过大概率变化能获得的代理收益，保留修正不利更新方向的梯度。

**核心公式 5：GAE**

$$\boxed{\hat{A}_t = \sum_{l \geq 0} (\gamma\lambda)^l \delta_{t+l}}, \qquad \delta_t = r_t^{\text{reward}} + \gamma V(s_{t+1}) - V(s_t).$$

**动机**：在长期样本回报和短期 Bootstrap 间进行平滑折中。这里用 $r_t^{\text{reward}}$ 区分即时奖励与 PPO 的概率比 $r_t(\theta)$。

**最终最小化损失**：

$$\boxed{\mathcal{L}_{\text{PPO}} = -L^{\text{CLIP}} + c_v \mathcal{L}_{\text{critic}} - c_e L^{\text{entropy}}}.$$

**研究层面的核心结论**：PPO 并不是一个新的环境梯度计算方法。它使用 Policy Gradient 确定局部性能改进方向，用 Importance Sampling 在旧数据上构造代理目标，用 Clipping 抑制过度优化，并用 GAE 改善 Advantage 估计。GAE 主要解决**梯度估计质量**的问题；Clipping 主要解决**策略更新稳定性**的问题。二者功能不同、相互补充。

### 参考文献与延伸阅读


1. Schulman, J. et al. (2017). *Proximal Policy Optimization Algorithms.* arXiv:1707.06347. https://arxiv.org/abs/1707.06347
2. Schulman, J. et al. (2015). *Trust Region Policy Optimization.* ICML. https://arxiv.org/abs/1502.05477
3. Schulman, J. et al. (2015). *High-Dimensional Continuous Control Using Generalized Advantage Estimation.* ICLR 2016. https://arxiv.org/abs/1506.02438
4. OpenAI Spinning Up. *PPO Documentation.* https://spinningup.openai.com/en/latest/algorithms/ppo.html


**版权与许可**：CC BY 4.0。

**代码说明**：代码片段仅用于解释算法机制，并非经过完整环境验证的可直接训练脚本。