PPO 完整推导与设计动机

课程首页 · English · PDF

项目	说明
适用范围	PPO-Clip / GAE 理论；PyTorch 风格示例为教学内容，非已测试训练包
文档核验日期	2026-10-18
许可	CC BY 4.0 · Xiong Zeng and contributors

核验边界： 文档整理与上游引用快照核对；未进行教程环境、训练或硬件验证。 版本与固定源码引用见版本说明。原创教材采用 CC BY 4.0，第三方引用、图片及代码遵循其原有许可；注明来源不等于拥有再许可权。

目录

- 第一部分　从预期回报到策略梯度
  - 1. 定义强化学习优化问题
  - 2. 利用 Log-Derivative Trick 推导 Policy Gradient
  - 3. 因果性与 Reward-to-Go
- 第二部分　Baseline、Value 与 Advantage
  - 4. 为什么可以减去 Baseline?
  - 5. 为什么使用 Value Function 作为 Baseline?
- 第三部分　性能差分、Surrogate Objective 与重要性采样
  - 6. 旧数据为什么不能无限重复使用?
  - 7. Performance Difference Lemma 的逐步证明
  - 8. 将真实性能改进近似为 Surrogate Objective
  - 9. Importance Sampling 推导 Probability Ratio
- 第四部分　TRPO：用 Trust Region 控制更新
  - 10. 直接最大化 CPI 为什么危险?
  - 11. KL Divergence 与 TRPO 约束
  - 12. TRPO 局部二阶近似与 Natural Gradient
- 第五部分　PPO-Clip 的核心推导
  - 13. 从 KL Penalty 到 Clipped Surrogate
  - 14. 正 Advantage：好动作不能无限被奖励
  - 15. 负 Advantage：坏动作也不能无限被压低
  - 16. 为什么一定要有 `min`，而不是只用 `clip`?
  - 17. 从梯度看 PPO 在何处停止更新
  - 18. PPO 不能保证 Ratio 或 KL 被硬性约束
- 第六部分　GAE：Advantage 究竟如何估计?
  - 19. Monte Carlo Advantage 的动机与代价
  - 20. 由 Bellman 方程得到 One-Step TD Advantage

    - 21. 从 One-Step 推导 N-Step Advantage
    - 22. GAE 的指数权重与求和交换推导
    - 23. GAE 的 $O(T)$ 反向递推
    - 24. 用 GAE 构造 Critic 训练目标
- 第七部分　完整 Actor–Critic 损失
    - 25. Actor Loss
    - 26. Critic Loss
    - 27. Entropy Bonus 的动机
    - 28. PPO 的最终训练目标
- 第八部分　连续动作 PPO 与机器人控制
    - 29. Gaussian Policy 的对数概率与 Ratio
    - 30. Gaussian Policy 的梯度如何推动动作均值?
    - 31. 机器人 Residual PPO 示例
- 第九部分　一次 PPO Iteration 的完整执行过程
    - 32. 从采样到更新的十个步骤
    - 33. 简洁且可直接改造的 PyTorch 实现
- 第十部分　超参数与实际诊断
    - 34. 常见起始超参数及其含义
- 第十一部分　与 REINFORCE、Actor–Critic、TRPO 的关系
    - 35. 算法演化：每一步解决一个问题
- 第十二部分　最终公式总览与研究启示
    - 参考文献与延伸阅读

第一部分　从预期回报到策略梯度

1. 定义强化学习优化问题

考虑马尔可夫决策过程（MDP）：

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, r, \gamma, \rho_0).$$

其中 $s_t \in \mathcal{S}$ 为状态，$a_t \in \mathcal{A}$ 为动作，$P(s_{t+1} \mid s_t, a_t)$ 为环境转移核，r_t 为奖励，ρ_0 是初始状态分布，$\pi_\theta(a \mid s)$ 是参数为 θ 的随机策略。学习目标是

$$\boxed{\theta^* = \arg\max_\theta J(\theta)}, \qquad \boxed{J(\theta) = \mathbb{E}_{\tau \sim p_\theta}\left[\sum_{t=0}^{\infty} \gamma^t r_t\right]}. \tag{1}$$

轨迹记为 $\tau = (s_0, a_0, s_1, a_1, \ldots)$，其折扣回报为 $R(\tau) = \sum_t \gamma^t r_t$。于是

$$J(\theta) = \int p_\theta(\tau) R(\tau)\, d\tau.$$

动机与困难：θ 首先改变动作分布，再通过环境动力学影响整条未来轨迹：

$$\theta \longrightarrow a_0 \longrightarrow s_1 \longrightarrow a_1 \longrightarrow \cdots \longrightarrow R(\tau).$$

对于碰撞、摩擦、接触切换和未知动力学，$R(\tau)$ 一般不能简单地通过环境对 θ 反向传播。因此需要一种**不要求环境动力学可微**的梯度估计方法。

2. 利用 Log-Derivative Trick 推导 Policy Gradient

对期望求梯度：

$$\nabla_\theta J(\theta) = \int \nabla_\theta p_\theta(\tau) R(\tau)\, d\tau.$$

使用恒等式

$$\boxed{\nabla_\theta p_\theta(\tau) = p_\theta(\tau) \nabla_\theta \log p_\theta(\tau)}, \tag{2}$$

得到

$$\boxed{\nabla_\theta J(\theta) = \mathbb{E}_{\tau\sim p_\theta}\left[R(\tau)\nabla_\theta \log p_\theta(\tau)\right]}. \tag{3}$$

这称为 Likelihood-Ratio / Score-Function Trick。它把**概率密度的梯度**转为**对数概率的梯度**。下一个关键点是：MDP 轨迹概率恰好可以分解。

$$p_\theta(\tau) = \rho_0(s_0) \prod_{t=0}^{\infty} \pi_\theta(a_t \mid s_t) P(s_{t+1} \mid s_t, a_t).$$

取对数并求导。如果初始分布、环境转移核不依赖 θ，则

$$\begin{aligned} \log p_\theta(\tau) &= \log \rho_0(s_0) + \sum_t \log \pi_\theta(a_t \mid s_t) + \sum_t \log P(s_{t+1} \mid s_t, a_t), \\ \boxed{\nabla_\theta \log p_\theta(\tau)} &= \boxed{\sum_t \nabla_\theta \log \pi_\theta(a_t \mid s_t)}. \end{aligned} \tag{4}$$

所以形式上有

$$\boxed{\nabla_\theta J(\theta) = \mathbb{E}\left[R(\tau) \sum_t \nabla_\theta \log \pi_\theta(a_t \mid s_t)\right]}. \tag{5}$$

这里严格处理无穷时域时需要适当的可积性与极限交换条件；也可以先在有限时域推导后取极限。

这一转换解决了什么？ 我们只需要对策略网络的 $\log \pi_\theta(a_t \mid s_t)$ 求梯度。机器人动力学和奖励仍然只用于前向采样，不必可微。

3. 因果性与 Reward-to-Go

式 (5) 的每个动作梯度都乘以整条轨迹回报。但 a_t 不能影响发生在 t 以前的奖励。利用 score function 的零均值性质，过去奖励对应的交叉项期望为零，于是可改写成

$$G_t = \sum_{k=t}^{\infty} \gamma^{k-t} r_k, \qquad \boxed{\nabla_\theta J(\theta) = \mathbb{E}\left[\sum_{t=0}^{\infty} \gamma^t \nabla_\theta \log \pi_\theta(a_t \mid s_t) G_t\right]}. \tag{6}$$

动机：对 a_t 的更新应由它能够影响的未来后果决定。去除过去奖励通常可以降低估计方差，而不改变梯度期望。式中的 γ^t 与原始折扣目标严格一致；实际 PPO 代码经常直接对采样时间步平均，属于相应采样分布下的优化约定，不应混为完全相同的无穷时域表达式。

第二部分　Baseline、Value 与 Advantage

4. 为什么可以减去 Baseline?

虽然使用 Reward-to-Go 比整条轨迹回报更合理，但 G_t 仍会因未来随机性而显著波动。考虑引入只依赖状态的 Baseline $b(s_t)$：

$$g_t = \nabla_\theta \log \pi_\theta(a_t \mid s_t)\,[G_t - b(s_t)].$$

证明它不改变策略梯度的期望：

$$\begin{aligned}
&\mathbb{E}_{a\sim\pi_\theta(\cdot|s)}[\nabla_\theta \log \pi_\theta(a \mid s) b(s)] \\
&= b(s) \int \pi_\theta(a \mid s) \nabla_\theta \log \pi_\theta(a \mid s)\, da \\
&= b(s) \int \nabla_\theta \pi_\theta(a \mid s)\, da \\
&= b(s) \nabla_\theta \int \pi_\theta(a \mid s)\, da \\
&= b(s) \nabla_\theta 1 = 0.
\end{aligned} \tag{7}$$

因此

$$\boxed{\mathbb{E}[\nabla \log \pi_\theta\, G_t] = \mathbb{E}[\nabla \log \pi_\theta\,(G_t - b(s_t))]}. \tag{8}$$

动机：去除与“当前动作相对质量”无关的整体回报水平，从而减小随机波动。要注意：不是任何 Baseline 都能保证减小方差；严格的最优方差 Baseline 通常还与 score gradient 的平方范数有关。$V^\pi(s)$ 是实用而自然的选择。

5. 为什么使用 Value Function 作为 Baseline?

定义状态价值、动作价值和优势函数：

$$\begin{aligned}
V^\pi(s) &= \mathbb{E}_\pi[G_t \mid s_t = s], \\
Q^\pi(s,a) &= \mathbb{E}_\pi[G_t \mid s_t = s, a_t = a], \\
\boxed{A^\pi(s,a)} &= \boxed{Q^\pi(s,a) - V^\pi(s)}.
\end{aligned} \tag{9}$$

$V^\pi(s)$ 衡量“从该状态按现有策略继续执行的平均回报”；$Q^\pi(s,a)$ 衡量“先执行指定动作再按策略继续执行的平均回报”。因此：

- $A^\pi(s,a) > 0$：这个动作比当前策略的平均动作更好，应倾向于提高其概率；
- $A^\pi(s,a) < 0$：这个动作比平均动作更差，应倾向于降低其概率；
- $A^\pi(s,a) = 0$：在该估计下没有相对优劣信号。

机器人示例：在同一个抓取状态，设 $V^\pi(s) = 10$。接触调整动作的 $Q = 15$，Advantage 为 $+5$；保持姿态的 $Q = 10$，Advantage 为 0；错误闭合手指的 $Q = 3$，Advantage 为 -7。PPO 学习的是这些动作**相对平均表现**的概率变化，而不是简单追求所有正奖励动作。

在准确的 Q^π, V^π 下，得到 Advantage Policy Gradient：

$$\boxed{\nabla_\theta J(\theta) = \mathbb{E}\left[\sum_t \gamma^t \nabla_\theta \log \pi_\theta(a_t \mid s_t) A^{\pi_\theta}(s_t, a_t)\right]}. \tag{10}$$

从而引出 Actor–Critic：Actor π_θ 负责产生动作；Critic V_ϕ 近似状态价值；Advantage 连接二者。使用不准确的 Value Baseline 本身不会改变理想 score-function 公式的期望，但使用自举构造 Advantage 时会引入额外估计偏差。

第三部分　性能差分、Surrogate Objective 与重要性采样

6. 旧数据为什么不能无限重复使用？

Policy Gradient 假设采样数据与当前策略一致。若使用 π_{θ_0} 采样后更新到 π_{θ_1}、π_{θ_2}，旧 Rollout 依然服从 π_{θ_0}，并不服从新策略。每次梯度步都重新采样又非常昂贵。

PPO 的目标之一是：**在一批由旧策略采集的数据上，进行多次相对安全的一阶更新**。要做到这一点，必须区分状态分布的变化和给定状态下动作分布的变化。

7. Performance Difference Lemma 的逐步证明

定义归一化折扣状态访问分布：

$$\boxed{d_\pi(s) = (1-\gamma)\sum_{t=0}^{\infty}\gamma^t \Pr(s_t = s \mid \pi)}. \tag{11}$$

对连续状态空间，上式应理解为对应概率测度/密度。对于任意新旧策略，性能差分引理给出**精确恒等式**：

$$\boxed{J(\pi_\theta) - J(\pi_{\text{old}}) = \frac{1}{1-\gamma}\mathbb{E}_{\substack{s\sim d_{\pi_\theta}\\ a\sim\pi_\theta}}[A^{\pi_{\text{old}}}(s,a)]}. \tag{12}$$

证明：由旧策略的 Bellman 方程，

$$A^{\pi_{\text{old}}}(s_t,a_t) = \mathbb{E}[r_t + \gamma V^{\pi_{\text{old}}}(s_{t+1}) - V^{\pi_{\text{old}}}(s_t) \mid s_t, a_t].$$

沿**新策略**的轨迹求折扣和：

$$\begin{aligned}&\mathbb{E}_{\pi_\theta}\left[\sum_t \gamma^t A^{\pi_{\text{old}}}(s_t,a_t)\right]\\ &= \mathbb{E}_{\pi_\theta}\left[\sum_t \gamma^t r_t + \sum_t \gamma^{t+1}V^{\pi_{\text{old}}}(s_{t+1}) - \sum_t \gamma^t V^{\pi_{\text{old}}}(s_t)\right].\end{aligned}$$

后两个级数望远镜相消，只剩 $-V^{\pi_{\text{old}}}(s_0)$（假设末端项消失），因此

$$\mathbb{E}_{\pi_\theta}\left[\sum_t \gamma^t A^{\pi_{\text{old}}}(s_t,a_t)\right] = J(\pi_\theta) - J(\pi_{\text{old}}).$$

再用 d_{π_θ} 的定义重写折扣时间求和，即得到式 (12)。

重要直觉：新策略的回报提升，等于它在自身将访问的状态、执行的动作上，取得的“相对于旧策略”的 Advantage 总和。

8. 将真实性能改进近似为 Surrogate Objective

式 (12) 的困难在于，期望中的状态来自新策略：

$$s \sim d_{\pi_\theta}.$$

但我们手上只有旧策略数据。如果新旧策略足够接近，可以作**局部近似**：

$$d_{\pi_\theta}(s) \approx d_{\pi_{\text{old}}}(s).$$

忽略正常数 $1/(1-\gamma)$ 后，定义

$$\boxed{L_{\text{sur}}(\theta) = \mathbb{E}_{\substack{s\sim d_{\pi_{\text{old}}} \\ a\sim\pi_\theta}}[A^{\pi_{\text{old}}}(s,a)]}. \tag{13}$$

它比直接优化新策略的整条轨迹分布容易得多：状态分布固定，只需要研究给定状态下动作概率的变化。在旧参数附近，准确 Advantage 对应的 Surrogate 与真实目标具有相同的一阶局部方向（差一个正常数）。

核心前提：只有当 π_θ 不远离 π_{old} 时，这种状态分布替换才比较可信。这为后面的 Trust Region 和 Clipping 提供了动机。

9. Importance Sampling 推导 Probability Ratio

式 (13) 仍然包含 $a \sim \pi_\theta$，而数据中的动作来自旧策略。给定状态 s，利用重要性采样：

$$\begin{aligned}\mathbb{E}_{a\sim\pi_\theta}[A^{\pi_{\text{old}}}(s,a)] &= \int \pi_\theta(a \mid s) A^{\pi_{\text{old}}}(s,a)\, da \\ &= \int \pi_{\text{old}}(a \mid s) \frac{\pi_\theta(a \mid s)}{\pi_{\text{old}}(a \mid s)} A^{\pi_{\text{old}}}(s,a)\, da.\end{aligned}$$

定义概率比：

$$\boxed{r_\theta(s,a) = \frac{\pi_\theta(a \mid s)}{\pi_{\text{old}}(a \mid s)}}. \tag{14}$$

于是得到 CPI（Conservative Policy Iteration）形式的代理目标：

$$\boxed{L^{\text{CPI}}(\theta) = \mathbb{E}_{\substack{s\sim d_{\pi_{\text{old}}} \\ a\sim\pi_{\text{old}}}}[r_\theta(s,a) A^{\pi_{\text{old}}}(s,a)]}. \tag{15}$$

实际估计写为 $\mathbb{E}_t[r_t(\theta)\hat{A}_t]$。

概率比的解释：若旧动作概率为 0.2、新概率为 0.3，则 $r = 1.5$；若新概率变为 0.1，则 $r = 0.5$。正 Advantage 鼓励 r 上升，负 Advantage 鼓励 r 下降。

边界与限制：上述重要性采样要求新策略对旧策略概率为零的动作不赋正概率（绝对连续性）；对于一般 Gaussian 分布，通常满足动作密度支持条件。重要性采样仅精确修正了**给定状态下的动作分布**，并未修正 d_{π_θ} 与 $d_{\pi_{\text{old}}}$ 的差异。因此，它没有消除式 (13) 的状态分布近似误差。

第四部分　TRPO：用 Trust Region 控制更新

10. 直接最大化 CPI 为什么危险?

对于正 Advantage 样本，$r_t\hat{A}_t$ 随 r_t 增长：若 $\hat{A} = 5$，$r = 1.2, 2, 10$ 对应 $6, 10, 50$。代理目标似乎鼓励无限放大好动作的概率。但这些 Advantage 是根据旧策略计算的；如果新策略改变很大，旧估计不一定再可信。

尤其在机器人操作中，动作分布的一次较大改变可能引发接触切换、掉落甚至完全不同的未来状态访问。故 L^{CPI} 增大**不保证**真实 J 增大。

11. KL Divergence 与 TRPO 约束

使用 KL Divergence 衡量同一状态下两策略的分布差异：

$$D_{\mathrm{KL}}(\pi_{\mathrm{old}}\|\pi_\theta) = \mathbb{E}_{a\sim\pi_{\mathrm{old}}}\left[\log\frac{\pi_{\mathrm{old}}(a\mid s)}{\pi_\theta(a\mid s)}\right].$$

TRPO 的实用优化形式是

$$\boxed{\begin{aligned}&\max_\theta \quad \mathbb{E}_t[r_t(\theta)\hat{A}_t]\\ &\text{s.t.} \quad \mathbb{E}_{s\sim d_{\pi_{\mathrm{old}}}}[D_{\mathrm{KL}}(\pi_{\mathrm{old}}(\cdot\mid s)\|\pi_\theta(\cdot\mid s))]\le\delta.\end{aligned}} \tag{16}$$

δ 决定信赖域大小。其动机不是“策略改变越小越好”，而是**在一个代理目标足够可信的局部区域内寻找改进**。

TRPO 的理论分析给出含有最大状态策略差异惩罚项的性能下界，典型结构为

$$J(\pi_\theta)\ge J(\pi_{\mathrm{old}})+\frac{L_{\mathrm{sur}}(\theta)}{1-\gamma}-C\max_s D_{\mathrm{KL}}(\pi_{\mathrm{old}}\|\pi_\theta), \tag{17}$$

其中 C 依赖回报/Advantage 的界和 γ；具体常数以及 KL 方向取决于采用的界。**注意**：理论中的最坏状态差异控制，强于工程实现的平均 KL 约束；实际神经网络 TRPO 不能据此保证每次更新单调提升。

12. TRPO 局部二阶近似与 Natural Gradient

令 $\Delta\theta=\theta-\theta_{\mathrm{old}}$。在旧参数附近进行泰勒展开：

$$L^{\mathrm{CPI}}(\theta)\approx L^{\mathrm{CPI}}(\theta_{\mathrm{old}})+g^\top\Delta\theta,\quad g=\nabla_\theta L^{\mathrm{CPI}}\big|_{\theta_{\mathrm{old}}}.$$

KL 在相同策略处为零且一阶梯度为零，二阶近似为

$$\bar{D}_{\mathrm{KL}}\approx\tfrac{1}{2}\Delta\theta^\top F\Delta\theta,$$

其中 F 是在旧参数处计算的 Fisher 信息矩阵。为避免歧义，先定义 $u_{\mathrm{old}}(s,a)=\nabla_\theta\log\pi_\theta(a\mid s)|_{\theta=\theta_{\mathrm{old}}}$，则

$$F=\mathbb{E}_{s\sim d_{\pi_{\mathrm{old}}},\,a\sim\pi_{\mathrm{old}}}[u_{\mathrm{old}}(s,a)u_{\mathrm{old}}(s,a)^\top].$$

局部问题变成

$$\boxed{\max_{\Delta\theta} g^\top\Delta\theta \quad \text{s.t.} \quad \tfrac{1}{2}\Delta\theta^\top F\Delta\theta\le\delta.} \tag{18}$$

写出 Lagrangian：

$$\mathcal{L}(\Delta\theta,\eta)=g^\top\Delta\theta-\eta\big(\tfrac{1}{2}\Delta\theta^\top F\Delta\theta-\delta\big).$$

一阶条件 $g-\eta F\Delta\theta=0$ 导致 $\Delta\theta=\eta^{-1}F^{-1}g$。代入活动约束（假设 F 正定、$g\neq0$）得

$$\boxed{\Delta\theta^*=\sqrt{\frac{2\delta}{g^\top F^{-1}g}}F^{-1}g.} \tag{19}$$

方向 $F^{-1}g$ 正是 Natural Policy Gradient 的核心形式。实际训练不能显式反演一个巨大矩阵，因此需要 Fisher-vector product、共轭梯度、线搜索等技术；非正定或病态情况下还需阻尼。**PPO 的设计动机**：保留保守策略更新的思想，但避免 TRPO 的复杂二阶/约束优化。

第五部分　PPO-Clip 的核心推导

13. 从 KL Penalty 到 Clipped Surrogate

最直接的一阶化方式是 PPO-Penalty：

$$L^{\mathrm{KLPEN}}(\theta)=\mathbb{E}_t[r_t(\theta)\hat{A}_t]-\beta\,\mathbb{E}_t[D_{\mathrm{KL}}(\pi_{\mathrm{old}}\|\pi_\theta)]. \tag{20}$$

但 β 太小会限制不足，太大则更新过慢，还需要调整罚系数。PPO-Clip 改为限制“过大的概率比带来的额外目标收益”。设

$$\mathrm{clip}(r,1-\epsilon,1+\epsilon)=\min\{1+\epsilon,\max\{r,1-\epsilon\}\}.$$

最常用的 PPO 目标为

$$\boxed{L^{\mathrm{CLIP}}(\theta)=\mathbb{E}_t\Big[\min\Big(r_t(\theta)\hat{A}_t,\mathrm{clip}(r_t(\theta),1-\epsilon,1+\epsilon)\hat{A}_t\Big)\Big]}. \tag{21}$$

常见起点为 $\epsilon=0.1\sim0.2$，但应当根据环境、动作维度和监测的 KL 调整。**这里的 `min` 与 `clip` 必须一起理解**。

14. 正 Advantage：好动作不能无限被奖励

若 $\hat{A}_t>0$，希望提高该动作概率，即使 $r_t>1$。式 (21) 化简为

$$\boxed{L_t^{\mathrm{CLIP}}=\min(r_t,1+\epsilon)\hat{A}_t=\begin{cases}r_t\hat{A}_t, & r_t\le 1+\epsilon,\\(1+\epsilon)\hat{A}_t, & r_t>1+\epsilon.\end{cases}} \tag{22}$$

设 $\hat{A}_t=2,\epsilon=0.2$：

r_t	原始 $r_t\hat{A}_t$	PPO 目标
0.8	1.6	1.6
1.0	2.0	2.0
1.1	2.2	2.2
1.2	2.4	2.4
1.5	3.0	2.4
2.0	4.0	2.4

当 $r_t>1.2$ 时，这个样本不再因为概率继续上升而增加代理目标，梯度在此方向上为零。**设计动机**：避免对看起来“好”的旧策略样本过度提高概率。

15. 负 Advantage：坏动作也不能无限被压低

若 $\hat{A}_t<0$，希望降低动作概率，即降低 r_t。由于乘以负数会反转大小关系，

$$\boxed{L_t^{\mathrm{CLIP}}=\max(r_t,1-\epsilon)\hat{A}_t=\begin{cases}(1-\epsilon)\hat{A}_t, & r_t<1-\epsilon,\\r_t\hat{A}_t, & r_t\ge 1-\epsilon.\end{cases}} \tag{23}$$

设 $\hat{A}_t = -2, \epsilon = 0.2$:

r_t	原始 $r_t\hat{A}_t$	PPO 目标
0.5	-1.0	-1.6
0.7	-1.4	-1.6
0.8	-1.6	-1.6
1.0	-2.0	-2.0
1.2	-2.4	-2.4
1.5	-3.0	-3.0

PPO 最大化目标，因此负 Advantage 时降低 r 有利；但当 $r < 0.8$ 时不再额外奖励进一步压低该动作的概率。

16. 为什么一定要有 `min`，而不是只用 `clip`?

假设只有 $\text{clip}(r, 1-\epsilon, 1+\epsilon)\hat{A}$。若 $\hat{A} > 0$、$r = 0.5$、$\epsilon = 0.2$，说明好动作的概率已经被错误地大幅降低，但单独的 `clip` 会输出 $0.8\hat{A}$，在 $r < 0.8$ 区域梯度为零，无法纠正错误方向。

加入 `min` 后，由于 $r\hat{A} < 0.8\hat{A}$，实际使用原始项 $r\hat{A}$，因此仍有正梯度推动 r 回升。负 Advantage 下的错误方向同理。

更新方向正确但幅度过大：	停止提供额外优化收益；
更新方向不利于 Advantage：	保留纠偏梯度。

而且由 $\min(x, y) \le x$，逐样本成立 $L^{\text{CLIP}} \le L^{\text{CPI}}$：这是对**未裁剪代理目标**的保守下界，**不等于对真实回报 J 的严格下界**。

17. 从梯度看 PPO 在何处停止更新

因为旧策略分母在本次优化中不变,

$$\boxed{\nabla_\theta r_t(\theta) = r_t(\theta)\nabla_\theta \log \pi_\theta(a_t \mid s_t)}. \tag{24}$$

忽略折点处的不可微性（优化器采用次梯度），单样本梯度为

$$\boxed{\nabla_\theta L_t^{\text{CLIP}} = \begin{cases} 0, & \hat{A}_t > 0,\ r_t > 1+\epsilon, \\ 0, & \hat{A}_t < 0,\ r_t < 1-\epsilon, \\ \hat{A}_t r_t \nabla_\theta \log \pi_\theta(a_t \mid s_t), & \text{其余区域.} \end{cases}} \tag{25}$$

当 $\theta = \theta_{\text{old}}$，$r_t = 1$，因此初始局部梯度与 CPI/Advantage Policy Gradient 一致（差相应归一化常数）。**PPO 不改变初始策略改进方向，而是在重复更新、概率比逐渐偏离 1 时抑制过大更新收益**。

18. PPO 不能保证 Ratio 或 KL 被硬性约束

$\epsilon = 0.2$ **不意味着**更新后始终有 $0.8 \le r_t \le 1.2$。Clipping 修改的是损失，而不是把策略投影到可行集合。共享神经网络参数会同时影响其他状态和样本；多个 Mini-batch Epoch 后，平均 KL 依然可能过大。

因此常在训练中监测

$$\bar{D}_{\mathrm{KL}}(\pi_{\mathrm{old}} \| \pi_\theta)$$

并使用 Target-KL Early Stopping，必要时结合学习率调整、Gradient Clipping。需要分清三种裁剪：**Ratio Clipping** 控制代理收益；**Gradient Clipping** 控制梯度范数；**Action Clipping** 限制真实执行动作范围。三者不是一回事。

第六部分　GAE：Advantage 究竟如何估计?

19. Monte Carlo Advantage 的动机与代价

PPO 中使用的 $\hat{A}_t$ 不是凭空给定。按定义 $A^\pi = Q^\pi - V^\pi$，最直接的方法是把样本回报 G_t 作为 Q^π 的样本估计：

$$\boxed{\hat{A}_t^{\mathrm{MC}} = G_t - V_\phi(s_t)}, \qquad G_t = \sum_{l=0}^{T-t-1} \gamma^l r_{t+l}. \tag{26}$$

对完整终止轨迹，在正确策略分布下，G_t 的条件期望等于 $Q^\pi(s_t, a_t)$。它不需要用 Critic 对未来进行自举，因此目标相对直接。然而，如果抓取任务直到第 100 步成功才给出奖励，早期动作的 G_t 会受到大量后续随机因素影响，梯度方差可能很大。

问题：能否尽早利用较少步数的信息估计 Advantage，而不依赖整条未来轨迹?

20. 由 Bellman 方程得到 One-Step TD Advantage

Bellman 关系为

$$Q^\pi(s_t, a_t) = \mathbb{E}[r_t + \gamma V^\pi(s_{t+1}) \mid s_t, a_t].$$

因此，一步 TD Residual：

$$\boxed{\delta_t = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t)} \tag{27}$$

可用作 Advantage 估计：

$$\boxed{\hat{A}_t^{(1)} = \delta_t}. \tag{28}$$

它只需要一个转移样本 s_t, a_t, r_t, s_{t+1}。未来随机回报被 $V_\phi(s_{t+1})$ 代替，通常可以降低方差；代价是 Critic 不准确时会引入自举偏差。对于真正终止状态，未来价值为零；对于人为时间截断，则通常仍需 Bootstrap。

估计器	主要优点	主要缺点
Monte Carlo	减少未来价值自举偏差	长期回报导致高方差
One-Step TD	方差较低、反馈及时	更依赖 Critic 的预测准确性

21. 从 One-Step 推导 N-Step Advantage

一步估计：

$$\hat{A}_t^{(1)} = r_t + \gamma V(s_{t+1}) - V(s_t) = \delta_t.$$

两步估计：

$$
\begin{aligned}
\hat{A}_t^{(2)} &= r_t + \gamma r_{t+1} + \gamma^2 V(s_{t+2}) - V(s_t) \\
&= [r_t + \gamma V(s_{t+1}) - V(s_t)] \\
&\quad + \gamma[r_{t+1} + \gamma V(s_{t+2}) - V(s_{t+1})] \\
&= \boxed{\delta_t + \gamma \delta_{t+1}}.
\end{aligned}
\tag{29}
$$

三步估计同理：

$$
\hat{A}_t^{(3)} = \delta_t + \gamma \delta_{t+1} + \gamma^2 \delta_{t+2}.
$$

推广到 n 步：

$$
\boxed{\hat{A}_t^{(n)} = \sum_{l=0}^{n-1} \gamma^l \delta_{t+l}}.
\tag{30}
$$

较小 n 更多依赖 Value Bootstrap，较大 n 更多依赖真实未来奖励。**GAE 的出发点**：不要在单一的 n 上做硬选择，而是平滑组合多个 N-Step 估计器。

22. GAE 的指数权重与求和交换推导

令 $0 \le \lambda < 1$，定义

$$
\boxed{\hat{A}_t^{\mathrm{GAE}(\gamma,\lambda)} = (1-\lambda) \sum_{n=1}^{\infty} \lambda^{n-1} \hat{A}_t^{(n)}}.
\tag{31}
$$

这里权重总和为 1：$(1-\lambda)\sum_{n\ge 1}\lambda^{n-1} = 1$。代入 N-Step 形式：

$$
\begin{aligned}
\hat{A}_t^{\mathrm{GAE}} &= (1-\lambda) \sum_{n=1}^{\infty} \lambda^{n-1} \sum_{l=0}^{n-1} \gamma^l \delta_{t+l} \\
&= \sum_{l=0}^{\infty} \gamma^l \delta_{t+l} (1-\lambda) \sum_{n=l+1}^{\infty} \lambda^{n-1} \\
&= \sum_{l=0}^{\infty} \gamma^l \delta_{t+l} \lambda^l.
\end{aligned}
$$

因此：

$$
\boxed{\hat{A}_t^{\mathrm{GAE}(\gamma,\lambda)} = \sum_{l=0}^{\infty} (\gamma\lambda)^l \delta_{t+l}}.
\tag{32}
$$

也就是：

$$
\hat{A}_t = \delta_t + \gamma\lambda\delta_{t+1} + (\gamma\lambda)^2 \delta_{t+2} + \cdots.
$$

两个极端：$\lambda = 0$ 时只剩 δ_t，即 One-Step TD；$\lambda \to 1$ 时趋于所有后续 TD Residual 之和。对于完整终止轨迹，$\lambda = 1$ 对应 $G_t - V(s_t)$。实用 PPO 常把 $\gamma = 0.99, \lambda = 0.95$ 作为起点。

GAE 并非数学上保证任何情况下方差都更低。它提供可调的偏差—方差折中：λ 较小通常更依赖 Critic，λ 较大通常更依赖长期采样回报。

23. GAE 的 $O(T)$ 反向递推

式 (32) 具有递归结构：

$$\boxed{\hat{A}_t = \delta_t + \gamma\lambda\hat{A}_{t+1}}. \tag{33}$$

若 $d_t = 1$ 表示 MDP 在该步真正终止：

$$\boxed{\begin{aligned}\delta_t &= r_t + \gamma(1-d_t)V_\phi(s_{t+1}) - V_\phi(s_t),\\ \hat{A}_t &= \delta_t + \gamma\lambda(1-d_t)\hat{A}_{t+1}.\end{aligned}} \tag{34}$$

这样从 $T-1$ 向前循环一次就能完成全部计算，复杂度为 $O(T)$。固定长度 Rollout 的最后一个状态若并未真正终止，应使用 $V(s_T)$ Bootstrap；而递归不能跨越一次 Episode Reset 错误地把下一条 Episode 的 Advantage 累加进来。实现时应区分 **terminated（真实终止）**、**truncated（外部时间限制）**和 **Rollout Boundary（采样段边界）**。

24. 用 GAE 构造 Critic 训练目标

GAE 给出 Advantage 估计：

$$\hat{A}_t \approx Q^{\pi_{\text{old}}}(s_t, a_t) - V_{\text{old}}(s_t).$$

自然定义 TD(λ) Return：

$$\boxed{\hat{R}_t^\lambda = \hat{A}_t^{\text{GAE}} + V_{\phi_{\text{old}}}(s_t)}. \tag{35}$$

这里 $V_{\phi_{\text{old}}}$ 是计算这一批 Rollout 目标时保存的旧 Value，整个 PPO 更新阶段必须视为常量。这一技巧让 Actor 的 Advantage 估计与 Critic 的回归目标保持一致。

第七部分　完整 Actor–Critic 损失

25. Actor Loss

本轮旧策略 Rollout 上，先计算并固定 $\hat{A}_t$（实践中经常标准化）。Actor 最大化

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t\left[\min\left(r_t\hat{A}_t, \text{clip}(r_t, 1-\epsilon, 1+\epsilon)\hat{A}_t\right)\right].$$

在 PyTorch 等以最小化为接口的框架中：

$$\boxed{\mathcal{L}_{\text{actor}} = -L^{\text{CLIP}}}. \tag{36}$$

如果 $\hat{A}_t$ 通过当前可训练 Critic 的计算图产生，应在 Actor Loss 中对其 `detach`，避免无意把 Actor 更新传播到 Advantage 目标。

26. Critic Loss

Critic 通过回归 $\hat{R}_t^\lambda$ 学习状态价值：

$$\boxed{\mathcal{L}_{\text{critic}}(\phi) = \mathbb{E}_t[(V_\phi(s_t) - \hat{R}_t^\lambda)^2]}. \tag{37}$$

也可以直接回归 Monte Carlo Return。某些实现另设 Value Clipping 或 $\frac{1}{2}$ 系数，但它们不是 PPO-Clip 目标的必要组成。Critic 过差会导致 Advantage 的符号或量级不准确，因此 PPO 的训练稳定性很大程度依赖 Value Function 的估计质量。

27. Entropy Bonus 的动机

策略可能过早收缩到狭窄动作分布，停止尝试其他抓取方式。使用策略熵

$$\boxed{H(\pi_\theta(\cdot \mid s)) = -\mathbb{E}_{a\sim\pi_\theta}[\log \pi_\theta(a \mid s)]}. \tag{38}$$

鼓励合理探索。其平均值记为 $L^{\text{entropy}} = \mathbb{E}_t[H(\pi_\theta(\cdot \mid s_t))]$。高熵并不总是更好，尤其是机器人部署阶段；Entropy Coefficient 可能取零，也可能随训练退火。

28. PPO 的最终训练目标

把 Actor、Critic、Entropy 组合，得到一个常见的联合最大化目标：

$$\boxed{L^{\text{PPO}}(\theta, \phi) = L^{\text{CLIP}}(\theta) - c_v \mathcal{L}_{\text{critic}}(\phi) + c_e L^{\text{entropy}}(\theta)}. \tag{39}$$

对应的**最小化**形式为

$$\boxed{\mathcal{L}_{\text{total}} = -L^{\text{CLIP}} + c_v \mathcal{L}_{\text{critic}} - c_e L^{\text{entropy}}}. \tag{40}$$

- c_v：控制 Value 回归损失权重；
- c_e：控制 Entropy Bonus 权重；
- 独立 Actor 与 Critic 参数时可分别更新；共享网络时需要考虑梯度耦合。

常见实现对每个训练 Mini-batch 做多轮更新，但旧 Log Probability、Advantage 和 Return Target 在该 Rollout 的 PPO Epoch 内保持固定。

第八部分　连续动作 PPO 与机器人控制

29. Gaussian Policy 的对数概率与 Ratio

机器人动作通常是连续向量，例如关节位置增量、目标速度或关节力矩。典型 Actor 使用对角 Gaussian：

$$\boxed{\pi_\theta(a \mid s) = \mathcal{N}(\mu_\theta(s), \operatorname{diag}(\sigma_1^2, \dots, \sigma_n^2))}. \tag{41}$$

则联合 Log Probability 为

$$\boxed{\log \pi_\theta(a \mid s) = -\frac{1}{2} \sum_{i=1}^{n} \left[\frac{(a_i - \mu_i)^2}{\sigma_i^2} + 2 \log \sigma_i + \log(2\pi) \right]}. \tag{42}$$

数值稳定的 Ratio 计算为

$$\boxed{r_t = \exp\left(\log \pi_\theta(a_t \mid s_t) - \log \pi_{\text{old}}(a_t \mid s_t)\right)}. \tag{43}$$

实现重点：先把各动作维度的 Log Probability 求和，得到整个动作向量的联合 Log Probability，再指数化算 Ratio；不能对各维 Ratio 分别 Clip 后当作标准 PPO 联合策略目标。若使用 Tanh-Squashed Gaussian，需按

变量变换计算正确的 Log Probability；若环境直接将采样动作截断到硬边界，也要审慎区分“采样动作”和“实际执行动作”的密度。

30. Gaussian Policy 的梯度如何推动动作均值?

考虑一维固定方差模型：

$$a \sim \mathcal{N}(\mu_\theta(s), \sigma^2),$$

$$\boxed{\frac{\partial \log \pi_\theta(a \mid s)}{\partial \mu_\theta} = \frac{a - \mu_\theta(s)}{\sigma^2}}. \tag{44}$$

因此未裁剪区域的 Policy Gradient 对均值参数的主要贡献为

$$\boxed{\nabla_\theta J \propto \mathbb{E}\left[\hat{A}\frac{a - \mu_\theta(s)}{\sigma^2}\nabla_\theta \mu_\theta(s)\right]}. \tag{45}$$

当 $\hat{A} > 0$，更新推动分布均值朝采样动作移动；当 $\hat{A} < 0$，更新推动均值远离该动作。PPO 的 Clipping 再限制单个样本从此类概率变化中获得的额外收益。若 σ 可训练，还有关于方差的梯度项。

31. 机器人 Residual PPO 示例

假设有基础轨迹跟随控制器

$$a_t^{\text{base}} = \pi_{\text{base}}(s_t),$$

另外用 PPO 学习随机残差

$$\Delta a_t \sim \pi_\theta(\cdot \mid s_t),$$

最终执行

$$\boxed{a_t = a_t^{\text{base}} + \Delta a_t}. \tag{46}$$

残差可表示关节目标位置、速度、末端位姿或手指闭合动作的修正。在抓取并旋转螺丝刀任务中，基础轨迹负责大体动作，PPO Residual 学习补偿接触位置误差、初始姿态扰动、摩擦系数变化和抓取滑动。

此时要用**残差动作分布**计算

$$r_t = \frac{\pi_\theta(\Delta a_t \mid s_t)}{\pi_{\text{old}}(\Delta a_t \mid s_t)}.$$

如果残差经过缩放、非线性变换或安全过滤，必须明确哪些变量的密度用于策略优化、哪些是实际控制命令。PPO 不要求接触动力学可微，但需要可重复的环境 Rollout、合理奖励和足够准确的状态/价值估计。

第九部分　一次 PPO Iteration 的完整执行过程

32. 从采样到更新的十个步骤

1. **冻结旧策略**：令 $\pi_{\text{old}} = \pi_{\theta_k}$，用它采集若干 Episode 或定长 Rollout。
2. **保存采样信息**：记录 (s_t, a_t, r_t, s_{t+1})、终止标记、$\log \pi_{\text{old}}(a_t \mid s_t)$ 和 $V_{\text{old}}(s_t)$。

3. **计算 TD Error**：$\delta_t = r_t + \gamma V_{\text{old}}(s_{t+1}) - V_{\text{old}}(s_t)$，对真实终止进行正确 Mask。
4. **反向计算 GAE**：$\hat{A}_t = \delta_t + \gamma\lambda\hat{A}_{t+1}$，同时正确处理 Episode Boundary。
5. **计算 Critic Target**：$\hat{R}_t^{\lambda} = \hat{A}_t + V_{\text{old}}(s_t)$，之后固定该目标。
6. **可选标准化 Advantage**：$\tilde{A}_t = (\hat{A}_t - \mu_A)/(\sigma_A + \varepsilon_{\text{num}})$。
7. **在 Mini-batch 上计算新 Log Probability**：对于已采样的**旧动作** a_t，计算当前 $\log \pi_\theta(a_t \mid s_t)$。
8. **计算 Ratio 与 Clipped Actor Loss**：$r_t = \exp(\log \pi_\theta - \log \pi_{\text{old}})$，然后应用式 (21)。
9. **更新 Actor 与 Critic**：最小化联合损失或分别优化，在同一批数据上重复若干 Epoch，监测 KL、Clip Fraction、Value Loss。
10. **重新采样**：更新完毕后，用新策略生成下一批数据；不把任意久远的旧数据当作标准 On-Policy PPO 的普通 Rollout 重复训练。

33. 简洁且可直接改造的 PyTorch 实现

下面代码给出 PPO 核心 Actor Loss。输入 `new_log_prob`、`old_log_prob` 均为**动作向量的联合** Log Probability，且旧 Log Probability 和 Advantage 在本轮更新中固定。

```
import torch


def ppo_actor_loss(new_log_prob, old_log_prob,
                   advantages, clip_eps=0.2):
    # The old log probability and advantage are fixed rollout data.
    old_log_prob = old_log_prob.detach()
    advantages = advantages.detach()

    log_ratio = new_log_prob - old_log_prob
    ratio = torch.exp(log_ratio)

    objective_unclipped = ratio * advantages
    objective_clipped = torch.clamp(
        ratio, 1.0 - clip_eps, 1.0 + clip_eps
    ) * advantages

    return -torch.minimum(
        objective_unclipped, objective_clipped
    ).mean()
```

计算 GAE 的最小后向递推如下。此示例中的 `bootstrap_mask[t]` 控制 δ_t 是否使用下一状态价值；`continue_mask[t]` 控制 GAE 是否跨越此步递归，真实终止、超时与 Rollout 切分须由环境正确提供。

```
import torch


def compute_gae(rewards, values, next_values,
                bootstrap_mask, continue_mask,
                gamma=0.99, lam=0.95):
    """All tensors are indexed by rollout time."""
    T = rewards.shape[0]
    advantages = torch.zeros_like(rewards)
    running = torch.zeros_like(rewards[0])

    for t in reversed(range(T)):
        delta = (rewards[t]
                 + gamma * bootstrap_mask[t] * next_values[t]
                 - values[t])
        running = (delta
```

```
                    + gamma * lam * continue_mask[t] * running)
        advantages[t] = running

    returns = advantages + values
    return advantages, returns
```

如果使用并行环境，这些变量可以具有形状 `[T, N_env]`；`continue_mask` 不能跨不同 Episode 串接。用于生成 `returns` 的旧 `values` 和 `next_values` 应与计算 Rollout 目标时的冻结 Critic 一致。

对于对角 Gaussian：

```
# dist: torch.distributions.Normal, action shape [batch, action_dim]
new_log_prob = dist.log_prob(actions).sum(dim=-1)
# entropy shape [batch]
entropy = dist.entropy().sum(dim=-1)
```

这段代码只展示核心公式；完整训练还需要 Rollout Buffer、环境步进、网络结构、优化器、正确的 `terminated/truncated` 处理与指标记录。

第十部分　超参数与实际诊断

34. 常见起始超参数及其含义

参数	常见起点	控制什么
γ	0.99	未来奖励的时间折扣
GAE λ	0.95	Advantage 的偏差–方差折中
Clip ϵ	0.1–0.2	过大 Probability Ratio 的额外代理收益
Actor 学习率	3×10^{-4}	Actor 优化速度
PPO Epoch 数	3–10	一批旧数据的重复更新次数
Target KL	0.01–0.03	是否提前停止 Actor 更新
Entropy 系数	0 或小正数	探索强度
Value 权重	约 0.5	Critic 回归损失相对权重

这些是便于启动实验的经验量级，不是普适最优参数。RSL-RL 等大规模并行运控实现可能使用不同学习率、Batch 尺寸、Clip 和 Epoch 设置。

γ 与 λ 的根本区别：γ 决定优化目标如何折扣远期奖励，而 λ 决定 Advantage 估计多大程度依赖远期采样 TD 信息。二者共同以 $(\gamma\lambda)^l$ 出现在 GAE 中，但理论角色不同。

重要诊断量还包括 Episode Return、Success Rate、Value Loss、Explained Variance、Entropy、Approximate KL、Clip Fraction、梯度范数。出现“代理 Loss 看似改善、真实成功率下降”时，应重点检查数据分布漂移、Critic 误差、KL 过大和奖励设计。

第十一部分　与 REINFORCE、Actor–Critic、TRPO 的关系

35. 算法演化：每一步解决一个问题

算法	关键公式 / 想法	主要动机
REINFORCE	$\nabla \log \pi_\theta G$	不对环境求导也能优化策略
Advantage Actor–Critic	$\nabla \log \pi_\theta \hat{A}$	用状态价值作为 Baseline 降低方差
TRPO	最大化 $\mathbb{E}[r\hat{A}]$，约束 KL	保持代理目标在可信的局部区域
PPO-Clip	$\min(r\hat{A}, \text{clip}(r)\hat{A})$	用简单一阶更新抑制过大概率改变的收益
PPO + GAE	$\hat{A}_t = \sum_l (\gamma\lambda)^l \delta_{t+l}$	调节 Advantage 估计的偏差和方差

PPO 本质上依然是 **On-Policy Policy Gradient / Actor–Critic**。在每轮 Rollout 的初始点，它的 Clipped Objective 与普通 CPI 代理目标的一阶梯度相同；真正的区别发生在对同一批数据继续做多次更新、Probability Ratio 逐渐偏离 1 之后。

PPO 在仿真机器人控制中常见，是因为可以并行采样许多环境、训练结构简单、不要求动力学可微，且天然支持 Gaussian 连续动作。但在真实机器人上，样本采集昂贵，SAC 等 Off-Policy 算法可能更具交互样本效率。对于 Diffusion / Flow Matching Action Policy，标准 PPO 需要的显式且可计算 Log Probability 往往不易获得，通常需要专门改造。

第十二部分　最终公式总览与研究启示

核心公式 1：策略梯度

$$\nabla_\theta J \propto \mathbb{E}\left[\nabla_\theta \log \pi_\theta(a \mid s) A^\pi(s,a)\right].$$

动机：不必对不可微动力学反向传播。

核心公式 2：重要性采样

$$r_t = \pi_\theta(a_t \mid s_t) / \pi_{\text{old}}(a_t \mid s_t).$$

动机：在旧策略动作样本上构造新策略的局部代理目标。

核心公式 3：TRPO 的信赖域思想

$$\bar{D}_{\text{KL}}(\pi_{\text{old}} \| \pi_\theta) \le \delta.$$

动机：控制代理目标因分布变化而失真的风险。

核心公式 4：PPO Clipped Objective

$$\boxed{L^{\text{CLIP}} = \mathbb{E}_t\left[\min\left(r_t\hat{A}_t, \text{clip}(r_t, 1-\epsilon, 1+\epsilon)\hat{A}_t\right)\right]}.$$

动机：保守限制过大概率变化能获得的代理收益，保留修正不利更新方向的梯度。

核心公式 5：GAE

$$\boxed{\hat{A}_t = \sum_{l \ge 0} (\gamma\lambda)^l \delta_{t+l}}, \qquad \delta_t = r_t^{\text{reward}} + \gamma V(s_{t+1}) - V(s_t).$$

动机：在长期样本回报和短期 Bootstrap 间进行平滑折中。这里用 r_t^{reward} 区分即时奖励与 PPO 的概率比 $r_t(\theta)$。

最终最小化损失：

$$\boxed{\mathcal{L}_{\text{PPO}} = -L^{\text{CLIP}} + c_v \mathcal{L}_{\text{critic}} - c_e L^{\text{entropy}}}.$$

> **研究层面的核心结论**：PPO 并不是一个新的环境梯度计算方法。它使用 Policy Gradient 确定局部性能改进方向，用 Importance Sampling 在旧数据上构造代理目标，用 Clipping 抑制过度优化，并用 GAE 改善 Advantage 估计。GAE 主要解决**梯度估计质量**的问题；Clipping 主要解决**策略更新稳定性**的问题。二者功能不同、相互补充。

参考文献与延伸阅读

1. Schulman, J. et al. (2017). *Proximal Policy Optimization Algorithms*. arXiv:1707.06347. https://arxiv.org/abs/1707.06347
2. Schulman, J. et al. (2015). *Trust Region Policy Optimization*. ICML. https://arxiv.org/abs/1502.05477
3. Schulman, J. et al. (2015). *High-Dimensional Continuous Control Using Generalized Advantage Estimation*. ICLR 2016. https://arxiv.org/abs/1506.02438
4. OpenAI Spinning Up. *PPO Documentation*. https://spinningup.openai.com/en/latest/algorithms/ppo.html

---

编写说明：正文基于前述完整 PPO 推导整理，补充了重要性采样支持条件、折扣占用分布的严格记号、PPO-Clip 并非硬约束、以及 Rollout 截断与真实终止的区别。