具身基础模型的强化学习后训练

2026 年 10 月 19 日

目录

1. 研究对象：已经预训练的生成式机器人策略 1
2. 按“更新哪里”组织后训练方法 2
3. 三个必须分开的分类维度 2
4. 直接更新基础生成器 3
5. 冻结基础生成器、训练额外模块 3
6. Actor–Critic 与 Online Off-policy 后训练闭环 4
7. 一张表选方法 4
8. 评估、部署与常见误区 5
9. 目前的具身 RL 后训练基础设施（2026 年 10 月） 5
10. 尚未解决的关键问题 6
11. 原论文、项目和扩展阅读 7

Reinforcement Learning Post-Training for Embodied Foundation Models ·基础设施与开放问题增补版（2026-10）

课程仓库 ·原版中文讲义

> **课程定位**：解释如何利用强化学习改进**已经预训练的** Diffusion Policy、Flow Matching Policy 与 VLA，包括算法接口、训练系统、真机闭环与尚未解决的问题。PPO / SAC 只保留必要概念；不讨论从零训练控制器，也不包含实验代码。本文按截至 2026 年 10 月 19 日可公开核验的资料整理；列出系统支持不等于保证任意“模型 × 算法 × 机器人”组合都可直接运行。
>
> **署名与依据**：基于 Xiong Zeng and contributors 的 Foundation of Embodied AI 教学资料增补（CC BY 4.0）。具体系统能力依据官方文档，研究结论依据原论文；本文不声称独立复现或真机验证。

1. 研究对象：已经预训练的生成式机器人策略

模仿学习为机器人提供基本动作能力；RL 后训练进一步利用奖励和交互数据改善成功率、操作精度、失败恢复以及执行效率。这里讨论的是**从一个已有预训练策略开始**，而非从头训练策略。

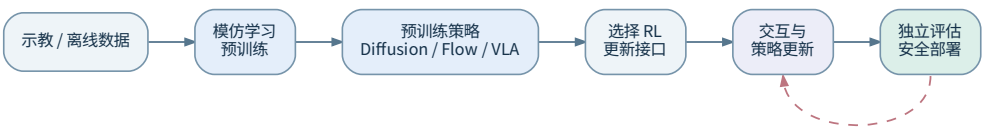


图 *1*：预训练策略是 *RL* 后训练的起点，独立评估与安全约束不应被训练目标替代。

令 o_t 表示观测，g_t 表示目标或语言指令，A_t 表示长度为 H 的动作块：

$$\pi_{\theta_0}(A_t \mid o_t, g_t), \qquad A_t = (a_t, \dots, a_{t+H-1}).$$

其中 θ_0 是预训练参数。Diffusion / Flow 生成器一般通过迭代式采样产生连续动作；VLA 还可能包含视觉语言骨干和独立的 Action Expert。经典 RL 目标为

$$J(\pi) = \mathbb{E}_{\tau\sim\pi}\left[\sum_{t=0}^{T}\gamma^t r_t\right].$$

后训练的特殊要求是：在优化奖励时，尽可能保留原先的泛化能力。对隐式生成策略，**不能默认可精确计算 $\log \pi(A \mid o, g)$ 或两个策略的 KL 散度**；这正是许多新方法必须修改策略更新接口的根本原因。

2. 按“更新哪里”组织后训练方法

最清晰的教学主线是两类：**直接更新预训练生成器**，以及**冻结生成器、训练外部适配模块**。二者并非严格互斥：例如 LoRA 只更新部分生成器参数，另一些系统同时训练残差模块与少量 Action Expert 参数。

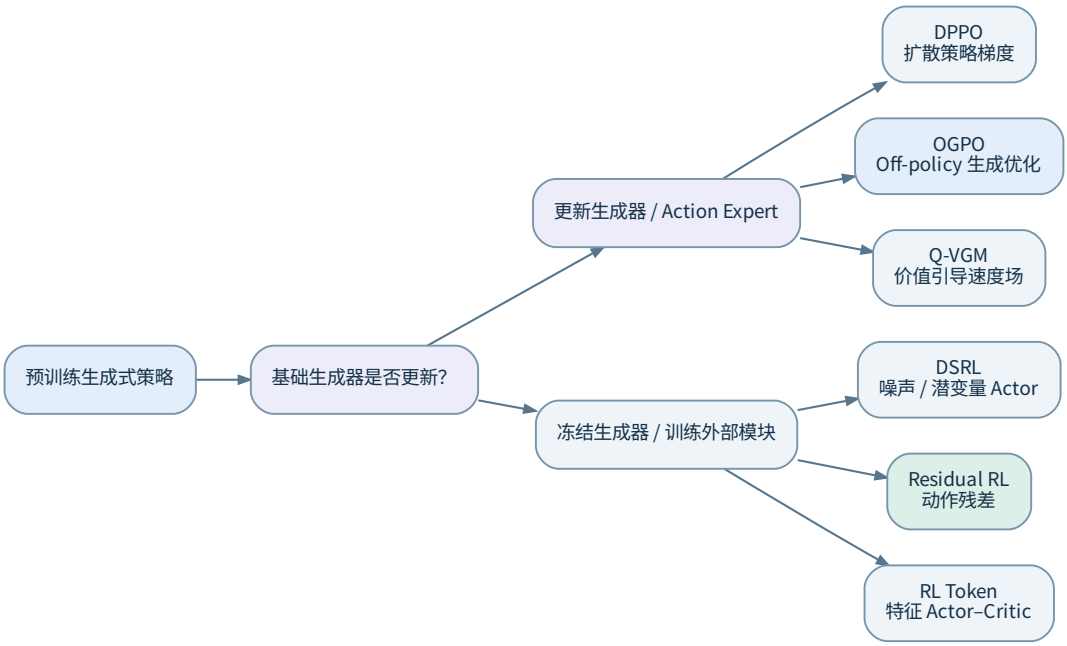


图 *2*：六类代表性更新接口。它们是不同方法，不是依次执行的训练步骤。

注意，“全参数 / 部分参数微调”描述**参数更新范围**；“Velocity Matching / Policy Gradient”描述**优化目标**；“On-policy / Off-policy”描述**数据与更新关系**。这三个概念不能混为一个互斥的分类树。

3. 三个必须分开的分类维度

维度	关键问题	典型选择
预训练模型	要后训练哪种策略?	Diffusion、Flow Matching、带 Action Expert 的 VLA
可训练接口	哪些参数接受 RL 信号?	生成器本体、LoRA、噪声 Actor、动作残差、特征 Actor

维度	关键问题	典型选择
数据与优化	数据是否持续新增、是否复用旧轨迹?	Online / Offline；On-policy / Off-policy；Replay Buffer

Online 不等于 On-policy。Online 描述训练过程中持续收集新交互；Off-policy 允许借助 Replay Buffer 复用来自旧策略的数据。因此，真机持续采样 + SAC 类算法重用历史数据就是 Online Off-policy RL。PPO 通常属于 On-policy；SAC 通常属于 Off-policy，但 DPPO 和 OGPO 不等于把普通 PPO / SAC 直接接到生成式动作头。

4. 直接更新基础生成器

4.1 DPPO：扩散策略梯度

DPPO 将逐步去噪过程纳入策略优化，而不是假设整个 Diffusion Policy 的动作概率天然易算。作为直观背景，PPO 的裁剪目标为

$$L_{\text{clip}} = \mathbb{E}\left[\min\left(\rho\hat{A}, \text{clip}(\rho, 1-\epsilon, 1+\epsilon)\hat{A}\right)\right].$$

这**不是 DPPO 的完整损失**。DPPO 的实用瓶颈包括 On-policy 采样成本、去噪链的计算开销、更新稳定性以及对原有技能的破坏风险。

4.2 OGPO：Off-policy 复用经验并更新生成过程

OGPO 利用 Replay Buffer 和 Off-policy Critic 传播价值信号，再更新生成式策略。其核心链路是 **历史与新轨迹 → 价值估计 → 生成器策略改进**。虽然目标中可能包含 PPO 风格的设计，不能据此把 OGPO 认定为 On-policy PPO；重要限制是 Critic 偏差、旧数据分布偏移以及多步生成过程的反向传播成本。

4.3 Q-VGM：Critic 引导 Flow Matching

Q-VGM 利用价值梯度构造局部 Velocity Matching 目标，更新 Flow Action Expert 的速度场网络，而无需对完整生成轨迹做反向传播。论文将离线 IQL 与在线 TD 价值估计结合；这种方法**仍然更新生成器**，不能归到冻结基础策略的分支。

三者分别强调：DPPO 的扩散策略梯度、OGPO 的 Off-policy 数据复用与全生成过程改进、Q-VGM 的局部价值引导 Flow 目标。不存在天然的训练先后顺序。

5. 冻结基础生成器、训练额外模块

5.1 DSRL：在噪声 / 潜变量空间学习

DSRL 冻结预训练生成器，让小型 RL Actor 选择可注入的噪声或潜变量：

$$z \sim q_\phi(z \mid o, g), \quad A = G_{\theta_0}(o, g, z), \quad \theta_0 \text{ fixed}.$$

其优势是减少需要更新的权重，同时保留原模型；但可改善的动作受预训练生成器的可达分布限制。**Diffusion 上可行的噪声接口不能未经验证直接移植到任意 Flow/VLA**。

5.2 Residual RL：在动作空间进行受限修正

冻结的基础策略产生 A_0；小型 Actor 产生 ΔA_ϕ，执行前进行时序、坐标系、尺度和安全约束处理：

$$A_{\text{cmd}} = \text{Safe}\left(A_0 + \lambda \Delta A_\phi\right).$$

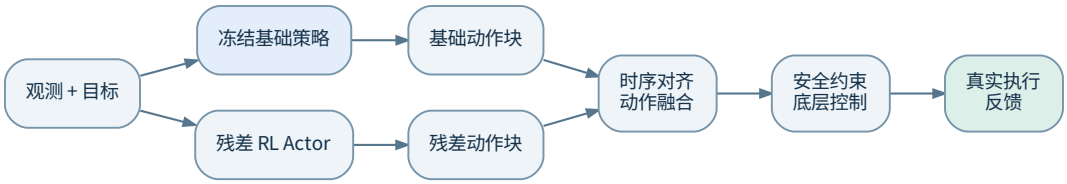


图 3：基础动作与残差动作并行产生，再融合执行。*Residual RL* 是架构模式，不指定唯一的 *RL* 算法。

5.3 RL Token：基于 VLA 特征的轻量 RL

RL Token 先为 VLA 建立可读出的紧凑特征接口，再在其上学习轻量 Actor–Critic。建立 token 接口可能需要模型适配，而随后的在线 RL 可以冻结 VLA 主体。它也不是动作残差方法的同义词。

6. Actor–Critic 与 Online Off-policy 后训练闭环

Off-policy 方法通常储存 $\mathcal{D} = \{(o_t, A_t, r_t, o_{t+1}, d_t)\}$，训练 Critic 再更新所选择的 Actor / Action Expert。一个简化的一步 Bellman 目标为

$$y_t = r_t + \gamma(1 - d_t)\,\mathbb{E}_{A' \sim \pi}\left[Q_{\bar{\psi}}(o_{t+1}, A')\right].$$

注意：若一个策略决策执行 K 个底层动作，则应按**实际累计奖励、K 步折扣 γ^K 与决策时刻转移**构造目标；上式不能不加修改地用于 Action Chunk，也不等于 SAC / OGPO / Q-VGM 的全部损失。

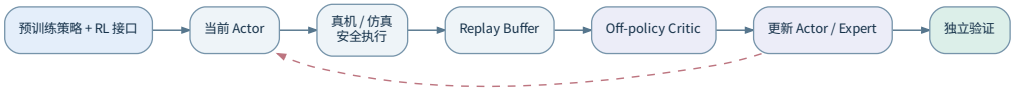


图 4：*Online Off-policy* 的典型闭环。对 *On-policy* 更新，应主要使用当前策略采样而非不加区分地重用 *Replay Buffer*。

训练时奖励与执行时安全约束、仿真与真实数据、Actor 更新与 Critic 更新、VLA 推理频率与机器人底层控制频率，应保持清晰分离。

7. 一张表选方法

方法	RL 更新对象	经验特点	适用条件 / 风险
DPPO	Diffusion 生成器	以 On-policy 为主	有权更新模型；采样与多步生成成本高
OGPO	生成式策略参数	Online + Off-policy Critic	可利用 Replay；警惕 Critic 偏差与策略漂移
Q-VGM	Flow Action Expert	Offline-to-Online；价值引导	可修改速度场；依赖价值梯度可靠性
DSRL	噪声 / 潜变量 Actor	可用 Off-policy	可控噪声接口；受冻结生成器可达性约束
Residual RL	动作修正 Actor	由具体算法决定	动作可安全融合；注意接触稳定性

方法	RL 更新对象	经验特点	适用条件 / 风险
RL Token	特征层 Actor–Critic	Online RL	有可读 VLA 特征；注意接口与延迟

选型顺序：先明确能否更新基础生成器，再明确噪声、速度场、动作块与特征接口，然后综合考虑 Replay 利用率、Critic 可靠性与部署实时性。

8. 评估、部署与常见误区

评价不应只报告训练奖励和成功率，还需报告**真实交互小时数、复位成本、算力 / 显存、推理延迟、动作块边界抖动、安全干预、失败恢复、分布外场景、原有技能保持情况**。Off-policy 系统需额外记录 Replay Buffer 的离线 / 在线比例、数据版本以及 Critic 的偏差与漂移。

五类常见误解是：Online = On-policy；冻结生成器 = 不需训练参数；Velocity Matching 与 Full Fine-tuning 互斥；DPPO、OGPO、Q-VGM 是串行流程；仿真成功率提升意味着真机安全可靠。这五个等号都不成立。

9. 目前的具身 RL 后训练基础设施（2026 年 10 月）

9.1 不要把“RL 系统、仿真器、模型代码和评测集”混为一类

真正的后训练基础设施至少要连接五层：**预训练策略及可训练接口；交互环境（仿真或真机）；带时间戳的经验与奖励；Actor–Learner / Critic 更新；安全部署和独立评估**。模型仓库负责加载与微调基础模型，不自动提供 Online RL；仿真器负责生成交互，不自动解决生成式策略优化。

层次	代表性开源项目 / 资源	当前角色与应知边界
VLA RL 训练系统	RLinf、RLinf-VLA	提供 VLA 接口、Rollout / Actor / Env Worker、分布式训练与 PPO 等实例；算法与模型组合须逐项核验
真机在线学习系统	RLinf-USER、HIL-SERL	Actor–Learner 异步训练、真实机器人接入、经验复用、人类干预；HIL-SERL 主要是通用机器人 RL 工作流，不是任意 VLA 的直接微调器
机器人学习与数据工具链	LeRobot	统一数据、硬件、策略训练与评估，并提供 HIL-SERL；其 VLA 支持和其 RL 算法支持不意味着所有交叉组合已打通
预训练模型和微调接口	OpenPI、Isaac-GR00T	模型权重、Action Expert、数据转换、SFT / 推理服务；并非单独完整的 RL 后训练闭环
交互环境 / 并行采样	Isaac Lab、ManiSkill、MuJoCo	任务、物理仿真、传感器、奖励与重置；Sim-to-Real 和接触真实性另需验证
任务与评测基准	LIBERO、RoboTwin 2.0、RoboCasa365、BEHAVIOR-1K	测量操作、泛化和长时程能力；Benchmark 不是训练算法，也不能替代真机统计
学习型交互环境（研究方向）	WoVR、VLA-MBPO	利用世界模型补充 Rollout，降低真实交互成本；目前不能默认接触动力学和失败轨迹均准确

9.2 两个最值得重点讲的系统

RLinf / RLinf-VLA：重点在规模化仿真后训练。官方框架具有按模型、环境与算法组合的训练示例；具备分离式 Worker、FSDP / 并行训练、Rollout 和评估机制，且已与 Isaac Lab 的 VLA RL 接口 集成。RLinf 也给出了 GR00T 上的 PPO、π_0 的 DSRL 和 SAC-Flow 等不同示例。不能因为系统支持 $\pi_{0.5}$ 权重、Replay Buffer 和 SAC，就推断“任意 $\pi_{0.5}$ Flow Expert 已验证 Online Off-policy RL”。

RLinf-USER / HIL-SERL：重点在真机闭环和交互效率。 RLinf-USER 将机器人视为与 GPU 类似的可调度资源，引入异步采样、权重同步、持久 Replay 与多机器人管理；论文同时展示了 Flow + SAC 及 π_0 + HG-DAgger 等路线，**但 HG-DAgger 属于在线交互式模仿学习，不应被改写为 π_0 的 SAC 后训练证据**。HIL-SERL 则提供“少量示教 + 奖励分类器 + SAC + 人类安全接管”的经典真机 RL 配方；LeRobot 文档 已收录相应工作流。

9.3 一套系统真正需要哪些接口?

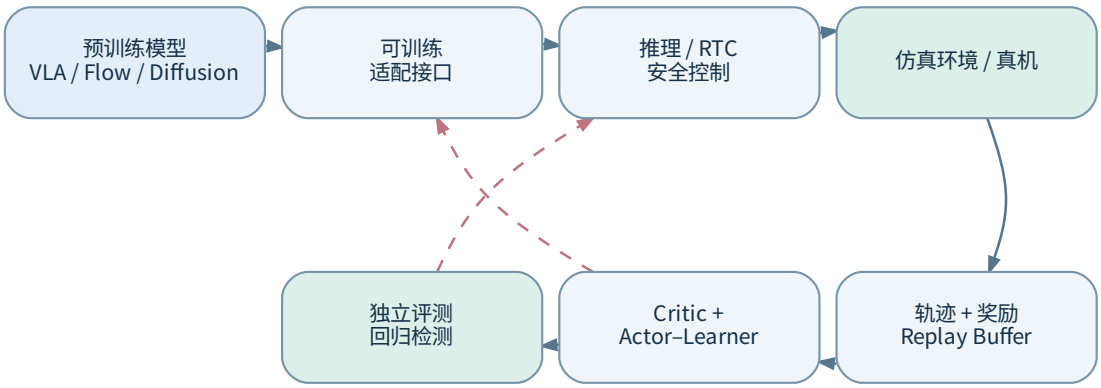


图 5: *Infrastructure* 不是单个 *RL* 算法，而是模型、交互、数据、更新、安全与评估组成的系统。

对生成式策略，还必须记录**采样种子 / 噪声、预处理与归一化、模型版本、动作块长度、决策频率和实际执行步数**，否则 Replay 中的动作与 Critic 的学习目标可能不一致。异步推理可以通过 RTC 与动作执行重叠，但需要专门处理旧动作块和新动作块的衔接。

10. 尚未解决的关键问题

下面的“未解决”指尚缺**跨机器人、跨任务、跨训练规模的可靠通用解法**，并非没有任何论文提出局部方案。

开放问题	为什么仍然困难	当前方向 / 必须核验的结果
真实交互与复位昂贵	真机不能像仿真一样加速、复制或无成本重置，且失败可能损坏设备	异步多机器人采样、HIL、Sim–Real 共训；报告每提升一点成功率所需的真实机器人小时数
奖励和成功判定不可靠	稀疏成功信号难学；VLM / 奖励分类器受视角、遮挡和分布变化影响	人类纠正、可审核奖励、独立终态验证；测误判率而不仅是奖励均值
Off-policy Critic 偏差与策略漂移	Replay 内含不同策略、不同版本和非平稳数据；生成动作的价值梯度可能被过估	Conservative / ensemble Critic、成功数据约束、策略锚定；验证 Q 误差、OOD 误差与新旧任务性能
生成式策略难以稳定更新	Diffusion / Flow 常有多步采样、非显式动作密度和高训练开销	局部 Velocity 目标、潜空间 RL、参数高效微调；报告每次更新的梯度 / 显存 / 推理开销
动作块与实时闭环冲突	观测滞后、Chunk 切换不连续、策略频率低于底层控制频率	RTC、重叠推理、边界平滑与安全控制器；测端到端延迟和扰动恢复
接触与灵巧操作的 Sim-to-Real 差距	摩擦、柔顺、物体几何、手指接触与视觉遮挡难以忠实模拟	接触随机化、触觉 / 本体反馈、在线系统辨识；必须含真机装配、滑移与失败恢复
后训练后遗忘与泛化下降	针对单个任务优化可能损害基础策略的其他技能和跨场景性能	SFT 混训、行为约束、跨任务 Replay；前后比较保留集与新环境表现

开放问题	为什么仍然困难	当前方向 / 必须核验的结果
世界模型中的虚假成功	长时程视频误差累积，多视角与小尺度接触细节缺失，策略可能利用模型偏差	短时域分支 Rollout、真实失败数据校准；以真机转移收益而非仅合成回报评价
缺乏可比的系统级基准	论文使用不同机器人、相机、复位、数据预算与安全条件	统一报告真实采样小时数、GPU 小时、失败恢复、安全接管、奖励误差和训练可复现性

这些困难可从 RLinf-USER（真实采样与系统调度）、$\pi^*_{0.6}$ / RECAP（示教、纠正、在线经验整合）、VLA-MBPO 与 VLAW（世界模型误差与物理保真度）等工作中找到直接证据。

10.1 最值得优先研究的三个交叉问题

（一）**Online Off-policy + 冻结大模型**。能否固定已有 Flow/VLA，只训练轻量 Adapter 或噪声 / 特征 Actor，通过可靠 Critic 复用真实失败数据，同时保留预训练泛化？关键是区分“能做样本高效的局部改进”和“可以突破冻结生成器的动作支持集”。

（二）**带奖励可信度和安全约束的真机学习**。价值学习的估计误差、奖励误判和安全动作修正应协同建模。把简单的奖励最大化改造成**成功率、恢复能力与风险约束**的联合优化，而不是让危险行为先出现再靠奖励惩罚。

（三）**Sim / World Model / Real 数据闭环**。仿真提供吞吐量，世界模型提供低成本候选经验，真机提供物理真实性；核心问题是如何估计并限制合成轨迹偏差，让更多合成数据确实减少所需真实采样，而非造成误导。

11. 原论文、项目和扩展阅读

主题	官方项目 / 原始论文
基础算法	PPO ·SAC
直接更新生成器	DPPO ·OGPO ·Q-VGM ·SAC-Flow
冻结或附加接口	DSRL ·RL Token
RL 后训练系统	RLinf ·RLinf-VLA ·RLinf-USER ·HIL-SERL ·LeRobot
预训练模型 / 仿真	OpenPI ·Isaac Lab ·ManiSkill
任务 / 泛化评测	LIBERO ·RoboTwin 2.0 ·RoboCasa365 ·BEHAVIOR-1K
真实数据与世界模型	$\pi^*_{0.6}$ / RECAP ·VLA-MBPO ·VLAW ·WoVR

总结：具身基础模型 RL 后训练应同时回答四类问题：**预训练了什么、RL 更新哪里、系统如何高效且安全地收集和复用经验、真实世界里哪些能力真正变好了**。目前的最大瓶颈正在从单一策略梯度算法，逐渐扩展为奖励、Critic、真机采样、时序控制、仿真可信度和系统级评估的联合问题。