具身基础模型的强化学习后训练

技术教程

2026-10-19

目录

1. 研究对象：从预训练生成式机器人策略开始 2
2. 首先明确：RL 更新了模型的哪一部分? 3
3. 三个独立的选型维度 4
4. 路线一：直接更新预训练生成器 4
5. 路线二：冻结生成器，只更新轻量模块 4
6. Actor–Critic 与 Online Off-policy 训练闭环 5
7. 用一张表选择后训练方法 6
8. 评估标准：离线性能不是可部署能力 7
9. RLinf：从可复用训练基础设施到真实机器人 7
10. 从 RLinf 的边界看尚未解决的研究问题 10
11. 原始论文与官方资料 10

课程仓库 ·English Markdown ·RLinf 官方文档

项目	说明
主题	RL Post-training
修订日期	2026-10-19
许可	CC BY 4.0 ·Xiong Zeng and contributors

1. 研究对象：从预训练生成式机器人策略开始

Reinforcement Learning Post-Training for Embodied Foundation Models
算法、RLinf 训练基础设施与真机部署的能力边界·2026 年 10 月

> **课程定位**：介绍如何利用强化学习改进**已经预训练的** Diffusion Policy、Flow Matching Policy 与 VLA；按照 “模型更新接口 → 数据与学习算法 → 训练系统 → 真机部署” 组织内容。只保留必需的 PPO、SAC 与 Actor–Critic 概念，不讨论从零训练运控策略，也不包含实验代码。
>
> **证据边界（截至 2026-10-19）**：本文把官方文档中已有的运行案例、由案例推断的集成需求、尚未普遍解决的研究问题严格区分。某系统分别支持模型 A、算法 B 和硬件 C，**不意味着 A × B × C 已经得到验证**。本文不声称自行复现或进行真机验证。
>
> **署名**：基于 Xiong Zeng and contributors 的 Foundation of Embodied AI 课程资料增补（CC BY 4.0）。论文与第三方代码各自遵循原有许可。

模仿学习使策略获得初始操作能力；RL 后训练利用与环境的交互，进一步改善成功率、精度、抗扰动能力、失败恢复与执行效率。研究对象是已有模型，而非随机初始化的控制器。

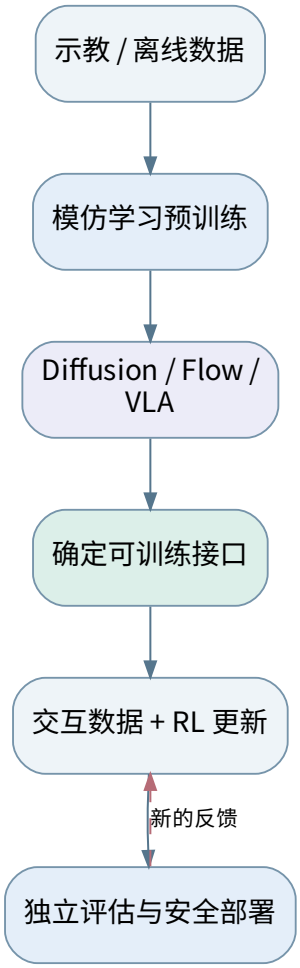


图 *1*：从预训练模型出发的 *RL* 后训练闭环。评估和安全部署不能由训练奖励替代。

令 o_t 为观测，g_t 为语言指令或任务目标，A_t 为预测动作块：

$$\pi_{\theta_0}(A_t \mid o_t, g_t), \qquad A_t = (a_t, \dots, a_{t+H-1}),$$

其中 θ_0 是预训练参数，H 是策略生成的动作长度。Diffusion / Flow 往往通过多步采样生成连续动作；VLA 还可能包含视觉语言骨干、Action Expert 与其他输出头。后训练通常最大化

$$J(\pi) = \mathbb{E}_{\tau\sim\pi}\left[\sum_{t=0}^{T}\gamma^t r_t\right],$$

但必须同时考虑原有技能的保持。尤其对隐式生成策略，**不能默认直接得到准确的** $\log \pi(A \mid o, g)$ **或 KL 散度**，因此不能把普通 PPO/SAC 无修改地套到任意生成式动作头上。

2. 首先明确：RL 更新了模型的哪一部分?

针对预训练生成器，有两条清晰的教学主线：**更新生成器 / Action Expert**，或**冻结生成器、训练辅助模块**。LoRA、部分参数微调与混合残差方案可能跨越这两条主线。

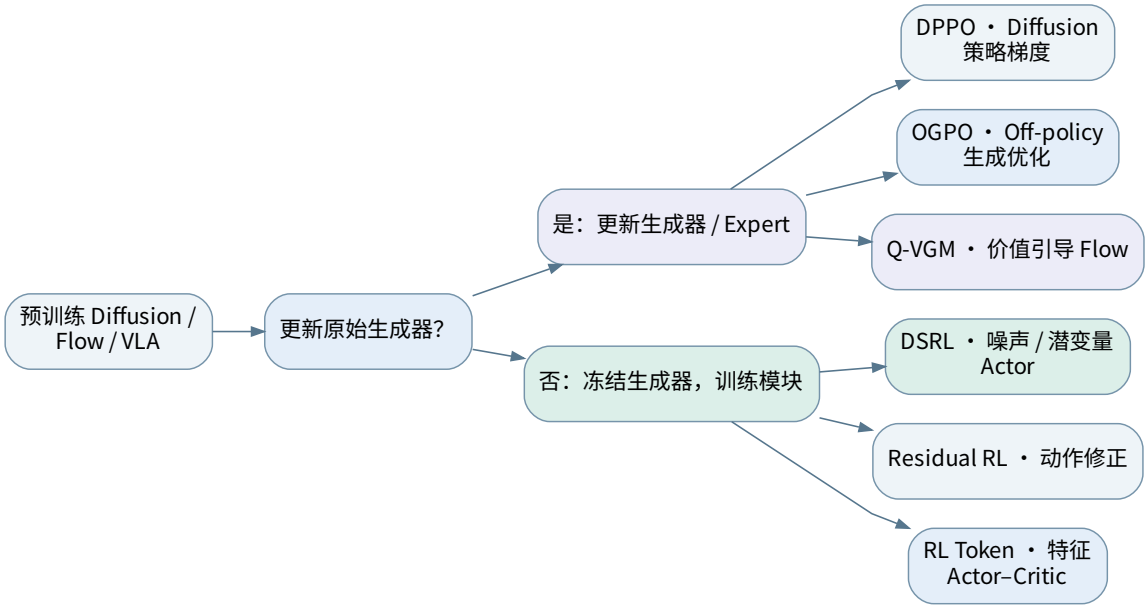


图 2：按模型更新接口而非算法名称分类。这些是并列路线，不是连续训练步骤。

这里的 “全参 / LoRA” 是**参数更新范围**，“Velocity Matching / Policy Gradient” 是**优化目标**，“On-policy / Off-policy” 是**数据复用关系**；它们不能混为一条互斥的分类树。

3. 三个独立的选型维度

维度	核心问题	代表性选择
预训练模型	对什么策略后训练?	Diffusion、Flow Matching、带 Action Expert 的 VLA
更新接口	哪些参数接收 RL 信号?	Expert、LoRA、噪声 Actor、动作残差、特征 Actor
数据与优化	新交互怎样进入训练、旧数据能否重用?	Online / Offline；On-policy / Off-policy；Replay Buffer

Online 不等于 On-policy。Online 表示训练期间持续获取新的环境交互；Off-policy 表示可以使用历史行为策略采集的数据。因此，真机不断收集轨迹、Learner 从 Replay Buffer 中混合采样历史数据，属于 **Online Off-policy RL**。PPO 通常 On-policy，SAC 通常 Off-policy，但 DPPO 和 OGPO 均需处理生成模型的特殊结构。

4. 路线一：直接更新预训练生成器

4.1 DPPO：扩散策略梯度

DPPO 将 Diffusion Policy 的逐步去噪过程纳入策略优化，而非把它当作一个天然具有可计算动作似然的 Gaussian Actor。PPO 的直观裁剪目标为

$$L_{\text{clip}} = \mathbb{E}\left[\min\left(\rho\hat{A},\ \text{clip}(\rho, 1-\epsilon, 1+\epsilon)\hat{A}\right)\right].$$

上式**不是 DPPO 的完整目标**。实践瓶颈包括 On-policy 采样成本、去噪计算与梯度成本、策略更新波动以及对预训练技能的干扰。

4.2 OGPO：Off-policy 复用经验并优化生成过程

OGPO 利用历史与在线轨迹训练 Off-policy Critic，再把价值信号传递给生成式策略，其信息流是 **Replay → Critic / Advantage → 生成器更新**。不能因为目标中有 PPO 风格项就将 OGPO 归为 On-policy PPO。风险集中在旧策略与新策略的分布偏移、Critic 误差和完整生成链上的更新成本。

4.3 Q-VGM：价值引导的 Flow Matching

Q-VGM 把 Q 值梯度转换为局部的速度场匹配目标，直接更新 Flow Action Expert，而不需要沿整条多步生成链进行反向传播。其论文使用离线 IQL 与在线 TD 价值估计相结合的思路。**Q-VGM 属于更新生成器路线，不是冻结原始 Flow Policy**。

三者的关键区别不是性能排名，而是梯度进入生成策略的方式：逐步扩散策略梯度、完整生成过程优化、局部价值引导速度场更新。

5. 路线二：冻结生成器，只更新轻量模块

5.1 DSRL：噪声 / 潜变量空间强化学习

DSRL 保持生成器固定，用小型 Actor 调整输入噪声或潜变量：

$$z \sim q_\phi(z \mid o, g), \qquad A = G_{\theta_0}(o, g, z), \qquad \theta_0 \text{ fixed}.$$

优势是训练参数少、基础生成器保持不变；局限是行为提升被**冻结生成器可到达的动作分布**所限制。RLinf 的 DSRL 实例 针对冻结的 π_0，并不自动证明它可不修改地适配任何 $\pi_{0.5}$、Flow 或新机器人。

5.2 Residual RL：在动作输出上进行受限修正

基础策略输出 A_0，残差 Actor 输出 ΔA_ϕ，执行时先做动作尺度、坐标系和 Chunk 时序一致化，再通过限幅与安全层：

$$A_{\text{cmd}} = \text{Safe}\big(A_0 + \lambda \Delta A_\phi\big)\,.$$

Residual RL 是**控制架构**，不是一种固定的 On-policy / Off-policy 优化器。它更易集成，但修正范围通常局限于基础动作邻域；对灵巧接触，残差还可能引发夹持失稳。

5.3 RL Token：在 VLA 特征之上学习 Actor–Critic

RL Token 首先建立可读出的 VLA 紧凑特征接口，然后冻结主特征网络并用轻量 Off-policy Actor–Critic 改进控制。RLinf 的 RLT 文档 明确区分示教阶段建立特征接口与随后在线 RL 的两个阶段。RL Token 不是动作残差方法；创建特征接口本身可能需要先行适配模型。

6. Actor–Critic 与 Online Off-policy 训练闭环

典型 Off-policy Learner 存储 $\mathcal{D} = \{(o_t, A_t, r_t, o_{t+1}, d_t)\}$ 并训练价值网络。简化的一步 Bellman 目标是

$$y_t = r_t + \gamma(1 - d_t)\, \mathbb{E}_{A' \sim \pi}[Q_{\bar{\psi}}(o_{t+1}, A')].$$

实际执行包含 K 个底层控制步的 Action Chunk 时，应按决策时刻构造

$$y_t^{(K)} = \sum_{j=0}^{K-1} \gamma^j r_{t+j} + \gamma^K (1 - d_{t+K}) \mathbb{E}_{A' \sim \pi}[Q_{\bar{\psi}}(o_{t+K}, A')].$$

因此，“模型输出了 H 步动作” 和 “机器人实际执行了 K 步动作” **不一定相同**。Replay、奖励折扣、时间戳、动作块覆盖与 Critic 的目标必须使用真实执行的 K。上述式子仅为教学抽象，不是 SAC、OGPO、Q-VGM 的完整损失。

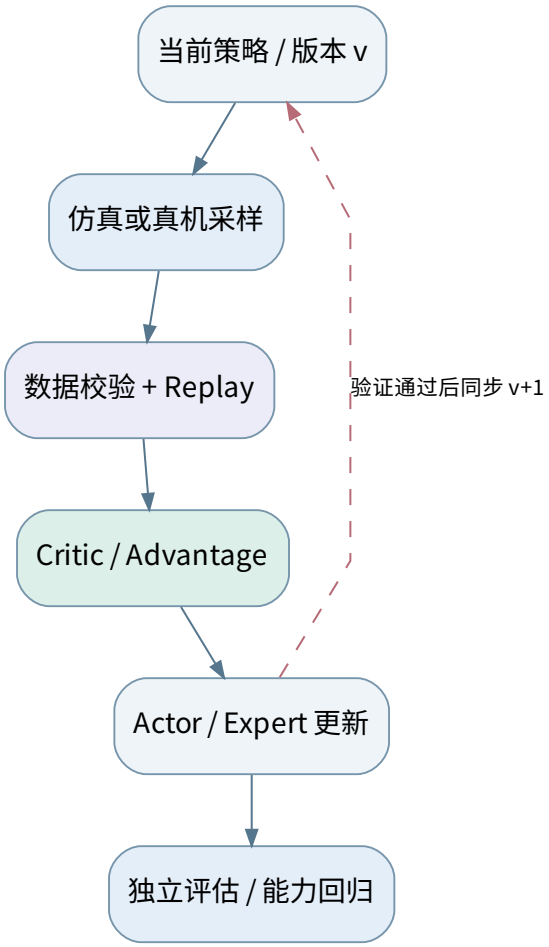


图 3：*Online Off-policy* 的 *Actor–Learner* 循环。旧经验可以复用，但策略版本和实际执行动作必须可追溯。

训练奖励与安全约束、仿真与真机样本、Critic 与 Actor 的更新、模型推理频率与底层控制频率，应清晰分离。

7. 用一张表选择后训练方法

方法	更新对象	典型数据范式	主要条件与风险
DPPO	Diffusion 生成器	主要为 On-policy	可改模型；去噪与 Rollout 成本高
OGPO	生成式策略	Online Off-policy	Replay 复用；警惕 Critic 偏差与分布漂移
Q-VGM	Flow Action Expert	Offline-to-Online	可训练速度网络；局部 Q 梯度必须可靠
DSRL	噪声 / 潜变量 Actor	可以 Off-policy	生成器冻结；受可达动作分布制约
Residual RL	动作修正 Actor	依具体算法而定	时序与动作尺度对齐；接触安全

方法	更新对象	典型数据范式	主要条件与风险
RL Token	特征 Actor–Critic	Online Off-policy	可读出特征；先行接口适配与推理开销

应先选 **模型更新接口**，再选 **优化算法与数据机制**；“仓库中有 SAC 和 Flow Model” 不等于 “给任意 Flow/VLA 用 SAC 只需修改配置”。

8. 评估标准：离线性能不是可部署能力

除训练奖励和成功率，应报告**真实机器人小时数、复位与人工干预成本、GPU 时间与显存、推理延迟（均值与尾延迟）、Chunk 边界不连续、安全触发率、扰动恢复能力、任务外泛化与旧技能保持**。对于 Off-policy RL，还要记录 Replay 的离线/在线比例、数据与模型版本、Critic 校准、行为策略漂移。

特别注意五个错误等式：**Online = On-policy；冻结生成器 = 不需训练；Velocity Matching = Full Fine-tuning；PPO/GRPO 训练案例 = Online Off-policy 案例；仿真成功 = 真机安全**。这些等式均不成立。

9. RLinf：从可复用训练基础设施到真实机器人

前面六种方法解释**怎么优化策略**。要让方法持续运行，还需要一个基础设施来连接模型、并行环境、数据、更新、硬件控制和评估。RLinf 正好是说明这种系统分工的代表：它同时涵盖规模化 VLA RL 和部分真机在线学习工作流，但不是所有后训练问题的通用 “即插即用” 解法。

9.1 它已经做到了什么：按可核验案例理解能力

对应能力	官方公开案例	必须保留的限定
预训练 VLA 的 On-policy RL	$\pi_0/\pi_{0.5}$ + PPO/GRPO，LIBERO 等	证明特定训练配方，不代表通用 Off-policy Flow 微调
冻结基础策略的 Off-policy RL	DSRL + 冻结 π_0，轻量噪声 Actor + SAC	噪声接口与 π_0 绑定；迁移到新模型需重新验证
Flow 与 SAC	SAC-Flow，ManiSkill 仿真与 Franka 插销	更新专用 Flow Actor；不能据此宣称冻结 $\pi_{0.5}$ 的 SAC 已验证
特征 Actor–Critic	RLT / RL Token，Franka 与 ManiSkill 案例	需要表示预训练和特征/动作语义一致性
真机接入与在线训练	RLinf-USER、多机器人训练	有异步采样、硬件调度等组件，但新机器人仍要适配
推理与动作执行重叠	RTC：$\pi_{0.5}$，LIBERO / Franka 评估	降低推理等待，不等于保证硬实时底层控制
扩展新硬件与任务	Adding a Robot、New Task	已提供统一接口和测试路径，但驱动、控制与安全仍需工程实现

RLinf 也提供 SFT、评测、仿真环境和不同训练后端。真实机器人文档 已涵盖 Franka、Turtle2、GimArm、DOS-W1 等不同成熟度案例。**不能简单说 “RLinf 不支持真机 / Off-policy / RTC”**；关键是区分已验证的具体组合和需要自行打通的交叉组合。

9.2 训练侧仍有哪些不足?

缺口	为什么不能只靠现有框架自动解决	接入新模型时要核验什么
模型 × 算法兼容性	$\pi_{0.5}$ + PPO/GRPO、π_0 + DSRL、专用 Flow + SAC 是不同的已验证配方	检查策略头、动作分布 / 采样噪声、可计算 log-prob、冻结参数范围及梯度路径

缺口	为什么不能只靠现有框架自动解决	接入新模型时要核验什么
通用 Online Off-policy Flow/VLA	历史数据复用要求价值学习和生成器更新目标兼容；并非任意预训练 Action Expert 都有现成接口	是否真正训练目标模型；Actor/Critic 更新频率、Replay 采样、行为策略和动作可达性
Critic 在高维视觉 / 接触任务上的稳定性	稀疏奖励、视觉遮挡与离策略偏差会造成 Q 误差累积	OOD Q 校准、双/集成 Critic、成功数据约束与真实失败轨迹
Action Chunk 的正确训练语义	采样块 H 与实际执行步 K 不同；RTC / 异步采样又引入延迟	K 步奖励、终止标志、时戳、动作覆盖、版本一致性与折扣 γ^K
大规模计算成本和复现	大 VLA 的分布式 Actor–Rollout–Learner 仍受模型推理、网络交换、显存与仿真吞吐限制	GPU 小时/成功增益、Worker 背压、FSDP 配置、checkpoint 转换、数据归一化和可复现性
多任务能力保持	针对少量任务的 Online RL 可能损害预训练模型广泛能力	跨任务保留集、跨场景回归、行为约束、SFT 与 Replay 混合比例

其中前两项是**现成组合覆盖范围的不足**，后四项主要是**尚需针对任务解决的研究与系统可靠性问题**。不能把它们笼统表述为“代码没有实现”。

9.3 部署侧仍有哪些不足?

训练模型在仿真里成功，并不意味着能够直接闭环驱动现实机器人。RLinf 的 Robot Interface 降低了接入新机器人和新任务的工作量，但还需处理以下边界。

缺口	典型风险	部署前的验收指标
非预设机器人硬件的适配	厂商 SDK、CAN/RS485、ROS 接口、机械臂/灵巧手动作语义与已支持平台不同	状态/动作单位、关节/末端坐标系、频率、重置与故障恢复接口一致
实时性与网络抖动	VLA 计算可能慢于机器人控制；RTC 只能隐藏部分等待	端到端延迟分布、P95/P99 抖动、超时策略、控制环连续性
Chunk 拼接和接触执行	新旧 Action Chunk 打架；旧观测导致精密装配、滑移抓取失败	Chunk 切换误差、接触力/电流安全阈值、扰动恢复时间
独立的运行时安全	训练奖励不能代替限位、急停、碰撞监测、失联保护与人工接管	硬件 Watchdog、动作投影/限幅、安全接管与可回滚策略
感知、标定和奖励可靠性	相机时间不同步、外参漂移、目标/接触判定误报	多传感器同步、独立成功判定、奖励误判率、置信度和 OOD 检测
真机数据闭环成本	人工复位、失败处理、机器人占用和物理磨损限制吞吐	Robot-hours、Reset-hours、干预次数、失败后可恢复率
模型版本与灰度发布	异步 Learner 的新权重不一定安全；Replay 可能混入旧数据语义	版本化数据与归一化、离线门禁、独立真机评估、失败回滚

要特别区分：**RTC 是延迟优化，不是实时安全控制器**；RLinf 真机 Demo 是可行性证据，不是其他型号机械臂或灵巧手的普适部署承诺。RTC 文档 本身报告了异步通信的额外残余开销。

9.4 把训练与部署接成一条真正的闭环

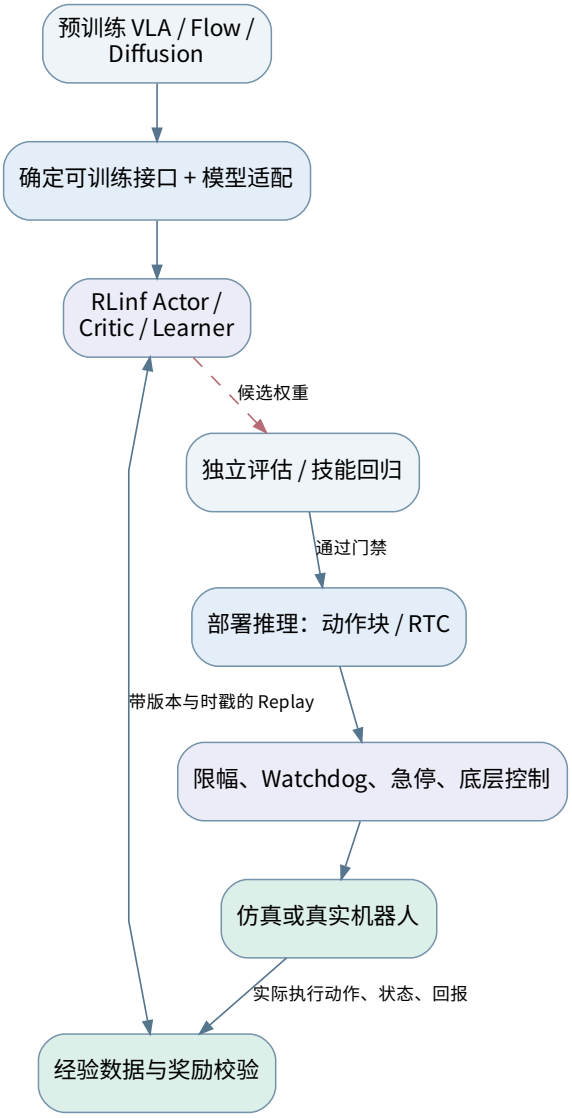


图 4: *RLinf* 在训练系统层提供关键组件；机器人驱动、安全执行、可靠奖励与真实数据回流依然必须端到端验证。

对于自定义的 “机械臂 + 灵巧手 + 头/腕相机” 平台，建议按**四层验收**推进：首先验证传感器、坐标系、归一化和 Action Chunk；然后验证策略推理与底层控制的时延和安全；再验证数据回传、Critic 与异步版本管理；最后才允许 Online RL 自动更新可部署权重。若无法通过前两层，增加更多 GPU 或更复杂算法通常不能解决根因。

由此进入下一章：RLinf 已部分解决 “如何组织训练和真机流程”，但仍没有通用方案确保 “真实数据足够、价值估计可靠、生成策略可控更新、部署长期安全”。这些才是后训练的核心开放问题。

10. 从 RLinf 的边界看尚未解决的研究问题

研究问题	科学难点	应该报告的证据
用更少真实数据稳定改进策略	稀疏奖励、环境非平稳、复位昂贵；离策略 Replay 导致偏差	每提升成功率所需 Robot-hours、样本复用率及不同场景统计
冻结大模型的 Online Off-policy 后训练	轻量 Actor 能否在不破坏预训练先验的情况下突破动作支持集约束?	与全参/LoRA、DSRL、RL Token、Residual RL 的对照；原技能保持
接触任务中可信的 Critic / Reward	视觉不能总是反映真实接触状态，Q 估计可能放大错误奖励	真实失败数据、Q 误差、错误成功判定、接触扰动恢复
兼顾反馈、流畅性和高控制频率	Chunk、异步网络、低频 VLA 与高频机器人控制之间存在时序冲突	P95/P99 延迟、动作边界误差、安全事件、扰动后恢复时间
从仿真和世界模型泛化到真实环境	接触摩擦/柔顺及长时程世界模型误差会形成虚假成功	未见物体、位置与光照变化、真机装配/滑移和恢复测试
长期持续学习与可比较评测	新技能学习与灾难性遗忘并存，软硬件和预算难统一	跨任务回归、机器人/计算资源账本、失败及人工接管记录

未来的高价值研究不仅是发明一个新的策略梯度损失，而是设计**可复用 Replay、可信价值估计、可控模型更新、可监测真实交互与安全部署**共同组成的长期闭环。可结合 RLinf-USER、RECAP 与 WoVR 理解这些问题的不同切面。

11. 原始论文与官方资料

类别	首选阅读
RL 基础	PPO ·SAC
更新生成器	DPPO ·OGPO ·Q-VGM
冻结 / 辅助接口	DSRL ·RL Token
RLinf 系统	Repository ·Docs ·RLinf-USER
已验证配方	$\pi_0/\pi_{0.5}$ RL ·DSRL ·SAC-Flow ·RLT
真机与部署	Real-World Robots ·Add a Robot ·RTC
仿真与世界模型	Isaac Lab ·ManiSkill ·WoVR

课程主旨：先明确定义预训练模型与 RL 可训练接口，再检查采样、优化、控制与部署是否形成真正可靠的闭环。RLinf 能显著减少系统重复建设，但不会自动替代科学验证和机器人安全工程。