机器人通用视觉基础模型：理解、比较与应用

技术教程

2026-10-19

目录

1. 从机器人任务理解视觉模型 . . . 2
2. 核心模型：从“能做什么”到“如何工作” . . . 2
3. 该选谁？关键模型差异与选型路径 . . . 5
4. 四类典型机器人工作流 . . . 5
5. 实际使用：从模型输出到可靠系统 . . . 6
6. 常见问题与一句话总结 . . . 7
官方参考资料 . . . 7

课程首页 ·English ·PDF

项目	说明
主题	视觉基础模型
修订日期	2026-10-19
许可	CC BY 4.0 ·Xiong Zeng and contributors

1. 从机器人任务理解视觉模型

Foundation of Embodied AI·扩充版讲义·*2026* 年 *10* 月

> **课程边界**：只讨论模型原理、输入输出、使用流程、组合策略和适用边界。不展开相机标定、复杂滤波推导、网络训练，不设置代码或实验章节。

阅读主线：语言或视觉提示 → **找到并分割目标** → **获取距离或形状** →（任务需要时）**估计刚体 6D 位姿** → **机器人策略或控制器**。这些能力往往来自不同模型；并不是每条机器人流水线都必须经过全部步骤。

1.1 五种常见视觉输出

你需要回答的问题	视觉任务	典型输出	不能据此断言
“红色螺丝刀在哪儿？”	检测 / 开放词汇定位	边界框、类别、候选实例	精确轮廓与距离
“哪些像素属于它？”	实例分割 / 视频跟踪	Mask、跨帧实例身份	物体三维朝向
“它离相机多远？”	深度估计 / 立体匹配	深度图或视差图	隐藏表面的完整形状
“它大致长什么样？”	三维重建	三维网格、纹理、空间布局	工程级 CAD 精度与质量惯量
“它的位置和朝向是什么？”	6D 位姿估计	三维平移 + 三维旋转	接触力、是否抓牢、是否滑移

重点： Mask ≠ 深度；深度 ≠ 完整物体模型；形状 ≠ 物体当前位姿；位姿 ≠ 接触状态。相机提供可见表面信息，指尖力、遮挡后的接触和材料参数通常还需要其他传感器或动力学推断。

1.2 先问四个问题，再选择模型

1. **任务需要多精确的几何？**只想知道“哪个目标”用检测/Mask 即可；抓取朝向、插装对准通常需要更明确的几何状态。
2. **有哪些传感器？** RGB、可靠的 RGB-D、同步标定双目，所适用的模型完全不同。
3. **有哪些物体先验？**有没有 CAD、准确尺寸、参考图像，决定 6D 位姿方法如何初始化。
4. **何时需要输出？**离线几何恢复可以较慢；闭环控制更关心观测新鲜度、吞吐量、延迟和失败恢复。

2. 核心模型：从“能做什么”到“如何工作”

2.1 SAM 2：用提示确定目标，用视频记忆传播 Mask

一句话理解： SAM 2 解决“我已指出这个目标，请继续告诉我它在视频中占据哪些像素”。它是**可提示的图像/视频分割器**，不是深度模型或 6D 位姿估计器。官方资料

关键思想。第一帧用点击点、框或已有 Mask 指定对象，模型利用当前图像特征生成分割；处理后续视频帧时，通过**流式记忆（streaming memory）**读取此前目标外观及分割信息，使目标在运动、形变和部分遮挡时仍能被传播。用户也能在某一帧追加提示以修正 Mask；记忆并不意味着永久正确的实例身份。

输入与输出。输入是 RGB 图像/视频以及正负点、边界框或掩码等提示；输出是每帧实例 Mask，以及用于管理目标的对象 ID/视频推理状态。Mask 是像素集合，不能直接给出相机到物体的米制距离。

典型使用流程。 ① 在起始帧指定螺丝刀；② 传播后续帧的 Mask；③ 当发生遮挡、相似工具交叉或对象出画时检查身份；④ 发现漂移后重新点击、给框或切换到全局重新检测。

适用与局限。已知目标、持续分割、制作视频伪标签、给位姿估计器提供对象区域时很合适；但当用户只有“找出红柄工具”这样的文本任务时，需要另外的语言定位模块。手和物体互相遮挡、视觉相似实例交换、运动模糊会导致 Mask 漂移；SAM 2.1 是更新的权重/实现系列，不是增加了度量深度能力。

2.2 SAM 3 / SAM 3.1：按概念发现目标，再分割和跟踪

一句话理解： SAM 3 不要求先由人指出唯一实例，而是能够根据**短文本概念或视觉示例**找出图像/视频中符合条件的实例，同时输出 Mask 并持续跟踪。官方论文 ·官方仓库

关键思想。 SAM 3 把“概念是否存在及在哪里”的**检测器**和“已找到实例如何在视频里延续”的**记忆式跟踪器**组织在同一视觉

特征体系中。概念提示可以是 “red-handled screwdriver” 等短名词短语，也可以是图像中的示例对象；系统返回**所有符合概念的候选实例**，而非默认选出机器人唯一要抓的那个。出现多个目标时，仍需任务级选择和 ID 管理。

与 SAM 2 的实质区别。 SAM 2 更适合 “实例已指定，维持像素跟踪”；SAM 3 增加概念驱动的**发现、分割与跟踪**。SAM 3.1 进一步用**对象复用（object multiplexing）**改进多个对象同时跟踪的计算效率；它不是独立的三维模型，也不把 Mask 直接升级成 6D 位姿。SAM 3.1 官方说明

输入与输出。输入为图像/视频 + 文本概念、视觉示例或交互提示；输出包括候选检测、实例 Mask、视频中的实例身份。复杂长指令可能要先经 VLM/Agent 化简为可定位的视觉概念，再用空间关系、任务记忆或机器人当前状态筛选目标。

典型使用流程。 ① 将 “把桌上的红柄螺丝刀拿起来” 转换为 “red-handled screwdriver” 提示；② 获取所有匹配 Mask；③ 根据桌面位置和任务约束选定实例；④ 开始视频跟踪；⑤ 身份不可靠时重新用概念检索。

适用与局限。适合语言条件抓取、开放类别物体发现、语义驱动目标选择。短语歧义、细小目标、相似物体、遮挡仍会出错；单个 Mask 不携带 CAD、深度、精确物体坐标系或接触状态。论文中的视频 FPS 依赖硬件、分辨率与对象数量，不能直接当成机器人闭环频率。

2.3 FoundationPose：刚体物体的 6D 位姿初始化、细化与跟踪

一句话理解： SAM 告诉我们 “哪些像素属于螺丝刀”，FoundationPose 则回答 “**这把已知或有参考视图的刚体螺丝刀相对于相机的位置与朝向**”。论文与代码

什么是 6D 位姿? 三维位置加三维旋转（通常记为 `SE(3)` 变换）相对于一个**已定义尺度和坐标轴的物体模型**才有意义。对长工具而言，刀尖、握柄和模型原点不同；“物体中心误差不大” 未必意味着刀尖对得准。

两种使用条件，不等于两个无条件通用模型。

模式	需要准备什么	应如何理解
Model-based	已知 CAD/网格、实际尺度、物体坐标约定	根据已知形状解释当前视觉观测；通常更适合重复使用的工具。
Model-free	对该物体采集的少量参考图像，并建立对应的对象表征	不要求现成 CAD，**但仍需对象参考信息**；公开流程可包含预先构建神经物体表示，不能理解为单张陌生图像就能直接得到精确 6D 位姿。

关键思想。首先根据可见对象区域和物体先验产生若干可能的姿态；**scorer** 判断候选的图像/几何一致性，**refiner** 对较好的候选进一步细化；后续帧把上一时刻的估计作为局部起点进行 **tracking**。这比每帧从全空间重新搜索更经济，但局部跟踪也容易把一次错误持续传播。论文通过共享后端，使 CAD 模式和少量参考图像模式能够使用相似的估计框架。

输入与输出。典型流程需要 RGB-D 观测、相机内参、目标 Mask，以及 CAD 或参考视图准备得到的物体表示；输出是在明确对象坐标系下的刚体 6D 位姿，连续帧可更新。若下游要在机器人基座坐标系控制，还需使用相机标定结果与采集时刻的机械臂状态完成坐标转换；这里不重复标定推导。

典型使用流程。 ① 确认 CAD/参考视图和真实物体一致；② 通过 SAM 等获得 Mask 与有效 RGB-D；③ **初始化**多个姿态候选；④ **评分、细化**得到当前位姿；⑤ 使用相邻帧做跟踪；⑥ 丢失或发生大姿态跳变时**重新初始化**，而不是无限期使用旧位姿。

适用与局限。适合刚性工具抓取、工具定向、装配中的视觉对齐。长时间遮挡、强反光/透明材质、细杆物体、深度缺失、CAD 与实物不符都会增加失效风险；**几何对称**可能使某些旋转角从视觉上不可区分。FoundationPose 估计的是物体位姿，不直接判断手指接触力或是否稳定抓持。对于严重非刚体，不应强行假设只有一个 6D 位姿。

2.4 FoundationStereo：用真实双目对应关系恢复深度

一句话理解： FoundationStereo 解决 “左右相机看见的同一位置如何对应”，先输出**稠密视差图**，再利用**标定过的双目几何**恢复以米为单位的深度。官方资料

关键思想。对整流后的左右图像，模型尝试判断左图某个像素在右图中的对应位置。两者的水平位移叫视差：一般同等相机配置下，近物体视差较大、远物体视差较小。深度与视差的关系可概括为 `Z = f × B / d`（焦距 `f`、基线 `B`、视差 `d`）。模型通

过图像特征与上下文匹配，力图让立体对应关系跨不同场景泛化；真正的米制尺度仍然来自**焦距和基线的标定**。

输入与输出。需要一对**同步、标定并完成立体校正**的左右 RGB 图像；主要输出视差，随后可转换为深度和点云。它不进行语言分割，不识别某一把螺丝刀的规范坐标系，也不直接求物体的 6D 位姿。

典型使用流程。 ① 确认确实是固定相对几何的双目；② 校正左右图像与有效视场；③ 推理视差；④ 根据双目参数转换深度；⑤ 与 Mask 联用提取目标可见表面；⑥ 如任务确实需要物体朝向，再接位姿估计器。

Fast-FoundationStereo 有什么变化? 它强调在保持较强跨域能力的同时降低立体匹配计算量，公开方法涉及知识蒸馏、按计算预算搜索网络设计和结构化剪枝；核心输出仍是**双目视差**，不是一个新类别的视觉任务。官方资料

适用与局限。已有硬件双目但原生深度不可靠时非常有用；如果 RGB-D 相机已经稳定提供精度足够的深度，不必为了 “使用基础模型” 重复运行立体网络。低纹理、镜面、透明、重复花纹、远距离小视差和双目失配会损害结果。头部 RGB-D 与随手臂运动的腕部 RGB **不能未经同步、外参建模与几何处理直接当成标准双目对**；论文报告的速度也不能替代本机端到端测量。

2.5 SAM 3D Objects：从单张图像生成物体形状先验

一句话理解： SAM 3D Objects 侧重 “这个目标可能具有怎样的**完整三维形状、外观和布局**”，并非直接返回经过标定、可用于精密装配的 CAD。官方资料

关键思想。单张图片只显示物体部分表面，其背面几何通常不可见。SAM 3D Objects 利用从大量数据学到的形状与外观先验，为被选中的目标生成合理的完整三维几何、纹理及空间布局。生成能力能够在遮挡和杂乱场景下补全形状，但这种 “看起来合理” 不代表所有不可见细节都是**真实测量**。

输入与输出。输入一般是 RGB 图片和目标选择/区域提示；输出为候选物体三维形状、纹理及相关场景信息。需要区分：**视觉网格、实际米制尺寸、物体坐标原点、碰撞几何、质量/惯量**是五类不同的物理要求，单图生成并不自动满足。

典型使用流程。 ① 选择图片中的目标；② 得到候选网格和纹理；③ 如果用于仿真或位姿估计，先检查尺度、法向、拓扑、对称性及对象坐标；④ 用 RGB-D、多视图或已知尺寸核验关键接触区域；⑤ 只把通过检查的网格作为下游几何先验。

与 FoundationPose 的关系。 SAM 3D Objects 生成 “物体可能长什么样”，FoundationPose 用物体先验估计 “它当前在哪里”。两者理论上可串联，但生成网格必须先验证尺度、坐标约定和几何质量；不能把它们描述成官方保证的直接、无校验即插即用接口。陌生物体的粗形状建模比毫米级插装更适合它。

2.6 Depth Anything 3：单目和多视图的通用几何先验

一句话理解： Depth Anything 3（DA3）把单幅/多幅图像的**深度与空间几何估计**统一到一个模型家族；但 “有深度图” 与 “有可信的米制深度” 依然要区分。官方资料

关键思想。模型从单目或多视角图像学习场景几何，既可预测深度，也可在一些配置下估计相机相关参数或一致的多视图表示。**不同 checkpoint 承担不同任务**：Main 系列支持多种视图配置；`DA3Mono` 面向相对单目深度；`DA3Metric` 面向度量单目深度。不能把某个模型的宣传能力不加区分地套到所有权重上。

怎么用。单目 RGB 场景需要大致前后关系时，可用它补充几何先验；若已有多视角图像，可关注几何一致性。对于厘米/毫米级机器人操作，必须检查尺度、视角变化和跨帧一致性：即使选择 Metric 版本，也不保证优于经过校准且质量良好的硬件深度或真实双目。

2.7 SAM 3D Body：估计人体三维形状，不是估计接触力

一句话理解： SAM 3D Body 从人体图像估计**人体三维网格与姿态**，常用于人类动作理解或机器人模仿学习中的人体侧几何先验。官方资料

使用方式与限制。输入为包含人体的图像，推理得到人体形状/姿态；如需由演示视频生成可用的机器人参考轨迹，还要解决**跨帧一致性、相机运动、尺度、人体到机器人运动学重定向、手—物接触**等问题。重建的人体网格不等于机器人关节轨迹，更不能直接推出抓取压力、摩擦力或物体被手挡住时的真实姿态。

2.8 Grounding DINO：可组合的文字目标检测器

一句话理解： Grounding DINO 根据开放词汇文本提示提供目标候选**边界框**，它适合 “先文本定位，再交给独立分割器” 的可替换流水线。官方资料

如何组合。 “red screwdriver” → Grounding DINO 框 → SAM 2 分割/视频传播。与 SAM 3 的概念分割统一接口相比，这条路线的组件可分别替换，但需要管理框与 Mask 的对应、多个相似目标的筛选，以及额外推理延迟。**只需要框就停在框，不必为了模型齐全而继续做三维重建。**

3. 该选谁？关键模型差异与选型路径

3.1 最容易选错的五组模型

容易混淆的模型	应该如何区分
SAM 2 vs SAM 3	已指定实例、重点是 Mask 传播 → SAM 2；用语言/示例发现新目标并跟踪 → SAM 3。
SAM 3 vs Grounding DINO	希望概念检测、Mask 与视频跟踪统一 → SAM 3；只需文字找框或保留模块化组合 → Grounding DINO。
FoundationStereo vs DA3	有同步标定的左右相机、需要基于视差的几何深度 → FoundationStereo；只有单目/任意视角图片、需要学习型几何先验 → 选 DA3 的合适变体。
FoundationPose vs SAM 3D Objects	已有 CAD/参考信息，想知道当前物体 6D 位姿 → FoundationPose；缺少物体形状，先生成候选几何 → SAM 3D Objects。
SAM 3D Body vs Objects	人体网格/姿态 → Body；一般物体三维形状与外观 → Objects；二者都不是接触传感器。

3.2 一个按问题依次做决定的选型树

1. **仅需目标语义和位置？** 有语言提示选 SAM 3（或 Grounding DINO），手工点选目标选 SAM 2；不必引入深度。
2. **需要持续获得目标 Mask？** 由 SAM 2 或 SAM 3 视频跟踪维持 ID；准备遮挡失效后的重检测。
3. **需要目标距离？**先用已有可靠 RGB-D；有标定双目用 FoundationStereo / Fast 版；只有单目可考虑 DA3 对应 checkpoint，但要审查尺度。
4. **需要完整形状？** 已有 CAD 就优先使用 CAD；陌生物体可考虑 SAM 3D Objects，并核验物理尺寸和关键表面。
5. **确实需要刚体姿态？** 以 RGB-D + Mask + CAD/参考视图接 FoundationPose；只有 Mask 或只有生成网格，并不自动满足其使用前提。
6. **要做接触丰富的操作？** 还需要本体状态、执行反馈，以及条件允许时的力觉/触觉；视觉只能提供其中一部分信息。

   最小充分模型原则： 抓取方向需要 6D 位姿，不等于必须运行 SAM 3D；已有可靠 RGB-D，不等于还要运行 FoundationStereo；VLA 能直接消费图像，也不等于显式 FoundationPose 永远没有价值。模型应由任务输出和输入条件驱动。

4. 四类典型机器人工作流

4.1 工具抓取与定向：需要已知目标的 6D 位姿

任务： 根据语言指令拿起螺丝刀，并把刀尖对准指定方向。

推荐链路： 任务语言 → SAM 3 发现螺丝刀并选择实例 → Mask + 头部 RGB-D + 对应的 CAD/参考视图 → FoundationPose 初始化 6D 位姿 → 连续跟踪与几何反馈 → 控制器执行。若目标和初始 Mask 已知，可跳过 SAM 3；如 FoundationPose 跟踪可靠，也未必需要每帧都运行完整分割。

为什么这样搭配？ SAM 3 管 “是哪一个”；深度管 “可见表面在哪里”；FoundationPose 管 “该刚体朝哪儿”；机器人控制器负责动作。视觉仍不能替代刀尖接触检测，物体滑移、跌落时要重新确认目标并定位。

4.2 双目机器人：没有 RGB-D 但想获得距离

任务：用两只已标定、同步的相机获取工作台的稠密深度。

推荐链路：左右图像校正 → FoundationStereo（实时性紧张时评估 Fast-FoundationStereo）→ 视差转换深度 → 根据目标 Mask 提取可见表面。只有在确实需要物体规范坐标系的 6D 朝向时，再加入具备对象先验的位姿估计。

判断要点：双目来自真实相机几何，单目深度来自学习先验；两者都可能失效，但尺度依据不一样。腕相机和头相机随时间变化的相对位置，不能直接代替标准固定双目输入。

4.3 未知物体：先获得候选形状，再决定是否能用于控制

任务：机器人面对一件没有 CAD 的陌生工具。

推荐链路： SAM 3 / SAM 2 选择目标 → SAM 3D Objects 得到候选形状 → 利用已知尺寸、RGB-D 或多视图检查尺度和几何 → 根据任务选择直接基于 Mask/点云抓取，或建立合适的参考模型供位姿估计使用。

判断要点：单视图看不到的槽、底面、接触边缘可能被生成模型 “猜错”；若要精密插装、受力配合或接触丰富的旋转，必须进一步验证关键几何。若只要粗略避障、可视化或对象级检索，不必先强求高精度 CAD。

4.4 人类演示与 VLA：不一定需要逐帧显式 6D 位姿

任务：从人类视频理解动作，或用视觉语言动作策略直接执行操作。

推荐链路：人体动作理解可用 SAM 3D Body 提供人体网格/姿态；若要重定向到机器人，额外需要轨迹连续性、人体—机器人几何对应及接触信息。VLA 可直接以相机图像、任务语言和机器人本体状态生成动作，不要求所有场景都先跑 FoundationPose。

显式几何何时仍有用？对需要刀尖朝向、碰撞约束、可解释失败检查、物体掉落后重定位的任务，SAM/深度/6D 位姿可作为独立观测或安全检查接口。它与直接视觉策略是**互补路线**，不是非此即彼。

5. 实际使用：从模型输出到可靠系统

5.1 六个必须确认的接口条件

方面	必须确认的问题	常见误用
输入	是 RGB、RGB-D、双目、文本、CAD，还是参考视图？	把单张 RGB 直接当作 FoundationPose 完整输入。
尺度	深度是相对尺度还是可靠米制深度？物体网格是否已校准？	把生成网格尺寸用于毫米级装配。
坐标	Mask、深度、相机和物体坐标系是否一致？	把相机系 6D 位姿直接当机器人基座位姿。
时间	图像拍摄时刻和模型发布时刻是否区分？	用新时刻的机械臂姿态解释旧图像。
身份	目标是否仍是同一个实例？丢失后如何重定位？	Mask 看似连续，实际跟到了另一件物体。
资源	显存、分辨率、推理频率、权重许可是否匹配？	把论文某 GPU 的单模型 FPS 当作真机控制频率。

5.2 失败恢复比漂亮的单帧结果更重要

遮挡：允许短时跟踪，但不能把长期不可见仍标成 “精确已观测”。**对称性：**某些旋转本来就无法由当前图像唯一确定。**细长、透明与反光物体：**深度和 Mask 可能同时受影响。**突然移动或掉落：**局部位姿跟踪可能跑偏，需重新检测、验证实例、重新初始化。**精密接触：**即使 6D 位姿准确，仍无法单凭视觉推定力、摩擦和微滑移。

机器人系统应把 “是否看见目标”“几何是否可信”“观测是否新鲜”“目标 ID 是否连续” 作为独立判断。必要时降低动作幅度、主动换视角或停止接触；这属于系统决策，而不是某个视觉模型会自动完成的事情。

5.3 何时运行大型模型?

事件触发的语义检索（任务开始、目标丢失）可以较低频；**连续 Mask 或位姿跟踪**可在相机更新时运行；**控制器**通常依赖更及时的本体观测和估计状态。吞吐量、单次模型延迟和 "动作真正使用时信息有多旧" 是不同指标。不要默认 SAM 3、FoundationStereo、SAM 3D Objects 和 FoundationPose 都需要每帧串行推理。

6. 常见问题与一句话总结

Q1：SAM 3 能替代 FoundationPose 吗? 不能。前者主要给语义候选与 Mask，后者估计有对象先验的刚体 6D 位姿。

Q2：FoundationPose 的 model-free 是 "完全零先验" 吗? 不是。它不要求现成 CAD，但需要参考视图等对象信息，具体公开工作流还有对象表示构建步骤。

Q3：有可靠 RGB-D，还要 FoundationStereo 吗? 通常不需要；只有深度质量、视角和硬件条件确实受益时才增加双目路线。

Q4：SAM 3D Objects 输出的网格能直接给 FoundationPose 用吗? 不能无条件直接使用。先验证尺度、坐标、几何和任务所需精度，再考虑作为对象先验。

Q5：只有单目 RGB 能获得精确的绝对深度吗? 学习型单目模型能提供深度先验，特定 metric 权重有尺度能力；但不应未经校验就把它当成机器人精密操作的可信量测。

Q6：精确 6D 位姿就等于抓取成功吗? 不等于。位姿是几何信息，接触力、抓持稳定性和滑移需要额外反馈。

最终记忆法：SAM 找目标、分割与追踪；FoundationStereo 用双目看距离；DA3 从单目/多视图估计场景几何；SAM 3D 生成三维形状；FoundationPose 估计当前刚体姿态。选最小必要模块，再根据任务补充传感器、跟踪和失败恢复。

官方参考资料

1. SAM 2 — Segment Anything in Images and Videos（Meta，官方仓库）；论文。
2. SAM 3 — Segment Anything with Concepts（Meta，官方论文）；官方仓库与 SAM 3.1 更新；SAM 3.1 说明。
3. FoundationPose（NVIDIA，CVPR 2024，官方仓库）；论文。
4. FoundationStereo（NVIDIA，CVPR 2025，官方仓库）。
5. Fast-FoundationStereo（NVIDIA，CVPR 2026，官方仓库）。
6. SAM 3D Objects（Meta，官方仓库）；SAM 3D Body（Meta，官方仓库）。
7. Depth Anything 3（ByteDance Seed，官方仓库与模型家族）。
8. Grounding DINO（IDEA-Research，官方仓库）。

课程来源与署名：改写自《*Foundation of Embodied AI*》课程原有《视觉感知与状态估计》讲义（*Xiong Zeng and contributors, CC BY 4.0*）。第三方模型、代码、权重及资料遵循各自许可证。*2026* 年 *10* 月修订；具体模型接口、许可与性能请以使用版本的官方资料为准。