机器人通用视觉基础模型：理解、比较与应用

Foundation of Embodied AI · 精简课程讲义 · 2026-10-18

本章只回答三个问题： 各类通用视觉模型分别输出什么？SAM、FoundationPose、FoundationStereo 与 SAM 3D 如何区分？面对机器人任务，怎样选择并组合这些现成模型？

范围： 概念、模型选型、系统组合与使用边界。不讲相机标定、SE(3) 滤波推导、策略训练，也不设置实验或代码章节。

1. 先看任务：机器人究竟需要哪一种视觉输出？

视觉模型不是一个可以任意互换的“感知黑盒”。选择模型前，应先确定**机器人下一步需要的变量**，而不是先比较网络大小或排行榜成绩。

任务类型	典型输出	能解决的问题	不能直接得到什么
检测（Detection）	目标类别、边界框、置信分数	“目标在哪个区域？”	精确轮廓、三维距离
实例分割与跟踪（Segmentation / Tracking）	像素 Mask、实例 ID、跨帧对应	“哪些像素属于这把工具？”	物体深度、刚体 6D 位姿
深度估计（Depth）	深度图或双目视差	“目标表面距离相机多远？”	物体完整形状、物体坐标系
三维重建（3D Reconstruction）	估计网格、形状或纹理	“物体大致长什么样？”	必然精确的尺寸、可抓取性
6D 位姿估计（6D Pose）	物体三维平移与三维旋转	“工具相对于相机朝向如何？”	接触力、摩擦、抓稳与否

最重要的四个区分： Mask 不是深度；深度图不是完整三维模型；三维模型不是当前位姿；6D 位姿也不是接触状态。一个输出不能替代另一个输出。

先问四件事： 只需找到目标，还是必须知道朝向？有没有 RGB-D 或标定双目？有没有 CAD 或参考图像？结果需要离线处理还是进入实时控制环？

2. 认识与区分最常用的视觉基础模型

2.1 一张表掌握核心模型

模型	输入条件	主要输出	最适合的用途 / 关键边界
SAM 2	图像或视频；点、框、Mask 提示	实例 Mask 与跨帧传播	**已知目标的分割和视频追踪**；不输出 6D 位姿。
SAM 3 / 3.1	图像或视频；文本概念、视觉示例或视觉提示	开放词汇检测、Mask、视频跟踪	**按语言寻找目标并保持实例**；3.1 改进多目标视频效率，不等于所有设备均能实时。
Foundation Stereo	标定、同步、极线校正的左右目图像	稠密视差，可换算尺度深度	**有真实双目时估计距离**；不是单目深度或物体姿态估计器。
Fast-Foundation Stereo	与 FoundationStereo 相同	更低延迟的双目视差	**对实时性敏感的双目系统**；需按部署 GPU、分辨率实测。
Foundation Pose	通常需要 RGB-D、目标 Mask，以及 CAD 或少量参考图像	刚体物体 6D 位姿与跟踪	**工具与刚体的姿态初始化/更新**；依赖几何先验与观测质量。
SAM 3D Objects	单幅图像中的目标区域	候选三维形状、外观及场景布局	**无 CAD 时生成形状先验**；生成网格不等于经过标定的工程 CAD。
SAM 3D Body	人体图像，可选关键点/Mask 等提示	人体三维网格、姿态	**人体动作与形状理解**；不能直接推断手—物接触力。

2.2 三组最容易混淆的概念

SAM 2 与 SAM 3：一个偏“追踪已知实例”，一个兼具“根据概念寻找实例”。 目标已由点击或框选指定，SAM 2 就能传播 Mask；任务指令是“找到所有红色螺丝刀”，优先考虑 SAM 3 的文本/示例提示。SAM 3.1 主要改善视频多实例推理效率。复杂长指令仍可能需要 VLM/Agent 先把任务拆成可定位的短概念。

FoundationStereo 与单目深度：几何尺度来源不同。 FoundationStereo 使用经过标定的**真实双目**来预测视差，并结合相机参数恢复尺度深度。单目模型（例如 Depth Anything 3 的相应变体）可从一张图估计深度或多视图几何，但应区分相对深度与专门训练的度量深度版本；不能默认任意模型输出都具有机械臂操作所需的尺度精度。头部相机与不断移动的腕部相机，不能未经外参、同步和立体校正便当作固定左右目。

FoundationPose 与 SAM 3D Objects：一个估计“现在在哪里”，一个估计“大致长什么样”。 FoundationPose 使用 CAD 或参考图像提供物体先验，再根据当前图像估计/追踪刚体姿态。SAM 3D Objects 可以在缺少 CAD 时给出候选形状，但必须另外检查真实尺寸、坐标定义、网格质量与可观测性，不能直接把生成结果当作精密装配模型。

2.3 两类常见补充工具

- **Grounding DINO：** 文本条件的开放词汇目标检测，主要输出边界框；如果只需按语言找框，或希望搭配独立分割器，可考虑它。与 SAM 3 直接输出 Mask 的接口不同。
- **Depth Anything 3：** 覆盖单目与多视图深度/几何任务；选择具体 checkpoint 时需核实是相对深度、度量深度还是多视图几何。可作为无硬件深度时的几何先验，但不可默认替代高精度标定 RGB-D。

3. 根据机器人任务选型与组合

3.1 一个简洁的选型顺序

第一步：先确定最低必要输出。 只需要“找到/持续跟踪目标”时，停在检测或 Mask；需要距离再引入深度；确实需要工具朝向、插装对齐等任务时再加入 6D 位姿。直接视觉策略（VLA）也可能从 RGB 与本体状态直接生成动作，并非必须显式计算位姿。

第二步：检查传感器和先验。 已有可靠 RGB-D 时，优先使用其经过对齐和检验的深度；有标定同步双目时，可以选择 FoundationStereo / Fast-FoundationStereo；只有单目时可选深度先验，但谨慎处理尺度。有 CAD 时优先使用 CAD；没有时考虑多视图参考图像或 SAM 3D Objects 作为候选几何来源。

第三步：按所需输出搭建最小流水线。 不要让每帧都串行运行所有大模型：文本定位可以只在初始化和丢失重定位时执行，连续帧可交给轻量跟踪和位姿更新。

3.2 两条最有代表性的机器人视觉路线

路线 A：显式几何状态（工具抓取、定向、装配）。

> 语言目标 → **SAM 3** 定位/分割 → **Mask + RGB-D 深度 + CAD/参考图像** → **FoundationPose** 初始化并跟踪 6D 位姿 → 将位姿交给机器人控制器；丢失时重新定位。

这条路线适合需要目标坐标系、姿态误差或可解释几何约束的操作。**SAM 3 本身不输出物体 6D 位姿；FoundationPose 也不会凭空提供 CAD 或有效深度。**

路线 B：直接视觉策略（VLA / 视觉闭环操作）。

> 任务语言 + 相机图像 + 机器人本体状态 → **VLA / 视觉策略** → 机器人动作；必要时使用 **SAM 3、跟踪器或几何估计器** 提供目标监测、状态检查与失败恢复。

这条路线不必强制插入 FoundationPose；需要显式位姿时才额外估计。两条路线可以混合：用显式几何辅助安全检查，而不改变策略的主要输入。

3.3 四个典型场景

具体问题	推荐的最小方案	什么时候需要升级
根据语言找到桌上的红色螺丝刀	SAM 3 找目标并输出 Mask；视频中持续跟踪	需要抓取方向时，加入深度和姿态估计。
从任意方向拿起工具并旋转到指定姿态	RGB-D + 目标 Mask + CAD/参考图像 + FoundationPose	遮挡或物体掉落时，触发重定位；接触环节仍需其他反馈。
没有 CAD，想先获得未知物体的粗略形状	SAM 3D Objects 生成候选网格	精密操作前核验尺度、形状与局部几何；必要时重建或扫描。
仅有单目 RGB，想估计场景距离	Depth Anything 3 的合适变体作几何先验	需要可靠米制精度时，添加尺度约束、RGB-D 或标定双目。

4. 实际使用时，哪些问题最值得检查?

4.1 部署前的六项检查

1. **输入前提：** 模型要求 RGB、RGB-D、双目、CAD、参考图像，还是文本/框/Mask？对应资源是否真的可用?
2. **坐标和尺度：** 深度是不是以米为单位？Mask 与深度是否对齐？位姿位于相机系还是机器人基座系？相机外参是否已另行标定?
3. **时序和身份：** 目标是否跨帧保持同一个 ID？有无遮挡时如何重定位？时间戳是采集时刻还是推理完成时刻?
4. **失败模式：** 透明/反光物体、弱纹理、对称形状、快速运动和手部遮挡，分别影响哪一个模块?
5. **时延预算：** 端到端延迟包括图像采集、模型前向、传输与控制；论文 FPS 不等于部署控制频率。
6. **许可和接口：** 查官方权重、代码与商业使用许可；核实输入格式、输出定义、GPU 显存以及是否真的支持所需工作模式。

4.2 不应由视觉大模型独自承担的事情

高置信 Mask 不代表准确位姿；准确位姿不代表接触成功。 灵巧手抓取、精密插装与旋转工具时，往往还需要手指关节状态、接触/力觉、本体状态和主动纠错。物体被遮挡、掉落或重定位失败时，应允许“暂停动作—重新观察—重新初始化”，而不是把过期位姿继续传给控制器。

把模型能力与系统能力分开评估。 官方论文说明模型能做什么；机器人系统是否可用还取决于传感器质量、延迟、外参、对象几何和下游控制。对无法从图像唯一观察的对称角度，不能仅靠换更大的模型解决。

4.3 选型速查：记住这七句话

- **找目标且有语言描述 → SAM 3；** 只要开放词汇边界框 → Grounding DINO。
- **已知目标、想连续得到 Mask → SAM 2；** 多目标视频也可考察 SAM 3.1。
- **已有可信 RGB-D → 直接用现成深度；** 不必为了使用基础模型而再估计一遍。
- **有标定同步双目、要深度 → FoundationStereo；** 紧张的时延预算下考察 Fast-FoundationStereo。
- **单目 RGB、要粗略几何 → Depth Anything 3；** 先核对 checkpoint 的尺度属性。
- **有刚体物体的 CAD/参考图像、要 6D 位姿 → FoundationPose。**
- **缺 CAD、要候选物体形状 → SAM 3D Objects；** 人体三维重建则看 SAM 3D Body。

官方资料与延伸阅读

主要能力边界依据以下官方论文/仓库整理，链接可直接打开：

SAM 2 · SAM 3 / 3.1 · SAM 3.1 更新 · FoundationPose · FoundationStereo · Fast-FoundationStereo · SAM 3D Objects · SAM 3D Body · Grounding DINO · Depth Anything 3

课程衔接： 相机内外参、坐标变换与标定 →《机器人相机标定》；模仿学习数据与动作学习 →《数据采集与模仿学习》；视觉闭环策略与控制 →《具身强化学习》《先进 Robot Agent》。本章刻意不重复上述内容。

改编自《视觉感知与状态估计》原讲义。原教材署名 Xiong Zeng and contributors，采用 CC BY 4.0；第三方模型、代码与插图的许可各自独立。本文为教学性选型指南，并非真实性能或部署保证。