具身智能中的世界模型与世界动作模型：训练、推理与部署

训练目标、生成机制、闭环推理与机器人部署

Foundation of Embodied AI ·教学讲义

2026-10-19

目录

1. 为什么具身策略需要世界预测? . . . 2
2. WAM 的四种建模范式 . . . 2
3. 训练数据究竟长什么样? . . . 3
4. 训练 WAM：从初始化到联合优化 . . . 4
5. WAM 的三条推理路径 . . . 5
6. 高效推理：延迟预算比模型参数量更重要 . . . 5
7. 灵巧操作：真实世界模型为什么更难? . . . 6
8. 如何评价 WAM 的研究贡献? . . . 6
9. 与现有课程的边界和推荐学习路线 . . . 6
10. 论文地图与官方资源 . . . 7

课程首页 ·English ·PDF

项目	说明
主题	世界动作模型
修订日期	2026-10-19
许可	CC BY 4.0 ·Xiong Zeng and contributors

1. 为什么具身策略需要世界预测?

定位：本讲承接 Flow Matching、机器人模仿学习、GR00T/SONIC，面向需要理解 WAM 的训练接口、推理路径及真机部署约束的读者。**范围：**不重复连续性方程、PPO 或基础 Transformer 推导；重点解释 world prediction 与 executable action 之间的连接。

阅读路径：概念与四类架构 → 数据表示 → 训练目标 → 推理模式 → 实时系统 → 接触与失败恢复 → 论文地图。

机器人动作不是与环境无关的文本 token。抓取前物体的姿态、接触后的滑移、手指遮挡和摩擦变化都会改变执行结果。传统视觉语言动作策略（VLA）可以直接拟合条件动作分布

$$\pi_\theta(A_t \mid h_t, \ell), \quad h_t = (o_{t-k:t}, q_{t-k:t}), \quad A_t = (a_t, \dots, a_{t+H-1}).$$

这里 o 是视觉或其他感知量，q 是本体状态，ℓ 是语言目标。**这种条件策略并非必然没有世界知识**：训练数据与表征可能已经隐式编码了动力学。引入世界预测，是为了提供更明确的时序监督、反事实推演或规划接口，而不是断言 VLA 完全不能推理物理。

World Model（WM）通常是行动条件的未来预测器。它可以工作在观测空间或潜在状态空间：

$$p_\phi(o_{t+1:t+H} \mid h_t, A_t), \qquad p_\phi(z_{t+1} \mid z_t, a_t).$$

前一个模型可能合成像素视频，后一个模型预测更适合控制的抽象状态。世界动作模型（WAM）强调将未来预测与机器人**可执行动作**相耦合：可以先想象再行动、借助预测特征生成动作、联合生成视频与动作，或仅在训练时用世界预测作为辅助监督。**WAM 不等同于“推理时必须生成视频”**。

1.1 三种容易混淆的模型

模型	典型输出	核心监督	部署角色
视觉/语言动作策略（VLA）	动作块	动作标签、任务信号	直接动作决策
世界模型（WM）	未来状态/观测	时序变化、动作条件	预测、评估、规划
世界动作模型（WAM）	关联未来的动作或联合输出	预测与动作的耦合信号	可执行策略或其训练途径

边界：视频生成基础模型如果没有可靠的动作条件和物理一致性，不能自动称为可用于控制的世界模型；同样，能生成视觉上合理的视频也不保证预测的接触力或运动满足动力学。

2. WAM 的四种建模范式

2.1 Imagine-then-execute：先预测，再生成动作

将希望发生的未来场景 $\hat{O}^+$ 作为动作生成的中间条件：

$$\hat{O}^+ \sim p_\phi(O^+ \mid h_t, \ell), \qquad A_t \sim \pi_\theta(A \mid h_t, \ell, \hat{O}^+).$$

在理想情况下，预测的视频编码了物体运动路径与目标状态；动作模型再将这类视觉意图映射成具体机器人控制量。缺点是视频采样成本高，生成的未来也可能不可达或与机器人实际动力学不一致。注意：有些实现还会条件化候选动作，不能把上述无动作条件表达视作所有系统的统一定义。

2.2 Video-feature-conditioned：利用视频模型的内部表征

先计算世界模型的潜变量或注意力特征 $f_\phi(h_t, \ell)$，再用动作头输出动作：

$$A_t \sim \pi_\theta(A \mid f_\phi(h_t, \ell), q_t).$$

这种方式可以跳过显式解码整段未来视频。但表征是否真正含有可控制、可接触的信息，需要用交互成功率和分布外恢复测试，而不能仅凭视频生成质量推断。

2.3 Joint video-action：联合建模视频与动作

联合模型可写成

$$p_{\theta,\phi}(O^+, A \mid h_t, \ell),$$

或者按链式法则分解为 $p(O^+ \mid h_t, \ell)p(A \mid O^+, h_t, \ell)$ 等形式。联合建模可共享表征或去噪骨干；**它不意味着视频 token 和动作 token 必须按同一解码顺序生成**。模型设计应区分共享骨干、双分支、交替预测与不同生成时间尺度。

2.4 Auxiliary video prediction：只在训练阶段预测视频

训练时通过未来预测促进更具动力学意义的状态表征；执行时可能只保留动作头：

$$\min_{\theta,\phi} \mathcal{L}_{\text{action}} + \lambda \mathcal{L}_{\text{future}}, \qquad A_t \leftarrow \pi_\theta(h_t, \ell) \text{ at test time.}$$

Fast-WAM 提供了重要证据：世界预测的收益可以体现在训练表征上，并不一定要求部署时完成显式视频生成。但**这不是所有任务或模型都适用的定理**。Fast-WAM

3. 训练数据究竟长什么样?

一个最小的机器人交互序列可以写成

$$\mathcal{D}_R = \{(o_t, q_t, a_t, o_{t+1}, r_t, d_t, \ell, \Delta t)\}_{t=0}^{T-1}.$$

Δt 是真实时间间隔，d_t 是 episode 终止标志；动作 a_t 必须标注单位、参考坐标系、控制模式与实际执行时刻。这里 r_t 非监督预训练的必需项；它主要服务于规划、价值评估或 RL。还应区分**策略期望命令**与**机器人实际执行命令**，尤其当存在控制饱和、延迟与低层滤波时。

3.1 数据来源与可监督目标

数据来源	可监督内容	典型缺陷
互联网/人类视频	视觉演化、物体交互先验	缺机器人动作标签、尺度和相机标定
机器人示教	同步的观测–动作序列	任务与本体覆盖有限
仿真 rollout	完整状态、接触、动作、奖励	视觉与接触 sim-to-real gap
在线交互数据	失败、恢复、状态分布修正	成本高、需安全守护与数据治理

混用视频与动作数据时，可针对缺失标签做损失掩码；**不能凭空给无动作视频补上“真实机器人动作”**。若利用逆动力学或轨迹重定向得到伪动作，应记录置信度与对应机器人本体。训练前必须同步视觉时间戳、机械臂状态、执行动作；像素预测与动作标签若存在系统性延迟，模型可能学到错误因果关系。

3.2 不可忽略的表征设计

视觉：RGB、深度、视频压缩潜变量或 3D token。机器人状态：关节位置/速度、末端位姿、手部编码、控制模式。动作：Δq、末端 SE(3) 增量、目标姿态、低层参考或 latent action。物理环境：接触事件、法向力/切向力、对象位姿与不确定性。训练/部署必须保持同一动作语义；高层预测可以与低层安全控制采用不同频率。

4. 训练 WAM：从初始化到联合优化

4.1 阶段 A：视频/状态预测预训练

如果采用 latent world model，将观测编码为 $z_t = E_\eta(o_t)$，预测未来的时空表征：

$$\hat{z}_{t+1} = F_\phi(z_{\le t}, a_{\le t}), \qquad \mathcal{L}_z = \sum_t \|\hat{z}_{t+1} - \mathrm{sg}(E_\eta(o_{t+1}))\|_2^2.$$

这是示意性的 latent regression，实际还可能使用 token cross-entropy、时序对比学习、JEPA 式预测、扩散/流匹配目标；是否 stop-gradient 取决于具体训练设计。若只有视频没有动作，可做非动作条件预测，但不能从中直接识别对任意机器人命令的干预因果效应。

4.2 阶段 B：动作专家或条件动作生成器

设专家动作块 A^*，从高斯噪声 ε 出发构造插值 $A_\tau = (1-\tau)\varepsilon + \tau A^*$；一个简单的条件 Flow Matching 目标是

$$\mathcal{L}_{\text{act}} = \mathbb{E}_{A^*,\varepsilon,\tau}\left[\|v_\theta(A_\tau, \tau, c_t) - (A^* - \varepsilon)\|_2^2\right],$$

其中 c_t 包括视觉/世界特征、机器人状态和指令。这里**生成时间 τ 与机器人物理时间 t 完全不同**，也不同于关节速度。有关一般条件流匹配的推导请见本课程 Flow Matching 专章，本讲只讨论它和世界预测表征的接口。

4.3 阶段 C：耦合世界和动作损失

统一而非唯一的教学写法：

$$\mathcal{L} = \lambda_a \mathcal{L}_{\text{act}} + \lambda_v \mathcal{L}_{\text{video}} + \lambda_z \mathcal{L}_{\text{latent}} + \lambda_c \mathcal{L}_{\text{consistency}}.$$

$\mathcal{L}_{\text{video}}$ 可是视频扩散噪声/速度回归，$\mathcal{L}_{\text{consistency}}$ 可以约束生成动作与预测的未来状态一致，**但一致性损失需要明确采用已知动力学、可微预测器还是对比目标，并不是不加定义就能直接计算**。若视频与机器人动作数据覆盖不同，训练批次应显式掩码不可观测监督。容易出错的地方包括：仅靠视频损失压制动作学习、world backbone 的灾难性遗忘、跨机器人动作尺度不一致、长时预测误差累积。

4.4 阶段 D：任务适配与 RL（可选）

监督微调旨在拟合目标本体与目标任务中的有效动作。RL 后训练则以真实或仿真交互回报更新可训练模块，例如动作专家、残差或独立的高层选择器。世界模型还可提供预测奖励或候选动作评分，但若预测器在分布外状态误差增大，策略会利用模型漏洞（model exploitation）。应分开验证 model-based planning 的有效性和 policy improvement 的实际收益。

4.5 训练前需要锁定的实验契约

定义明确的 o_t / a_t / ℓ、训练 horizon H、物理时间戳、摄像机外参、动作归一化统计量、episode 边界、世界预测尺度、训练/验证环境划分，以及 unseen-object、unseen-pose 与 recovery 数据切分。对接触丰富的灵巧操作，仅看视频 PSNR 或 FVD 不足以评价控制能力；必须报告任务成功率、重试次数、接触安全和闭环计算时延。

5. WAM 的三条推理路径

5.1 显式未来想象

每次获取观测 h_t 后，生成未来视频或 latent rollout $\hat{O}^+$，再解码 A_t；只执行动作块前 $K \leq H$ 步并重新观测。优点是未来可解释，可检验不同候选轨迹；代价是视频扩散推理和动作生成可能串行叠加，且 “看上去合理” 的未来可能不可执行。

5.2 联合视频–动作生成

单个条件生成过程输出 $(\hat{O}^+, \hat{A})$。应分别明确采样过程的 token 组织、因果掩码、视觉与动作解码顺序，以及是否能够仅从联合模型截取动作。它不自动等价于显式模型预测控制（MPC）：只有实际进行候选评估、优化/筛选，并执行滚动反馈，才能称为相应的规划机制。

5.3 推理时仅保留动作分支

共享世界表征在训练期间受未来预测辅助；部署时计算

$$\hat{A}_t = G_\theta(h_t, q_t, \ell),$$

可省去昂贵的视频解码。需要报告动作分支仍需多少次 Transformer 前向、多少次去噪/ODE 函数评估，以及是否需要访问未来预测中间状态。Fast-WAM 在其实验设置中展示了 190 ms 级延迟；这**不能推广为任意 WAM 的性能承诺**。Fast-WAM

6. 高效推理：延迟预算比模型参数量更重要

端到端延迟必须分解为

$$T_{\text{e2e}} = T_{\text{sense}} + T_{\text{encode}} + T_{\text{world}} + T_{\text{action}} + T_{\text{network}} + T_{\text{dispatch}}.$$

从机器人控制的角度，关键不只是 GPU token/s，而是感知采集到**动作真正生效**的时间。特别是异步推理中，即使高层动作块生成只需数百毫秒，也必须明确旧动作块如何继续执行、新动作块从哪个物理时间戳开始接管。

6.1 可以优化哪里?

优化手段	降低什么成本	主要风险
缩短视频预测或跳过视频解码	视频采样延迟	失去明确未来检查
减少 flow/diffusion 步数	动作生成函数评估	模式覆盖或精度下降
KV Cache（因果模型）	重复前缀注意力计算	图像/状态更新与缓存失效条件
FlashAttention	注意力内存 IO 与临时张量	不必然等于整体推理同比例加速
跨 denoising/replanning cache	重复骨干计算	时间步变化、输入变化导致陈旧特征
量化/蒸馏/轻量动作头	模型内存与计算	接触精度、校准及尾部时延变化

技术边界： KV Cache 适用于满足特定因果结构的自回归推理，不能未经论证直接搬到双向视频 DiT；跨扩散步缓存也不是普通 KV Cache。FlashAttention 可以提高注意力核效率，但高层分辨率视频生成仍可能主要受其他算子与去噪次数限制。这部分的底层算子推导放在 “具身基础模型的高效训练与实时推理” 专讲。

6.2 物理时钟与动作块

令低层周期 Δt_c、高层输出长度 H、计划执行长度 K、生成延迟 d 个控制周期。通常必须满足连续命令覆盖或提供稳定的后备控制：高层在计算新动作块时，底层不能无约束暂停。RTC 的已承诺前缀、动作块 inpainting 和训练时条件化已在模仿学习章节讲过；这里强调 **WAM 视频计算额外引入的延迟和可能的相机–动作时间错位**。

7. 灵巧操作：真实世界模型为什么更难?

在抓取、插接、旋转等任务中，视觉结果可能无法唯一识别接触状态：同样的图像可以对应不同的法向力、静摩擦裕度或即将发生的滑移。纯 RGB 视频预测需要面对部分可观测性。因此，世界状态最好纳入关节/电机电流、力/触觉、可见对象位姿及置信度；没有触觉时，应诚实地表示不可观测量的不确定性。

一种任务级状态抽象是

$$z_t = (T_{\text{obj}}, T_{\text{hand}}, q_t, \hat{c}_t, \Sigma_t),$$

其中 $\hat{c}_t$ 是估计接触模式，Σ_t 是状态不确定度。训练可用接触事件辅助损失，但不能假定每条视频天然有可靠接触标签。用于控制的测试应包含自由空间轨迹、初次接触、稳定抓持、滑移、掉落与恢复，而非只测试理想起始位置。

7.1 一个贯穿案例：任意位置拿起螺丝刀并旋转

高层目标是找到工具并建立合适抓握，再移动到固定作业位姿。世界分支预测 “若以某种接近角度抓持，工具是否移动/掉落/碰撞”；动作分支输出末端与手指动作；本体感知闭环低层控制器负责频繁纠偏。若视觉预测给出 “已抓住” 而电流/位置残差显示打滑，不能继续盲目执行动作块，应触发重观测、保持或恢复策略。

7.2 真机部署最低检查清单

1. 明确动作类型、坐标系、频率与安全限幅；在仿真和真机一致。
2. 测量相机曝光、编码、网络、GPU 推理、控制下发及实际执行的时间戳。
3. 统计 $p50/p95/p99$ 延迟而非仅单次最短时间；准备推理超时后备策略。
4. 区分预测成功、动作执行成功和真实任务成功；收集失败恢复轨迹。
5. 将世界模型的不确定度当作风险线索，而不是可靠接触力传感器的替代品。

8. 如何评价 WAM 的研究贡献?

评价维度	建议指标	容易误判的地方
世界预测	长短时预测、运动一致性、校准	视频画质并非物理正确性
策略能力	成功率、跨物体/姿态泛化	仅训练分布成功率
闭环鲁棒性	外部扰动、遮挡、失败恢复	只报告开环重放
系统实时性	端到端 p95 延迟、控制连续性	只测纯 GPU forward
数据效率	新本体示教需求、样本成本	混淆预训练总数据与适配数据
安全性	碰撞、力矩、接触损伤、超时回退	靠预测视频保证安全

对于一项新 WAM，至少做四组消融：去掉视频预训练、去掉视频辅助损失、去掉显式测试时未来预测、去掉真实闭环重规划。**这些组件影响不同的能力来源，不能仅用 “WAM vs VLA” 单项比较来判断因果。**

9. 与现有课程的边界和推荐学习路线

本讲不重新推导 Flow Matching 的概率路径与连续性方程；这些见 Flow Matching。BC/DAgger/ACT/RTC 的数据协议见 Imitation Learning。冻结/更新基础生成器的 RL 算法见 RL Post-training。GR00T/SONIC 则重点介绍 System 1–System 0 的动作接口。WAM 本讲专注**世界预测如何帮助动作学习与在线决策**，Robot Agent 再讨论外层任务编排、调用工具、成功验证和重规划。

建议学习顺序：世界预测定义 → 四范式 → 训练数据契约 → 视频/动作损失 → 三种推理路径 → 延迟与安全预算 → 接触/扰动测试。实现不同 WAM 之前，先决定究竟需要可视化的 future imagination，还是只想利用未来监督提升表征。

10. 论文地图与官方资源

1. Zhang, Zeng, Zhang. From World Models to World Action Models: A Concise Tutorial for Robotics, 2026. 概念、表示与四类 WAM 范式。
2. Ye et al. World Action Models are Zero-shot Policies (DreamZero), 2026. 视频扩散骨干和联合世界—动作建模。
3. Yuan et al. Fast-WAM: Do World Action Models Need Test-time Future Imagination?, 2026. 训练时视频监督与测试时视频生成的区分。
4. NVIDIA. Cosmos, 视频/世界生成的基础设施入口；它并不是单个可直接部署的机器人动作策略。
5. Physical Intelligence. openpi, 机器人动作专家及 Flow Matching 实现参考。
6. Chi et al. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion, 2023. 动作块扩散基线。
7. Lipman et al. Flow Matching for Generative Modeling, 2023. 生成式速度场的数学基础。

文档说明：教学表达式未必是各篇论文的原始损失。具体实验数字和计算系统会随论文版本、硬件与复现条件变化。此教程是课程讲义而非复现报告；未执行模型训练和真实机器人实验。