世界动作模型：从 DreamZero 到 Dream-1

训练机制、高效推理、跨本体迁移与部署

2026-10-30

目录

1. 什么是世界动作模型? . . . 2
2. WAM 如何训练? . . . 2
3. DreamZero：联合生成与实时闭环 . . . 3
4. Dream-1：零样本跨本体与能力边界 . . . 4
5. 高效 WAM：推理时究竟需要多少未来信息? . . . 5
6. VLA 与 WAM：如何公平比较与选择? . . . 6
7. 真机部署、接触操作与研究方向 . . . 7

参考资料 . . . 7

课程首页 ·English ·PDF

项目	说明
主题	世界动作模型
修订日期	2026-10-30
前置知识	模仿学习、流匹配与入门机器人控制
许可	CC BY-NC-SA 4.0 ·Xiong Zeng and contributors

1. 什么是世界动作模型?

核心问题：机器人不仅要识别 “现在有什么”，还要选择 “做什么才会让场景按目标变化”。世界动作模型（World Action Model, **WAM**）把视频中的时序变化与可执行动作联系起来，学习从视觉、机器人状态和语言指令到动作的策略。本文将 **WAM 视为机器人策略**。

1.1 从直接预测动作到利用未来信息

令 o_t 为相机观测，q_t 为本体状态，ℓ 为语言指令，$h_t = (o_{t-k:t}, q_{t-k:t})$ 为历史，$A_t = (a_t, \dots, a_{t+H-1})$ 为动作块。一个典型的直接动作策略可以写成

$$A_t \sim \pi_\theta(A \mid h_t, \ell).$$

WAM 的额外学习信号来自**动作与未来视觉变化之间的关系**。对于联合视频–动作生成型 WAM，可以用下式表示：

$$(O_t^+, A_t) \sim p_\theta(O^+, A \mid h_t, \ell), \qquad O_t^+ = (o_{t+1}, \dots, o_{t+F}).$$

重要区别：上式只描述一类 WAM，不是所有 WAM 的定义。WAM 可以在训练时预测未来、在推理时只生成动作；也可以复用未来的隐式特征，而不渲染未来视频。视频中物体运动的合理性也不自动保证接触力、摩擦和可达性正确。

1.2 四种常见范式

范式	推理过程	主要收益	主要代价或风险
Imagine-then-execute	先生成候选未来，再据此选择动作	可观察候选结果	视频采样慢；想象不一定可执行
Joint video-action	联合生成未来视觉与动作块	时序信息与动作紧耦合	联合去噪计算昂贵
Video-feature-conditioned	利用视频模型的中间特征生成动作	不一定需要像素解码	特征未必足以处理接触
Auxiliary video prediction	训练时预测未来，部署只保留动作路径	延迟小、便于实时部署	可能丢失测试时的未来条件信息

这些范式不是严格互斥的产品分类：一个系统可能同时使用联合训练、隐式未来特征与轻量动作头。**判断 WAM 的关键**是未来监督如何影响动作，而不是推理时有没有生成可见视频。[1, 3]

1.3 三个不要混淆的概念

- **未来预测 $\neq$ 物理正确**。 RGB 视频难以可靠反映抓取力、静摩擦阈值与微小滑移。
- **跨本体动作接口 $\neq$ 跨本体成功率**。统一末端位姿（EEF pose）与逆运动学（IK）只是让不同机器人接收相同高层命令，并不提供可行轨迹或任务能力。
- **动作块长度 $\neq$ 推理延迟**。生成一个可执行 1.6 s 的动作块，不意味着模型耗时 1.6 s，也不意味着可以每 20 ms 重新闭环。

本节结论： WAM 的研究重点是利用时序视觉先验改善机器人动作的泛化与控制质量，而非为视频生成本身追求更逼真的画面。

2. WAM 如何训练?

2.1 数据需要同时回答 “看到了什么” 和 “执行了什么”

机器人示教通常包含同步的 $(o_t, q_t, a_t, o_{t+1}, \ell, \Delta t)$；有奖励的在线交互还可加入 (r_t, d_t)。其中相机时间戳、动作执行时间、控制频率、坐标系、单位和控制模式必须明确，否则视频变化可能与错误的动作配对。

数据来源	主要贡献	必须说明的限制
人类或互联网视频	运动、物体交互、任务时序先验	没有机器人真实动作标签
机器人示教/遥操	视频、本体状态和动作的监督对齐	机器人与任务覆盖有限
仿真轨迹	可扩展动作与扰动样本	几何、接触及渲染域差异
在线真机交互	失败恢复与分布外数据	成本、安全与数据治理

纯视频可以训练视觉预测部分，但**不能把缺失的机器人动作当作真实标签**。逆动力学估计和动作重定向产生的伪标签应单独标识；对不同本体还要统一动作语义，例如 base/EEF 坐标系、增量/绝对位姿和夹爪命令。[1]

2.2 从视频先验到机器人动作

一种常见路线是以预训练视频 Diffusion Transformer（DiT）提供运动表征，再加入机器人状态编码器、动作编码器/解码器，将视频 latent z 和动作 A 对齐。可选的训练机制包括动作行为克隆、Flow Matching、视频预测和跨模态一致性；**并非所有 WAM 都共享一个损失函数**。

为了理解生成式动作学习，令 $x^\star$ 为目标动作或拼接的 “视频 latent + 动作”，$\epsilon \sim \mathcal{N}(0, I)$。直线 Flow Matching 的一个标准教学形式是

$$x_\tau = (1-\tau)\epsilon + \tau x^\star, \qquad \mathcal{L}_{\text{FM}} = \mathbb{E}\left[\left\| v_\theta(x_\tau, \tau, c) - (x^\star - \epsilon) \right\|_2^2\right],$$

其中 $\tau \in [0,1]$ 是**生成时间**，不是机器人控制时间 t；c 汇集视觉历史、语言与本体条件。DreamZero 使用联合视频–动作速度场；Fast-WAM 则主要研究训练时视频监督对部署动作预测的贡献。[1, 3]

2.3 三种部署路径

可以把共同主线记作：**收集对齐轨迹 → 学习视频运动先验与动作映射 → 给定当前真实观测 → 输出动作块 → 执行一部分 → 再观测并纠偏**。差别在于推理时用多少未来信息：

1. **显式未来：**生成或采样未来视觉结果，再计算动作；适合需要解释、筛选候选计划的场景。
2. **联合未来与动作：**一次联合采样未来视频 latent 和动作，借助真实观测更新下一次生成的条件。
3. **仅动作或压缩未来特征：**用训练得到的时序表征直接输出动作，或者只读取少量未来特征，降低部署成本。

本节结论：数据同步与动作语义是训练 WAM 的先决条件；是否需要在部署时显式生成未来，应由延迟与鲁棒性实验决定。

3. DreamZero：联合生成与实时闭环

DreamZero（Ye 等，2026）的公开论文、模型与代码为研究 WAM 提供了可复现的主线。它从预训练视频生成骨干出发，将未来视频与动作块视作一个相关的生成任务。[1, 2]

3.1 联合架构为什么不同于 “先生成视频再运行 IK”?

DreamZero 基于 **Wan2.1-I2V-14B-480P** 视频骨干，以语言、视觉历史和本体状态作为条件，联合建模未来视频 latent 与动作。设第 k 个时间块的干净目标为 $x_k^\star = [z_k^\star, A_k^\star]$，则联合训练可概念化为

$$\mathcal{L}_{\text{joint}} = \mathbb{E}\Big[\left\| u_\theta(x_{k,\tau}, \tau; h_k, \ell, q_k) - (x_k^\star - \epsilon_k) \right\|_2^2\Big].$$

这是一种**便于教学的抽象写法**，并非论文所有加权项的逐字复现。核心是视频和动作在联合建模中相互约束，而不是先独立生成完整视频、再依赖一个外部 IK 求解动作。DreamZero 使用因果 chunk 和真实历史条件，使模型在连续执行中反复获得新观测。[1]

3.2 数据规模、时间尺度与零样本结论

论文在 AgiBot 设置中使用约 **500 小时、7,200 段、22 个环境**的多样机器人轨迹。对应实验中的视频约 5 FPS、低层动作约 30 Hz、动作块 $H = 48$ 步。这意味着动作块覆盖约 $48/30 = 1.6\,\text{s}$，**不等于**模型推理耗时。大模型仍需要有覆盖面的机器人数据，并非 “只用 30 分钟即可从零训练”。[1]

论文报告，相比所比较的强 VLA 基线，DreamZero 在未见任务和环境的**任务进度**指标上显著领先；任务进度不等同于 “完整任务成功率”。它还展示了两种应分开的跨本体证据：其他机器人/人类视频可提供额外学习信号；在新机器人 YAM 上使用约 **30 分钟 play data 适配**后，模型再对未见任务进行零样本测试。后者不是 “未见本体完全零数据部署”。[1]

3.3 150 ms 与 7 Hz 如何实现?

基础模型联合采样开销很高。论文采用异步推理与动作执行、并行计算、算子和缓存优化，并提出 **DreamZero-Flash**：训练时改变视频与动作的噪声时间分布，使模型在未来视频尚不精确时仍能生成动作。

论文同一任务下的设置	去噪步数	任务进度	单块推理时间
DreamZero	4	83%	350 ms
DreamZero 直接压到一步	1	52%	150 ms
DreamZero-Flash	1	74%	150 ms

该组结果说明**减步数会损害质量，训练方案需要配套修改**。论文进一步报告在 **两张 GB200** 上约 150 ms/块、约 7 Hz 的高层闭环；这是特定硬件和工程配置下的报告值，不应直接外推到单张 RTX 4090 或其他任务。[1]

真正的闭环不是永远播放模型想象的未来：执行一部分动作后，应编码新采集的**真实图像与真实本体状态**，更新下一轮条件历史。KV cache 可以复用因果历史，但不能替代接触反馈或消除视觉估计误差。

本节结论： DreamZero 说明了联合生成式 WAM 可以通过系统优化实现真机闭环，但其真实泛化证据、动作时钟和计算硬件必须连同指标一起阅读。

4. Dream-1：零样本跨本体与能力边界

Dream Labs 在 **2026 年 10 月**发布 Dream-1 及其云端 API。官方展示其在多种未见双臂平行夹爪机器人上的零样本控制；截至本文修订日期，公开材料仍以**技术公告和产品演示**为主，并未给出 DreamZero 那样完整的权重、训练配方与消融细节。因此下面区分 “官方展示”“可合理解释的机制” 和 “尚待验证的因果结论”。[4]

4.1 让不同机器人使用同一种动作语言

Dream-1 除已支持本体的关节控制外，还可输出左右末端执行器（EEF）的目标位姿及夹爪开合。对机器人 r，可将部署接口抽象为

$$A_t^{\text{shared}} = \{(T^{\star}_{\text{EE},i}, g_i)\}_{i\in\{L,R\}}, \qquad q^{\star}_{t+1} = \text{IK}_r(A_t^{\text{shared}}; q_t, \mathcal{C}_r).$$

这是**教学抽象**，不是 Dream-1 公开的精确 action tensor；IK 提供关节目标，仍需碰撞检测、轨迹约束和底层控制器执行。共享 EEF 接口减小了机器人之间的关节空间差异，但单独使用 IK 并不能赋予机器人新技能，且 VLA 同样可以采用共享 EEF 表示。[4]

4.2 为什么视觉先验可能有助于跨本体?

官方介绍的观测包括**头部一个相机与左右手腕各一个相机**。头部提供物体、任务和机器人整体几何，腕部视角提供局部操作变化。不同机器人虽然关节布局不同，物体被接近、抓起、搬运、放下等视觉变化具有一部分可共享结构。可用三条互补线索理解：**共享 EEF/IK 动作接口、视频—动作时序监督、跨本体视觉表示**。

但这三者的各自独立贡献，仍需在**相同相机、动作空间、训练数据和控制器**下消融验证。不能因为 Dream-1 展示跨本体迁移，就断言 “只有 WAM 能零样本跨本体”；VLA 的 LAP-3B 也报告了未见机器人上的零样本迁移结果。[4, 8]

4.3 Zero-shot 不等于不需要后训练

层次	含义	DreamZero / Dream-1 的区别
未见任务/环境	本体可能已见，任务或场景改变	两者都有相关展示
少样本本体适配	先收集该机器人数据，再更新策略	DreamZero 的 YAM 约 30 分钟属于此类
零样本本体迁移	未用新本体数据微调就直接尝试	Dream-1 对部分双臂夹爪机器人有相关演示

Dream-1 公告同时指出 IK、关节限位、工作空间和动力学差异的限制，并提供 Fine-tuning-as-a-Service（FaaS）。它展示了**用 5 分钟本体数据进行一些适配**的案例；对于与平行夹爪相距较远的灵巧手配置，官方展示的是使用更多本体数据的适配，而非同等条件下的零样本能力。[4]

官方 API 每次返回约 **1.6 秒动作覆盖范围**，并公布按动作小时估算的服务价格，但没有在公告中完整提供可复现的端到端网络 $p95$ 延迟、端侧缓存和底层控制频率。因此不能直接将 DreamZero 的 150 ms 结果记为 Dream-1 的 API 延迟。[4]

本节结论： Dream-1 的意义是展示 “共享机器人动作接口 + 视频时序先验” 的跨本体潜力；但当前公开证据不能证明 WAM 必然优于 VLA，也不意味着未见灵巧手可直接可靠部署。

5. 高效 WAM：推理时究竟需要多少未来信息?

部署 WAM 的关键矛盾是：**未来信息可能改善鲁棒性，但视频模型和动作生成又会增加延迟**。 2026 年的 Fast-WAM 与两篇同名 Faster-WAM 论文探索了三个不同折中点。[3, 5, 6]

5.1 Fast-WAM：视频共训练，推理只保留动作

Fast-WAM（Yuan 等，2026）保留**训练时的视频预测监督**，推理时使用视频骨干的单次表征而不再生成未来视频。作者通过消融发现：在其基准设置里，移除视频共训练的性能损失，往往比取消测试时显式未来生成更大。论文报告约 **190 ms** 推理、比其对比的显式未来生成方案快 **4 倍以上**；这是论文指定硬件和工作负载下的数字。[3]

这回答的是 “**未来预测的主要收益能否在训练时得到?** ” 而不是 “所有任务都不需要未来特征”。

5.2 Faster-WAM（Ma 等）：轻量动作头

Faster-WAM: Do World Action Models Need Deep Action Modules?（arXiv:2608.02365）把大部分表征能力留给视频骨干，用单层动作 expert，通过 **Lite KV-Fusion** 访问多层视频特征。项目页报告在特定真机工作站上约 **129 ms**，同一实验中的 Fast-WAM 为 **502 ms**；这组数字不能与另一论文的设备直接排名。其贡献针对的是**动作头深度与计算冗余**。[5]

5.3 Faster-WAM（Zhao 等）：稀疏未来条件化

Faster-WAM: Efficient Inference-Time Future Conditioning for Robust World Action Models（arXiv:2608.04404）研究的是另一问题：完全删除推理期未来表征，是否会牺牲分布外鲁棒性? 方法使用 **SparseMoT** 与 **Interval KV-Fusion**，只在少量阶段复用未来特征。

在该论文的 LIBERO-Plus 协议中，它报告 **73.57%** 成功率，Fast-WAM 对照为 **49.14%**，同时比作者实现的 Joint-WAM 快 **2.21 倍**。这支持 “推理时保留少量未来表征在部分分布偏移下有价值”，但**不是**跨论文、跨硬件的统一性能排名。[6]

方法	推理时保留什么?	试图解决的问题
DreamZero-Flash	联合视频–动作采样，压缩生成步数	联合生成太慢
Fast-WAM	训练出的世界表征，主要走动作推理路径	不必每次显式生成未来
Faster-WAM（Ma）	多层视频特征 + 单层动作头	动作 expert 过深
Faster-WAM（Zhao）	稀疏未来特征 + 动作去噪	速度与 OOD 鲁棒性的折中

本节结论： “不生成未来视频” 与 “完全不使用未来信息” 不是同义词。真正的技术选型，是在**无显式未来、压缩未来特征、联合未来生成**之间找到任务需要的工作点。

6. VLA 与 WAM：如何公平比较与选择?

6.1 先比较学习信号，不按名称贴标签

对比维度	典型直接动作 VLA	典型 WAM（多种变体）
主要训练监督	观测、语言到动作	动作监督之外还关联未来视觉变化
常用基础先验	VLM 的视觉语义表征	视频模型的时序运动表征
推理输出	离散动作或连续动作块	最终同样输出可执行动作块
推理代价	取决于骨干、动作头与采样步数	还取决于未来特征/视频是否在推理时保留
泛化假设	语言、对象语义和动作分布迁移	时序运动与交互变化有助于陌生任务
典型风险	动作覆盖不足、感知偏差	上述风险外，还可能有视频幻觉与额外延迟

不能说 “VLA 一定单步，WAM 一定多步”；$\pi_0/\pi_{0.5}$ 等 VLA 也可以使用 Flow Matching 采样动作。也不能说 “VLA 必须微调，WAM 不需要微调”：训练数据覆盖、统一动作空间、相机布局和控制器都可能决定迁移成败。LAP-3B 的零样本跨本体实验是重要的反例。[8]

6.2 算力与延迟应该怎样核算?

部署显存至少包含权重、激活、KV cache、视觉 latent 与运行时工作区。对 P 个参数、每参数 b bit 的模型，**权重理论下界**可写为

$$M_{\text{weights}}\ [\text{GB}] \approx \frac{Pb}{8 \times 10^9}, \qquad M_{\text{peak}} > M_{\text{weights}}.$$

以十进制单位计，BF16 约为每十亿参数 2 GB；该值**不是**实际 GPU 显存推荐配置。视频帧数、分辨率、token 数、去噪步数、量化、共享注意力和并行方式都显著改变计算量。由于训练语料、预训练覆盖、硬件和成功率指标不统一，**不存在有根据的 “WAM 一定比 VLA 贵几倍” 普适数字**。

估计部署时延至少需要

$$T_{\text{e2e}} = T_{\text{sense}} + T_{\text{encode}} + T_{\text{network}} + T_{\text{model}} + T_{\text{dispatch}}.$$

工程上还应报告 $p50/p95/p99$、并发负载、动作执行时长和闭环纠偏频率。模型加速不自动意味着整条控制链同比例加速。

6.3 一个可操作的选型逻辑

- **机器人动作数据充分、GPU 有限、控制频率紧张：**优先建立直接动作 VLA/Flow policy 基线；在相同数据上加入视频共训练，检验是否真的获益。
- **新任务中物体运动变化复杂、时序先验可能重要：**比较 Fast-WAM 与保留压缩未来特征的 WAM，重点观察分布外成功率与恢复能力。
- **需要可解释的候选未来或视觉任务计划：**才考虑完整联合未来采样，并核算其算力与真实闭环代价。
- **机器人本体变化很大：**首先统一动作坐标系和末端控制接口，再测零样本结果；不要把 IK 的收益错误归因于视频生成。

为了评估 “视频监督的独立价值”，应固定机器人、任务、控制模式、相机、动作空间、训练数据和评价预算，只改变是否加入未来监督以及推理时保留多少未来特征。

本节结论： WAM 和 VLA 是可比较、可组合的策略设计，不是非此即彼的两种机器人形态。选择取决于**分布外可靠性、延迟预算、数据规模和部署接口**。

7. 真机部署、接触操作与研究方向

7.1 将模型时钟连接到机器人时钟

真机有三个需要分别报告的时间尺度：

1. **底层控制频率** f_{ctrl}：关节或末端命令实际更新频率。
2. **策略闭环频率** f_{policy}：模型重新读取真实观测并重新规划的频率。
3. **动作块覆盖时长** H/f_{ctrl}：一段预测动作可执行多久。

实际部署建议采用 “相机与状态同步 → WAM 推理 → 安全过滤/IK → 低层控制器 → 新观测” 的分层结构。若推理是异步的，需为动作块加时间戳和有效期，在新的动作块到来时做平滑交接；失联或超时应有安全停止策略。

7.2 接触操作不能只靠视觉想象

精密接触任务的核心失败模式包括：遮挡引起的物体位姿误差、接触瞬间模型时延、摩擦和柔顺性失配、手指滑移、IK 可达但碰撞不可行。视频预测有助于 “物体应该如何运动” 的高层先验，但**不能代替**力/触觉反馈、阻抗/柔顺控制、限幅或碰撞检测。

尤其从双臂平行夹爪迁移到**多指灵巧手**时，动作空间、接触维度与低层控制差异很大。对这一类任务，合理路线通常是：WAM 提供目标与操作意图；可观测状态估计提供闭环反馈；低层控制器负责力与稳定性；必要时使用任务示教、残差策略或 RL 后训练补偿接触误差。这是**工程研究建议**，不是 Dream-1 已证实的通用配方。

7.3 评价一个 WAM 研究结果需要什么证据?

测量对象	至少应报告
任务泛化	已见/未见任务、完整成功率及任务进度的区别
本体泛化	新机器人是否参加预训练；是否收集了适配数据
时序鲁棒性	相机抖动、遮挡、物体位置变化、接触扰动
计算成本	同硬件端到端延迟、$p95$、显存、吞吐、推理步数
可执行性	动作约束违规、IK 失败、碰撞、滑移和恢复率
可复现性	权重/代码/数据协议、控制接口、实验次数与方差

最值得做的消融：在同一骨干、机器人和数据下，比较 “无视频监督 → 训练时视频监督 → 测试时压缩未来条件 → 完整联合未来生成”。这比仅比较两篇论文报告的最高成功率，更能回答 “视频模型究竟为机器人控制贡献了什么”。

课程结束时应记住三句话：

1. WAM 的价值是**未来相关的动作表示和时序监督**，不是生成好看的视频。
2. DreamZero 展示联合生成与优化后的闭环能力；Dream-1 展示部分未见双臂夹爪机器人的迁移潜力，但公开证据层级不同。
3. 高效 WAM 的关键问题不是 “是否世界模型”，而是**在保证任务可靠性的前提下，推理时保留多少未来信息**。

参考资料

[1] Ye et al., *World Action Models are Zero-shot Policies* (DreamZero), 2026. 主要参考：联合建模、训练数据、加速与真机实验。

[2] NVIDIA GEAR, DreamZero 官方项目与开源实现, 2026.

[3] Yuan et al., *Fast-WAM: Do World Action Models Need Test-time Future Imagination?*, 2026.

[4] Dream Labs, *Zero-Shot to New Robots: Introducing Dream-1*, 2026-10. **官方技术公告；不等同于完整公开的同行评审论文。**

[5] Ma et al., *Faster-WAM: Do World Action Models Need Deep Action Modules?*, 2026.

[6] Zhao et al., *Faster-WAM: Efficient Inference-Time Future Conditioning for Robust World Action Models*, 2026. **与 [5] 不同的同名论文。**

[7] Su et al., *1Step-WAM: Your World Action Model but Faster using 1-Step Action Generation*, 2026. 延伸阅读：一步动作生成与推理并行。

[8] Zha et al., *LAP: Language-Action Pre-training Enables Zero-Shot Cross-Embodiment Transfer*, RSS 2026. 对比证据：VLA 同样可能零样本跨本体。

文中标为 “教学抽象” 的公式不代表具体模型公开的逐项实现。